

AIF-C01

AWS CERTIFIED AI PRACTITIONER

Guia de revisão

Fundamentos de IA e ML, IA generativa, agentes, foundation models, IA responsável e segurança para a revisão da certificação.

Por Erik Nathan · eriknathan.me

DOMÍNIOS DO EXAME • PESOS OFICIAIS

20%

Fundamentals of AI and ML

24%

Fundamentals of GenAI

28%

Applications of Foundation Models

14%

Guidelines for Responsible AI

14%

Security, Compliance, and Governance

Sumário

COMO USAR ESTE GUIA

Números, preços e atualizações	5
Método para questões do AI Practitioner	5

Formato do exame AIF-C01	6
Domínios do exame AIF-C01 (pesos oficiais)	6

CAPÍTULO 1 – FUNDAMENTOS DE IA E ML

1.1	Conceitos e terminologia	7
	Termos básicos	7
	Semelhanças e diferenças entre IA, ML, deep learning, GenAI e IA agêntica	7
1.2	Tipos de dados e de aprendizado	8

	Tipos de dados em modelos de IA	8
	Tipos de aprendizado	8
1.3	Tipos de inferência	8
	Como o modelo atende às requisições	8
1.4	Decisão rápida – Fundamentos de IA e ML	9

CAPÍTULO 2 – CASOS DE USO E SERVIÇOS DE IA

2.1	Quando a IA agrega valor	10
	Onde IA/ML ajuda	10
	Quando IA/ML não é apropriada	10
	Escolhendo a técnica de ML	10
2.2	Aplicações reais e serviços gerenciados	11

	Exemplos de aplicações de IA	11
	Serviços de IA gerenciados (sem treinar modelo)	11
2.3	ML tradicional ou foundation model	12
	Como decidir	12
2.4	Decisão rápida – Casos de uso e serviços	12

CAPÍTULO 3 – CICLO DE VIDA DE IA/ML E MLOPS

3.1	Pipeline de IA/ML	13
	Etapas e o que acontece em cada uma	13
	Serviços e recursos por etapa	13
3.2	Fontes de modelos e uso em produção	14
	De onde vêm os modelos	14
	Formas de usar um modelo em produção	14

3.3	MLOps	14
	Conceitos fundamentais	14
3.4	Métricas de avaliação	15
	Métricas de desempenho de classificação	15
	Métricas de negócio	15
3.5	Decisão rápida – Ciclo de vida e MLOps	15

CAPÍTULO 4 – FUNDAMENTOS DE IA GENERATIVA

4.1	Conceitos básicos de IA generativa	17
	Termos fundamentais	17
	Casos de uso de IA generativa	17
	Ciclo de vida de um foundation model	17
4.2	Tokens, custo e contexto	18
	Preço baseado em tokens	18
	Engenharia de contexto	18

4.3	Capacidades e limitações	18
	Vantagens da IA generativa	18
	Desvantagens e limitações	18
	Seleção de modelos de IA generativa	19
	Valor de negócio e métricas	19
4.4	Decisão rápida – Fundamentos de IA generativa	19

CAPÍTULO 5 – IA AGÊNTICA E AGENTES

5.1	Conceitos fundamentais de IA agêntica	20
	O que compõe um agente	20
	Model Context Protocol (MCP)	20
	Padrões de sistemas multiagente	20
	Aplicações de negócio de agentes	21

5.2	Serviços AWS para agentes	21
	Amazon Bedrock AgentCore	21
	Strands Agents, Kiro e outros serviços agênticos	22
5.3	Decisão rápida – IA agêntica	22

CAPÍTULO 6 – SERVIÇOS AWS PARA IA GENERATIVA

6.1	Amazon Bedrock	23	Amazon Q e a transição para Kiro e Amazon Quick	24
	O que é e o que oferece	23		
	Família Amazon Nova	23	Vantagens dos serviços de IA generativa da AWS	24
6.2	SageMaker AI, JumpStart e outros serviços	24	6.3 Custos e trade-offs	25
	Amazon SageMaker AI e SageMaker JumpStart	24	Opções de preço e fatores de custo	25
			6.4 Decisão rápida – Serviços de IA generativa	25

CAPÍTULO 7 – APLICAÇÕES COM FOUNDATION MODELS: DESIGN, RAG E CUSTOMIZAÇÃO

7.1	Critérios de seleção e parâmetros de inferência	26	Bancos vetoriais na AWS	27
	Critérios para escolher um FM	26	7.3 Abordagens de customização	27
	Parâmetros de inferência	26	Comparação de custo e esforço	27
7.2	Retrieval Augmented Generation (RAG)	27	7.4 Agentes em aplicações	28
	Como o RAG funciona	27	O papel dos agentes no design	28
	Benefícios e aplicações de negócio	27	7.5 Decisão rápida – Design, RAG e customização	28

CAPÍTULO 8 – ENGENHARIA DE PROMPTS

8.1	Construção de prompts	30	8.3 Riscos e gerenciamento de prompts	31
	Elementos de um prompt	30	Riscos e limitações	31
8.2	Técnicas de prompt	30	Amazon Bedrock Prompt Management	31
	Técnicas cobradas	30	8.4 Decisão rápida – Engenharia de prompts	31
	Benefícios e boas práticas	31		

CAPÍTULO 9 – TREINAMENTO, FINE-TUNING E AVALIAÇÃO DE FMS

9.1	Treinamento e fine-tuning	33	Abordagens de avaliação	34
	Elementos do treinamento de um FM	33	Métricas de avaliação de FMs	34
	Métodos de fine-tuning	33	Avaliar aplicações e alinhamento com o negócio	34
	Preparação de dados para fine-tuning	33		
9.2	Avaliação de foundation models	34	9.3 Decisão rápida – Treinamento e avaliação	34

CAPÍTULO 10 – IA RESPONSÁVEL

10.1	Características da IA responsável	36	Seleção responsável de modelos	38
	Dimensões da IA responsável	36	10.3 Transparência e explicabilidade	38
	Ferramentas para IA responsável na AWS	36	Modelos transparentes vs. caixa-preta	38
	Filtros do Amazon Bedrock Guardrails	37	Ferramentas de transparência e explicabilidade	38
10.2	Dados, vies e riscos	37	Trade-offs entre segurança, transparência e desempenho	38
	Características de bons conjuntos de dados	37	Design centrado no humano para IA explicável	38
	Vies e variância	37		
	Como detectar e monitorar vies, confiabilidade e veracidade	37	10.4 Decisão rápida – IA responsável	39
	Riscos legais da IA generativa	38		

CAPÍTULO 11 – SEGURANÇA, CONFORMIDADE E GOVERNANÇA PARA IA

11.1	Proteger sistemas de IA	40	Origem dos dados e engenharia de dados segura	41
	Serviços e recursos de segurança	40		
	Considerações de segurança e privacidade	40	11.2 Governança e conformidade	41
	Deteção de alucinação e grounding	41	Serviços de governança e conformidade	41

Estratégias de governança de dados	42	Generative AI Security Scoping Matrix	42
Processos e frameworks de governança	42	11.3 Decisão rápida — Segurança e governança	42

CAPÍTULO 12 – PADRÕES RECORRENTES E PALAVRAS-CHAVE

12.1 Palavras-chave do enunciado	44	12.3 Afirmações falsas que aparecem como alternativa	45
12.2 Pares que mais se confundem	45		

CAPÍTULO 13 – MAPA DE DOMÍNIOS DO EXAME

13.1 Domínio 1 — Fundamentals of AI and ML (20%)	47	13.4 Domínio 4 — Guidelines for Responsible AI (14%)	48
13.2 Domínio 2 — Fundamentals of GenAI (24%)	47	13.5 Domínio 5 — Security, Compliance, and Governance for AI Solutions (14%)	48
13.3 Domínio 3 — Applications of Foundation Models (28%)	47	13.6 Observação sobre o modelo de pontuação	48

CAPÍTULO 14 – AUTOTESTE – FLASHCARDS DE REVISÃO RÁPIDA

14.1 Fundamentos de IA e ML	49	14.7 Design, RAG e customização	58
14.2 Casos de uso e serviços de IA	50	14.8 Engenharia de prompts	59
14.3 Ciclo de vida e MLOps	52	14.9 Treinamento e avaliação	60
14.4 Fundamentos de IA generativa	54	14.10 IA responsável	62
14.5 IA agêntica	55	14.11 Segurança, conformidade e governança	63
14.6 Serviços de IA generativa	57	14.12 Pegadinhas Duplas (confusões mais recorrentes)	65

CAPÍTULO 15 – MAPA DE COBERTURA DO GUIA OFICIAL E QUESTÕES DE MÚLTIPLA RESPOSTA

15.1 Como resolver múltipla resposta, ordenação e correspondência	66
---	----

Como usar este guia

- Use os capítulos 1 a 11 para revisão de conteúdo. Eles seguem os cinco domínios do exame: fundamentos de IA e ML (capítulos 1 a 3), fundamentos de IA generativa (4 a 6), aplicações de foundation models (7 a 9), IA responsável (10) e segurança e governança (11).
- Use a tabela **Decisão rápida** ao final de cada capítulo (1 a 11) como cheat sheet de véspera de prova: cada uma reúne cenários típicos, a resposta correta e os distratores clássicos daquele tema.
- Use os **Padrões recorrentes e palavras-chave** (seção 12) para treinar a leitura do enunciado. No AI Practitioner, uma expressão como "sem treinar modelo", "dados privados atualizados", "menor custo de customização" ou "filtrar conteúdo nocivo" costuma decidir a questão.
- Use o **Mapa de Domínios** (seção 13) para priorizar a revisão conforme o peso de cada domínio na nota final.
- Use o **Autoteste** (seção 14) para revisão ativa: cada flashcard esconde a resposta até você clicar, forçando recall em vez de releitura passiva.
- Use o **Mapa de cobertura e questões de múltipla resposta** (seção 15) para conferir as 14 tarefas oficiais e praticar os formatos de questão do exame, inclusive **ordenação** e **correspondência**.
- O AI Practitioner cobra **conceitos e escolha de serviço**, não programação nem matemática. Para cada tema, saiba responder: **o que é, quando usar, quanto custa em relação às alternativas e qual risco traz**.

Números, preços e atualizações

Os números, nomes de serviços e datas deste guia foram conferidos na documentação oficial da AWS (docs.aws.amazon.com e aws.amazon.com) em **setembro de 2026**. São uma referência datada: confirme disponibilidade e preços antes de depender de um valor exato.

O ecossistema de IA da AWS mudou muito em 2026, e a maior parte dos cursos e simulados ainda não reflete isso:

- *O guia do exame foi revisado para a versão 1.1 (30/abr/2026). Entraram IA agêntica, **Model Context Protocol (MCP)**, engenharia de contexto, preço por tokens, detecção de alucinação e os serviços **Kiro**, **Strands Agents**, **Amazon Bedrock AgentCore**, **Amazon Quick**, **SageMaker JumpStart** e **AWS Transform**.*
- *Em 30/jul/2026, vários serviços e recursos passaram a **modo de manutenção** (não aceitam novos clientes; quem já usa continua): **Amazon Bedrock Agents** (agora "Agents Classic", substituído pelo AgentCore), **Amazon Kendra**, **Amazon Q Business** e os recursos do SageMaker AI **Clarify**, **Model Monitor**, **Ground Truth**, **Augmented AI (A2I)**, **Debugger** e **Role Manager**.*
- *O **Amazon Q Developer** deixou de aceitar novas assinaturas em 15/mai/2026 e será substituído pelo **Kiro**.*

Esses serviços ainda aparecem em simulados e explicam conceitos cobrados na prova, como detecção de viés, monitoramento de drift e revisão humana. Por isso o guia os ensina, sempre indicando a situação atual.

Método para questões do AI Practitioner

1. **Classifique o problema:** é previsão com dados estruturados (ML tradicional), tarefa pronta de percepção (serviço de IA gerenciado), geração de conteúdo (IA generativa) ou execução de tarefas em várias etapas (agente)?
2. **Prefira o caminho de menor esforço que atende:** serviço de IA pronto → Bedrock com prompt → RAG → fine-tuning → treinar do zero. Só suba um degrau quando o enunciado exigir.

3. **Leia a restrição decisiva:** "dados privados e atualizados" leva a RAG; "tom e formato específicos do domínio" leva a fine-tuning; "sem acesso à internet pública" leva a PrivateLink; "bloquear tópicos" leva a Guardrails; "explicar a decisão ao regulador" leva a modelo interpretável.
4. **Desconfie das alternativas que exageram:** treinar um modelo do zero quase nunca é a resposta de menor custo, e mais dados de treino não resolvem uma pergunta sobre fatos de ontem.
5. **Questões de ordenação e correspondência:** não há crédito parcial. Revise a ordem das etapas do pipeline de ML, do RAG e do ciclo de vida de FMs.

Formato do exame AIF-C01

Item	Valor
Código	AIF-C01 (guia versão 1.1, vigente em setembro de 2026)
Questões	65 no total: 50 pontuadas e 15 não pontuadas (não identificadas)
Duração	90 minutos
Tipos de questão	Múltipla escolha (1 correta entre 4), múltipla resposta (2 ou mais corretas entre 5 ou mais), ordenação (colocar 3 a 5 itens na ordem certa) e correspondência (associar respostas a 3 a 7 enunciados)
Pontuação	Escala de 100 a 1.000; mínimo de 700 para aprovação
Modelo de pontuação	Compensatório: não é preciso passar em cada domínio, só na prova como um todo
Chute	Questão em branco conta como errada e não há penalidade por errar
Público-alvo	Até 6 meses de exposição a IA/ML na AWS; usa , mas não necessariamente constrói , soluções de IA
Fora do escopo	Programar modelos, engenharia de dados e de features, tuning de hiperparâmetros, construir pipelines, análise matemática, implementar protocolos de segurança e frameworks de governança
Valor	US\$ 100 (confira o preço vigente no site de certificação)

Domínios do exame AIF-C01 (pesos oficiais)

Domínio	Peso
Fundamentals of AI and ML (Fundamentos de IA e ML)	20%
Fundamentals of GenAI (Fundamentos de IA generativa)	24%
Applications of Foundation Models (Aplicações de foundation models)	28%
Guidelines for Responsible AI (Diretrizes de IA responsável)	14%
Security, Compliance, and Governance for AI Solutions (Segurança, conformidade e governança)	14%

1. Fundamentos de IA e ML

Regra de ouro da prova: pense em círculos concêntricos. **IA** é o campo amplo; **machine learning** é a parte da IA que aprende padrões com dados; **deep learning** é a parte do ML que usa redes neurais com muitas camadas; **IA generativa** usa deep learning para **criar conteúdo novo**; **IA agêntica** usa modelos generativos para **planejar e executar tarefas** com ferramentas.

Conceitos e terminologia

Termos básicos

Termo	Definição para a prova
Inteligência artificial (IA)	Campo que busca fazer máquinas executarem tarefas que exigiriam inteligência humana: perceber, raciocinar, aprender e decidir
Machine learning (ML)	Subconjunto da IA em que o sistema aprende padrões a partir de dados , sem regras programadas explicitamente
Deep learning	Subconjunto do ML que usa redes neurais com muitas camadas ; é bom com dados não estruturados (imagem, áudio, texto)
Rede neural	Estrutura de nós (neurônios) organizados em camadas que ajustam pesos durante o treinamento
Visão computacional	IA que interpreta imagens e vídeos (detectar objetos, rostos, defeitos)
Processamento de linguagem natural (NLP)	IA que entende e gera linguagem humana (sentimento, tradução, resumo)
Algoritmo	O método de aprendizado (ex.: regressão linear, árvore de decisão, XGBoost)
Modelo	O resultado do treinamento : o algoritmo com os parâmetros aprendidos, pronto para fazer previsões
Treinamento	Processo de ajustar os parâmetros do modelo com dados
Inferência	Usar o modelo treinado para fazer previsões ou gerar saídas com dados novos
Viés (bias)	Erro sistemático que favorece ou prejudica resultados ou grupos. Em ML também significa suposições simplificadoras demais do modelo
Justiça (fairness)	Resultados que não discriminam indevidamente grupos de pessoas
Ajuste (fit)	Quão bem o modelo captura o padrão. Overfitting : ótimo no treino, ruim em dados novos. Underfitting : ruim até no treino
Large language model (LLM)	Modelo de linguagem muito grande, baseado em transformers , treinado em enormes volumes de texto
IA generativa (GenAI)	IA que cria conteúdo novo (texto, imagem, áudio, vídeo, código) a partir de um prompt
IA agêntica (agentic AI)	Sistemas em que modelos planejam, decidem e agem em várias etapas, usando ferramentas e memória, com autonomia (veja a seção 5)

Semelhanças e diferenças entre IA, ML, deep learning, GenAI e IA agêntica

- Todos são **IA**. ML, deep learning e GenAI aprendem com dados; sistemas de regras também são IA, mas não são ML.
- **ML tradicional** costuma trabalhar com **dados estruturados** e produzir uma **previsão** (um número, uma classe).
- **Deep learning** lida bem com **dados não estruturados** e exige mais dados e computação.

- **GenAI** produz **conteúdo novo** e costuma usar **foundation models** pré-treinados, reaproveitáveis para muitas tarefas sem treinar de novo.
- **IA agêntica** não é um tipo novo de modelo: é uma **arquitetura** em que um modelo generativo decide os próximos passos, chama ferramentas e usa memória para cumprir um objetivo.

Tipos de dados e de aprendizado

Tipos de dados em modelos de IA

Tipo	Exemplo
Rotulado (labeled)	Imagens marcadas como "gato" ou "cachorro"; transações marcadas como "fraude"
Não rotulado (unlabeled)	Textos, cliques ou fotos sem marcação
Tabular	Linhas e colunas (planilha, tabela de banco)
Série temporal	Valores ordenados no tempo (vendas por dia, leituras de sensor)
Imagem	Fotos, raios X, imagens de satélite
Texto	E-mails, avaliações, documentos
Estruturado	Formato fixo e previsível (tabelas)
Não estruturado	Sem esquema fixo (texto livre, áudio, vídeo, imagem). A maior parte dos dados das empresas

Tipos de aprendizado

Tipo	Como aprende	Técnicas e exemplos
Supervisionado	Com dados rotulados (entrada → resposta correta conhecida)	Classificação (spam ou não, fraude ou não); regressão (prever preço, demanda)
Não supervisionado	Com dados não rotulados , encontrando estrutura por conta própria	Clustering (segmentar clientes), redução de dimensionalidade, detecção de anomalias
Por reforço (reinforcement learning)	Um agente age em um ambiente e aprende por recompensas e penalidades	Robótica, jogos, otimização de rotas, AWS DeepRacer; RLHF usa feedback humano como recompensa
Autosupervisionado	Cria os próprios rótulos a partir dos dados (ex.: prever a próxima palavra)	Pré-treinamento de LLMs e foundation models
Semissupervisionado	Poucos dados rotulados + muitos não rotulados	Quando rotular tudo é caro

Tipos de inferência

Como o modelo atende às requisições

Tipo	Como funciona	Quando usar	Na AWS
Tempo real (real-time)	Endpoint sempre ativo responde a cada requisição com baixa latência	Recomendações no site, detecção de fraude no pagamento, chatbots	SageMaker AI real-time endpoints; Bedrock on-demand
Serverless	Endpoint sem gerenciar instâncias, que escala até zero; pode ter cold start	Tráfego intermitente ou imprevisível , com tolerância a alguma latência inicial	SageMaker AI Serverless Inference

Tipo	Como funciona	Quando usar	Na AWS
Assíncrona (asynchronous)	Requisição entra em fila ; o resultado é gravado no S3 e notificado depois	Payloads grandes (até 1 GB) e processamento longo (até cerca de 1 hora)	SageMaker AI Asynchronous Inference
Em lote (batch)	Processa um conjunto grande de dados de uma vez , sem endpoint persistente	Pontuar milhões de registros por noite; quando não é preciso resposta imediata	SageMaker AI Batch Transform; Bedrock batch inference (preço menor que on-demand)

Decisão rápida — Fundamentos de IA e ML

Cenário / requisito	Resposta correta	Distratores clássicos
Prever o preço de um imóvel	Aprendizado supervisionado — regressão	Classificação, clustering
Classificar e-mails como spam	Aprendizado supervisionado — classificação	Regressão, clustering
Segmentar clientes sem rótulos	Não supervisionado — clustering	Classificação
Robô que aprende por tentativa e erro com recompensas	Aprendizado por reforço	Supervisionado
Ajustar um LLM com preferências humanas	RLHF	Clustering, pré-treinamento
Modelo ótimo no treino e ruim em dados novos	Overfitting	Underfitting
Modelo ruim até nos dados de treino	Underfitting	Overfitting
Resposta imediata a cada transação	Inferência em tempo real	Batch
Pontuar milhões de registros uma vez por noite	Inferência em lote	Tempo real
Tráfego intermitente sem gerenciar instâncias	Inferência serverless	Endpoint real-time sempre ativo
Payload de 500 MB e processamento de 20 minutos	Inferência assíncrona	Tempo real, serverless
Sistema que planeja e usa ferramentas em várias etapas	IA agêntica	ML tradicional

2. Casos de Uso e Serviços de IA

Regra de ouro da prova: antes de escolher o modelo, pergunte se **IA é mesmo necessária**. Se o resultado precisa ser **exato e determinístico** (calcular imposto, aplicar uma regra fixa), use regras ou código. Se é uma tarefa comum de percepção ou linguagem, use um **serviço de IA pronto** antes de treinar qualquer coisa.

Quando a IA agrega valor

Onde IA/ML ajuda

- **Apoiar decisões humanas:** priorizar leads, sugerir diagnóstico para revisão médica, sinalizar transações suspeitas.
- **Escalar soluções:** analisar milhões de documentos, imagens ou chamadas que humanos não conseguiriam revisar.
- **Automatizar** tarefas repetitivas: extrair dados de formulários, transcrever, traduzir, classificar tickets.
- **Encontrar padrões** complexos demais para regras escritas à mão.

Quando IA/ML não é apropriada

- **O custo supera o benefício:** pouco volume, ganho pequeno ou custo alto de dados, treinamento e operação.
- **É preciso um resultado específico, não uma previsão:** regras de negócio fixas, cálculos exatos, conformidade que exige a mesma saída sempre.
- **Faltam dados** suficientes, representativos ou de qualidade.
- **Explicabilidade total é exigida** e o modelo disponível é uma "caixa-preta".
- **O erro é inaceitável** e não há revisão humana.

Escolhendo a técnica de ML

Técnica	Saída	Exemplos
Regressão	Um número contínuo	Prever vendas, preço, tempo de entrega, consumo de energia
Classificação	Uma categoria (binária ou múltipla)	Fraude sim/não, sentimento positivo/negativo, tipo de defeito
Clustering	Grupos de itens parecidos, sem rótulos	Segmentação de clientes, agrupar documentos
Detecção de anomalias	Itens fora do padrão	Fraude, falha de equipamento, intrusão
Previsão de séries temporais (forecasting)	Valores futuros ao longo do tempo	Demanda do próximo mês, capacidade
Recomendação	Itens relevantes para cada usuário	"Quem comprou isto também comprou"

Aplicações reais e serviços gerenciados

Exemplos de aplicações de IA

Aplicação	Exemplo	Serviço AWS típico
Visão computacional	Moderar imagens, reconhecer rostos, contar pessoas	Amazon Rekognition
Extração de documentos	Ler notas fiscais, formulários, tabelas	Amazon Textract, Bedrock Data Automation
NLP	Sentimento de avaliações, entidades, PII em texto	Amazon Comprehend
Reconhecimento de fala	Transcrever chamadas e reuniões	Amazon Transcribe
Síntese de fala	Ler textos em voz alta	Amazon Polly
Tradução	Traduzir conteúdo	Amazon Translate
Chatbots	Atendimento por voz e texto	Amazon Lex, Amazon Bedrock
Sistemas de recomendação	Recomendações personalizadas	Amazon Personalize
Deteção de fraude	Transações suspeitas	Modelos no SageMaker AI
Previsão (forecasting)	Demanda e estoque	SageMaker AI (Canvas, algoritmos de séries temporais)
Bases de conhecimento	Responder perguntas com documentos da empresa	Amazon Bedrock Knowledge Bases
IA agêntica	Assistente que consulta sistemas e executa tarefas	Amazon Bedrock AgentCore, Amazon Quick

Serviços de IA gerenciados (sem treinar modelo)

Serviço	O que faz	Palavra-chave
Amazon Rekognition	Análise de imagens e vídeos: objetos, cenas, texto, rostos (comparação e busca), moderação de conteúdo , rótulos personalizados	"Detectar rostos", "conteúdo impróprio em imagens"
Amazon Textract	Extrai texto , formulários (pares chave-valor) e tabelas de documentos digitalizados; vai além do OCR simples	"Extrair dados de formulários escaneados"
Amazon Comprehend	NLP : sentimento, entidades, frases-chave, idioma, tópicos, deteção de PII , classificação personalizada. Comprehend Medical para textos clínicos	"Sentimento de avaliações", "entidades em documentos"
Amazon Transcribe	Fala para texto , com identificação de locutores, vocabulário personalizado e redação de PII. Call Analytics e Transcribe Medical	"Transcrever chamadas", "legendas"
Amazon Polly	Texto para fala com vozes naturais (neurais) e SSML	"Converter texto em áudio"
Amazon Translate	Tradução automática neural , com terminologia personalizada	"Traduzir conteúdo em tempo real"
Amazon Lex	Chatbots de voz e texto com reconhecimento de intenção (mesma tecnologia da Alexa); integra-se ao Amazon Connect	"Criar bot conversacional para atendimento"
Amazon Personalize	Recomendações personalizadas em tempo real, com a tecnologia usada na Amazon.com	"Recomendar produtos a cada usuário"
Amazon SageMaker AI	Plataforma para construir, treinar e implantar modelos próprios (seção 3)	"Modelo personalizado com dados próprios"

- *Material antigo cita **Amazon Kendra** (busca corporativa inteligente), **Amazon Forecast**, **Amazon Fraud Detector** e a família **Amazon Lookout**. O Kendra entrou em modo de manutenção em 30/jul/2026, e a recomendação atual para busca e perguntas sobre documentos é **Amazon Bedrock Knowledge Bases**. Os demais também deixaram de aceitar novos clientes ou tiveram o suporte encerrado; confira a disponibilidade antes de escolher.*

ML tradicional ou foundation model

Como decidir

Critério	ML tradicional tende a ser melhor	Foundation model tende a ser melhor
Tipo de tarefa	Previsão específica com dados estruturados (churn, preço, fraude)	Linguagem, conteúdo, conversas, tarefas abertas e variadas
Regulação e explicabilidade	Exigência de explicar cada decisão (crédito, seguros): modelos interpretáveis	Quando a explicação detalhada de cada saída não é exigida
Restrições operacionais	Latência muito baixa, custo por previsão mínimo, execução em dispositivo	Quando é aceitável custo por token e latência maiores
Dados	Muitos dados rotulados do próprio negócio	Poucos dados rotulados; o FM já traz conhecimento geral
Determinismo	Mesma entrada, mesma saída	Saídas variáveis (não determinísticas) são aceitáveis
Tempo de entrega	Projeto de ML com treinamento	Protótipo rápido com prompt, sem treinar

Decisão rápida — Casos de uso e serviços

Cenário / requisito	Resposta correta	Distratores clássicos
Cálculo que precisa dar sempre o mesmo resultado exato	Regras/código, não ML	Modelo de ML, LLM
Prever a demanda do próximo mês	Regressão / forecasting	Clustering
Agrupar clientes por comportamento	Clustering	Classificação
Detectar rostos e conteúdo impróprio em fotos	Amazon Rekognition	Textract, Comprehend
Extrair tabelas de PDFs digitalizados	Amazon Textract	Rekognition, Comprehend
Sentimento e PII em avaliações	Amazon Comprehend	Translate, Textract
Transcrever chamadas do call center	Amazon Transcribe	Polly
Gerar áudio a partir de texto	Amazon Polly	Transcribe
Traduzir o site	Amazon Translate	Comprehend
Chatbot com intenções para atendimento	Amazon Lex	Polly, Rekognition
Recomendações personalizadas	Amazon Personalize	Comprehend
Modelo próprio com dados da empresa	Amazon SageMaker AI	Serviços de IA prontos
Decisão de crédito que precisa ser explicada ao regulador	Modelo de ML tradicional interpretável	LLM de propósito geral
Perguntas sobre documentos internos (busca atual)	Bedrock Knowledge Bases	Kendra para novos clientes

3. Ciclo de Vida de IA/ML e MLOps

Regra de ouro da prova: a ordem do pipeline cai em questões de **ordenação**. Decore: **objetivo de negócio** → **enquadrar o problema de ML** → **coletar dados** → **explorar (EDA)** → **pré-processar** → **engenharia de features** → **treinar** → **ajustar hiperparâmetros** → **avaliar** → **implantar** → **monitorar** (e retreinar).

Pipeline de IA/ML

Etapas e o que acontece em cada uma

Etapa	O que acontece	Serviços AWS
1. Objetivo de negócio	Definir o problema, a métrica de sucesso e o valor esperado	—
2. Enquadrar o problema de ML	Traduzir em tarefa de ML (classificação, regressão...) e verificar se ML é adequado	—
3. Coleta de dados	Reunir dados de várias fontes e rotulá-los quando preciso	S3, AWS Glue, AWS Data Exchange, SageMaker Ground Truth (rotulagem)
4. Análise exploratória (EDA)	Entender distribuições, correlações, valores faltantes e desbalanceamento	SageMaker Data Wrangler, SageMaker Canvas, Athena, Amazon Quick
5. Pré-processamento	Limpar, tratar faltantes, remover duplicatas, normalizar, dividir em treino/validação/teste	AWS Glue, Glue DataBrew, Data Wrangler
6. Engenharia de features	Criar e selecionar as variáveis que o modelo usa	Data Wrangler, SageMaker Feature Store (guarda e compartilha features)
7. Treinamento	Ajustar os parâmetros do modelo com os dados de treino	SageMaker AI Training, JumpStart, Autopilot/Canvas
8. Ajuste de hiperparâmetros	Buscar a melhor configuração (taxa de aprendizado, profundidade...)	SageMaker Automatic Model Tuning
9. Avaliação	Medir desempenho em dados que o modelo não viu (métricas da seção 3)	SageMaker AI, SageMaker Clarify (viés), Bedrock Model Evaluation
10. Implantação	Colocar o modelo em produção (endpoint, batch)	SageMaker AI endpoints, SageMaker Model Registry
11. Monitoramento	Acompanhar qualidade, drift de dados e de conceito, viés e custo; retreinar quando necessário	SageMaker Model Monitor, CloudWatch

- **Hiperparâmetro vs. parâmetro:** **parâmetros** (pesos) são aprendidos no treinamento; **hiperparâmetros** são escolhidos **antes** do treinamento (ex.: número de épocas, taxa de aprendizado).
- **Divisão dos dados:** **treino** ensina o modelo, **validação** ajusta hiperparâmetros e **teste** mede o desempenho final em dados nunca vistos.

Serviços e recursos por etapa

Serviço ou recurso	Papel no ciclo de vida
Amazon SageMaker AI	Plataforma completa para construir, treinar, implantar e gerenciar modelos (antigo Amazon SageMaker)
SageMaker Studio	Ambiente de desenvolvimento web para todo o ciclo de ML

Serviço ou recurso	Papel no ciclo de vida
SageMaker Canvas	ML sem código para analistas de negócio (previsões por interface visual)
SageMaker JumpStart	Hub de modelos pré-treinados e foundation models para implantar e ajustar com poucos cliques
SageMaker Data Wrangler	Preparação visual de dados e engenharia de features
SageMaker Feature Store	Repositório central de features para treino e inferência
SageMaker Pipelines	Automatiza fluxos de ML (CI/CD de ML)
SageMaker Model Registry	Catálogo de versões de modelos com aprovação para produção
SageMaker Model Cards	Documentação do modelo: uso pretendido, dados, métricas, riscos (governança)
SageMaker Clarify	Deteção de viés e explicabilidade (importância das features). <i>Em manutenção desde 30/jul/2026</i>
SageMaker Model Monitor	Monitoramento de drift e qualidade em produção. <i>Em manutenção desde 30/jul/2026</i>
SageMaker Ground Truth	Rotulagem de dados com humanos e automação. <i>Em manutenção desde 30/jul/2026</i>
Amazon Augmented AI (A2I)	Revisão humana de previsões de baixa confiança. <i>Em manutenção desde 30/jul/2026</i>
Amazon Bedrock	Foundation models por API, com customização, avaliação e guardrails (seção 6)
Amazon Quick	Espaço de trabalho de IA para usuários de negócio: BI (Quick Sight), pesquisa, fluxos e agentes
Kiro	Ambiente de desenvolvimento agêntico para criar aplicações de IA (seção 5)
AWS Glue, Glue DataBrew, Lake Formation, Data Exchange	Preparar, catalogar, governar e obter dados

Fontes de modelos e uso em produção

De onde vêm os modelos

- **Modelos pré-treinados de código aberto** (open-weight): Llama, Mistral e outros, disponíveis no Bedrock, no SageMaker JumpStart ou em repositórios públicos. Você pode usá-los como estão ou ajustá-los.
- **Modelos proprietários via API**: Amazon Nova, Anthropic Claude e outros, acessados pelo Amazon Bedrock.
- **Treinar um modelo próprio**: com seus dados no SageMaker AI. Dá controle total, mas exige dados, tempo e custo. Treinar um foundation model do zero é o caminho mais caro de todos.

Formas de usar um modelo em produção

- **Serviço de API gerenciado** (ex.: **Amazon Bedrock**): sem infraestrutura para gerenciar, cobrança por uso (tokens), escala automática. Menor esforço operacional.
- **API auto-hospedada** (ex.: modelo em **endpoint do SageMaker AI**, EC2, ECS ou EKS): mais controle sobre o modelo, a versão e a infraestrutura, mas o cliente gerencia capacidade, escala e custo das instâncias.

MLOps

Conceitos fundamentais

- **MLOps** aplica práticas de DevOps ao ciclo de vida de ML para colocar e manter modelos em produção de forma confiável.

- **Experimentação:** registrar experimentos, parâmetros e resultados para comparar versões.
- **Processos repetíveis:** pipelines automatizados de dados, treino e implantação (SageMaker Pipelines).
- **Sistemas escaláveis:** treino e inferência que crescem com a demanda.
- **Gerenciar dívida técnica:** evitar código e dados ad hoc que tornam o sistema frágil.
- **Prontidão para produção:** versionamento (Model Registry), testes, aprovação, rollback.
- **Monitoramento do modelo:** o desempenho **degrada com o tempo**. **Data drift** é a mudança na distribuição dos dados de entrada; **concept drift** é a mudança na relação entre entrada e resultado.
- **Retreinamento:** agendado ou disparado quando o monitoramento detecta queda de qualidade.

Métricas de avaliação

Métricas de desempenho de classificação

Base: a **matriz de confusão**, com verdadeiros positivos (VP), falsos positivos (FP), verdadeiros negativos (VN) e falsos negativos (FN).

Métrica	O que mede	Quando priorizar
Acurácia (accuracy)	Proporção de acertos no total	Classes balanceadas . Engana com dados desbalanceados (99% de "não fraude" dá 99% de acurácia a um modelo inútil)
Precisão (precision)	Dos que o modelo disse "positivo", quantos eram mesmo: $VP / (VP + FP)$	Quando falso positivo é caro (bloquear um cliente bom, marcar e-mail legítimo como spam)
Recall (sensibilidade)	Dos positivos reais, quantos o modelo encontrou: $VP / (VP + FN)$	Quando falso negativo é caro (não detectar fraude ou doença)
F1 score	Média harmônica de precisão e recall	Equilibrar as duas, especialmente com classes desbalanceadas
AUC-ROC	Capacidade de separar as classes em todos os limiares (0,5 = aleatório; 1 = perfeito)	Comparar classificadores binários

- **Regressão** usa métricas de erro: **MAE** (erro absoluto médio), **RMSE** (raiz do erro quadrático médio) e **R²** (quanto da variação o modelo explica).

Métricas de negócio

- **Custo por usuário** ou por previsão, **custos de desenvolvimento**, **feedback dos clientes**, **retorno sobre o investimento (ROI)**.
- Um modelo tecnicamente ótimo que não melhora a métrica de negócio não entrega valor. As métricas de negócio são definidas na **primeira etapa** do pipeline.

Decisão rápida — Ciclo de vida e MLOps

Cenário / requisito	Resposta correta	Distratores clássicos
Primeira etapa do pipeline de ML	Definir o objetivo de negócio	Coletar dados, treinar
Entender distribuições e valores faltantes	Análise exploratória (EDA)	Treinamento
Criar variáveis a partir dos dados	Engenharia de features	Ajuste de hiperparâmetros
Escolher a melhor taxa de aprendizado	Ajuste de hiperparâmetros	Engenharia de features

Cenário / requisito	Resposta correta	Distratores clássicos
Dados de produção mudaram e o modelo piorou	Data drift → monitorar e retreinar	Aumentar a instância
Rotular milhares de imagens	Ground Truth (em manutenção) ou rotulagem própria	Rekognition, Comprehend
ML sem código para analistas	SageMaker Canvas	SageMaker Studio, EMR
Implantar modelo pré-treinado com poucos cliques	SageMaker JumpStart	Treinar do zero
Documentar uso pretendido e riscos do modelo	SageMaker Model Cards	CloudTrail, Model Registry
Versionar e aprovar modelos para produção	SageMaker Model Registry	Feature Store
Automatizar o fluxo de treino e implantação	SageMaker Pipelines	Step Functions genérico
Falso negativo é o erro mais caro (fraude, doença)	Priorizar recall	Acurácia, precisão
Falso positivo é o erro mais caro	Priorizar precisão	Recall
Equilibrar precisão e recall com classes desbalanceadas	F1 score	Acurácia
Menor esforço operacional para usar um modelo	API gerenciada (Bedrock)	Endpoint auto-hospedado

4. Fundamentos de IA Generativa

Regra de ouro da prova: um **foundation model (FM)** é um modelo grande, pré-treinado em dados amplos e **reaproveitável** para muitas tarefas. Você o adapta com **prompt**, **contexto (RAG)** ou **fine-tuning**, e paga por **tokens**. Suas fraquezas clássicas são **alucinação**, **não determinismo** e **baixa interpretabilidade**.

Conceitos básicos de IA generativa

Termos fundamentais

Termo	Definição para a prova
Token	Unidade de texto processada pelo modelo (uma palavra, parte de palavra ou pontuação). Limites de contexto e preço são medidos em tokens
Chunking	Dividir documentos em pedaços menores antes de gerar embeddings, para caber no contexto e melhorar a busca (RAG)
Embedding	Representação numérica (vetor) do significado de um texto, imagem ou áudio. Conteúdos parecidos geram vetores próximos
Vetor	Lista de números que representa o embedding; bancos vetoriais fazem busca por similaridade entre vetores
Engenharia de prompt	Projetar as instruções e o contexto enviados ao modelo para obter a melhor resposta (seção 8)
Transformer	Arquitetura de rede neural com mecanismo de atenção (self-attention), base dos LLMs modernos; processa sequências em paralelo
Large language model (LLM)	FM de linguagem baseado em transformers, treinado para prever o próximo token
Foundation model (FM)	Modelo grande pré-treinado em dados amplos, adaptável a muitas tarefas sem treinar do zero
Modelo multimodal	Aceita e/ou gera mais de um tipo de dado (texto, imagem, áudio, vídeo)
Modelo de difusão	Gera imagens (ou vídeo e áudio) partindo de ruído e removendo-o passo a passo até formar o conteúdo pedido
Janela de contexto	Quantidade máxima de tokens (entrada + saída) que o modelo considera de uma vez
Alucinação	Resposta plausível, mas falsa ou sem base nos dados

Casos de uso de IA generativa

- **Geração de imagem, vídeo e áudio:** marketing, protótipos visuais, narração.
- **Resumo** de documentos, reuniões e chamadas.
- **Assistentes de IA** e **agentes de atendimento ao cliente**.
- **Tradução** e adaptação de conteúdo.
- **Geração de código** e documentação.
- **Busca** semântica e perguntas e respostas sobre documentos.
- **Mecanismos de recomendação** e personalização de conteúdo.

Ciclo de vida de um foundation model

1. **Seleção de dados:** reunir e curar dados amplos e de qualidade.
2. **Seleção do modelo:** arquitetura e tamanho (ou escolher um FM pronto).

3. **Pré-treinamento:** treinamento autossupervisionado em grande escala.
4. **Fine-tuning:** especializar para tarefas ou domínios.
5. **Avaliação:** benchmarks, métricas e avaliação humana.
6. **Implantação:** disponibilizar para inferência.
7. **Feedback:** coletar retorno de uso para melhorar o modelo (inclusive RLHF).

Tokens, custo e contexto

Preço baseado em tokens

- A maioria dos FMs no Amazon Bedrock é cobrada **por token de entrada e por token de saída**, com preços diferentes para cada um. Tokens de **saída** costumam ser **mais caros** que os de entrada.
- **Efeito no custo:** prompts longos, muitos documentos no contexto, históricos de conversa extensos e respostas longas aumentam a conta. Um modelo maior custa mais por token.
- **Efeito no desempenho:** mais tokens significam **mais latência**, porque o modelo processa a entrada e gera a saída token a token.
- **Como reduzir:** escolher o **menor modelo que atende**, limitar o tamanho máximo de saída, enviar só o contexto relevante (bom chunking e recuperação), usar **cache de prompt** (prompt caching) para prefixos repetidos e **inferência em lote** quando não há urgência.

Engenharia de contexto

- É a disciplina de **decidir e montar o que entra na janela de contexto** do modelo a cada chamada: instruções do sistema, histórico relevante, documentos recuperados, resultados de ferramentas, memória e exemplos.
- Vai além da engenharia de prompt: trata o contexto como um **recurso limitado e caro**. Contexto demais aumenta custo e latência e pode "diluir" a informação importante; contexto de menos causa alucinação.
- **Técnicas:** recuperar só os trechos relevantes (RAG), resumir históricos longos, guardar fatos em **memória** de longo prazo e trazê-los quando necessário, estruturar a saída de ferramentas e remover informação obsoleta.
- É central em **agentes**, que acumulam muitas interações e resultados de ferramentas ao longo de uma tarefa.

Capacidades e limitações

Vantagens da IA generativa

- **Adaptabilidade:** um mesmo modelo resolve muitas tarefas diferentes.
- **Responsividade:** respostas rápidas em linguagem natural.
- **Capacidade conversacional:** interações de várias rodadas.
- **Capacidade de gerar conteúdo** novo (texto, imagem, código, áudio).
- **Simplicidade:** menos necessidade de dados rotulados e de treinamento específico.

Desvantagens e limitações

Limitação	O que é	Mitigação
Alucinação	Inventa fatos com confiança	RAG com citações, contextual grounding check, validação da saída

Limitação	O que é	Mitigação
Interpretabilidade	Difícil explicar por que o modelo respondeu algo	Modelos mais simples quando a explicação é exigida; documentação; avaliação
Imprecisão	Erros factuais, cálculos errados, conhecimento desatualizado (data de corte)	RAG com dados atuais, ferramentas (agentes) para cálculos e consultas
Não determinismo	A mesma entrada pode gerar respostas diferentes	Temperatura baixa, prompts e formatos de saída estruturados
Viés e toxicidade	Reproduz vieses dos dados de treino	Guardrails, avaliação, dados diversos
Custo e latência	Tokens e modelos grandes custam e demoram	Modelo menor, cache, batch, destilação

Seleção de modelos de IA generativa

Fatores do guia do exame: **tipo de modelo** (texto, imagem, multimodal, embeddings), **requisitos de desempenho, capacidades, restrições, conformidade, custo, latência e complexidade do modelo**. O capítulo 7 detalha os critérios de seleção.

Valor de negócio e métricas

- **Desempenho entre domínios** (cross-domain performance), **ROI, eficiência** (tempo economizado, tarefas automatizadas), **taxa de conversão, receita média por usuário (ARPU), precisão e valor do tempo de vida do cliente (CLV)**.
- Métricas de alinhamento com o negócio em aplicações de IA: **taxa de conclusão de tarefas, satisfação do usuário e custo por interação** (seção 9).

Decisão rápida — Fundamentos de IA generativa

Cenário / requisito	Resposta correta	Distratores clássicos
Unidade usada para medir contexto e preço	Token	Caractere, palavra
Representação numérica do significado de um texto	Embedding	Token, chunk
Dividir documentos antes de indexar	Chunking	Tokenização, fine-tuning
Arquitetura base dos LLMs	Transformer	Modelo de difusão
Gerar imagens partindo de ruído	Modelo de difusão	Transformer de texto
Modelo que entende texto e imagem	Multimodal	Embeddings de texto
Resposta plausível mas falsa	Alucinação	Overfitting
Mesma pergunta, respostas diferentes	Não determinismo	Alucinação
Reduzir custo de prompts que repetem o mesmo prefixo	Prompt caching	Modelo maior
Decidir o que entra na janela de contexto a cada chamada	Engenharia de contexto	Fine-tuning
Etapa do ciclo do FM que especializa o modelo	Fine-tuning	Pré-treinamento

5. IA Agêntica e Agentes

Regra de ouro da prova: um **agente** combina um **modelo** (raciocínio), **ferramentas** (agir no mundo), **memória** (lembrar) e um **loop de orquestração** (planejar → agir → observar → repetir) para cumprir um objetivo com autonomia. **MCP** padroniza como agentes se conectam a ferramentas e dados. Na AWS, o SDK é o **Strands Agents** e a plataforma de execução é o **Amazon Bedrock AgentCore**.

Conceitos fundamentais de IA agêntica

O que compõe um agente

Componente	Papel
Modelo (FM)	Raciocina, planeja e decide o próximo passo
Instruções	Objetivo, papel e limites do agente (system prompt)
Ferramentas (tool use / function calling)	Funções que o agente pode chamar: APIs, bancos de dados, busca, execução de código, navegador
Memória	Curto prazo: contexto da conversa ou tarefa atual. Longo prazo: fatos e preferências que persistem entre sessões
Orquestração do fluxo	O loop que decide a ordem das ações, trata erros, pede confirmação e sabe quando parar

- **Diferença para um chatbot:** o chatbot responde; o agente **executa** tarefas de várias etapas (consultar um pedido, abrir um chamado, reagendar uma entrega), decidindo quais ferramentas usar.
- **Humano no loop:** agentes que executam ações sensíveis devem pedir **aprovação humana** antes de agir (ex.: estornar um pagamento).

Model Context Protocol (MCP)

- **Protocolo aberto** que padroniza como aplicações de IA e agentes se conectam a **ferramentas, dados e sistemas externos**.
- Arquitetura **cliente-servidor**: o agente (cliente MCP) descobre e chama as ferramentas expostas por um **servidor MCP** (ex.: um servidor que expõe o sistema de tickets, o banco de dados ou uma API interna).
- **Benefício:** escrever a integração **uma vez** e reutilizá-la em vários agentes e modelos, em vez de criar um conector próprio para cada combinação. Costuma ser comparado a uma "porta USB-C" para IA.
- Na AWS, o **AgentCore Gateway** transforma APIs, funções Lambda e serviços existentes em **ferramentas compatíveis com MCP**.
- **Agent-to-Agent (A2A)** é outro protocolo aberto, voltado à **comunicação entre agentes**; MCP conecta agente a ferramenta.

Padrões de sistemas multiagente

Padrão	Como funciona	Quando usar
Supervisor / orquestrador	Um agente central divide a tarefa e delega a agentes especialistas, depois consolida	Tarefas complexas com partes bem definidas

Padrão	Como funciona	Quando usar
Agentes como ferramentas (agents-as-tools)	Um agente chama outros agentes como se fossem ferramentas	Reaproveitar especialistas de forma simples
Swarm (enxame)	Agentes colaboram de forma autônoma, passando o controle entre si	Problemas exploratórios que se beneficiam de várias perspectivas
Grafo / workflow	Agentes em um fluxo com ordem e condições definidas	Processos previsíveis e auditáveis

- **Padrões de comunicação:** hierárquica (supervisor), ponto a ponto, memória ou estado compartilhado e troca de mensagens (A2A).
- **Riscos:** mais agentes significam mais custo (tokens), mais latência e mais pontos de falha. Use multiagente só quando um agente não resolve bem.

Aplicações de negócio de agentes

- **Atendimento ao cliente** que consulta pedidos, altera cadastros e abre chamados.
- **Operações de TI:** investigar incidentes, consultar logs e sugerir correções.
- **Assistentes de pesquisa** que buscam, leem e sintetizam várias fontes.
- **Automação de processos:** aprovações, conciliações e preenchimento de sistemas.
- **Desenvolvimento de software:** planejar, escrever, testar e revisar código (Kiro).
- **Modernização e migração** de aplicações legadas (AWS Transform).

Serviços AWS para agentes

Amazon Bedrock AgentCore

Plataforma agêntica para **construir, implantar e operar agentes com segurança e em escala**, com **qualquer framework** (Strands Agents, LangGraph, CrewAI, LlamaIndex e outros) e **qualquer modelo**, dentro ou fora do Bedrock, **sem gerenciar infraestrutura**. Os serviços funcionam juntos ou separados:

Componente	Função
Runtime	Ambiente serverless e seguro para executar agentes e ferramentas, com isolamento de sessão e suporte a tarefas longas
Harness	Loop de agente gerenciado : declare modelo, prompt e ferramentas e invoque com uma chamada de API. É o substituto recomendado do Bedrock Agents Classic
Memory	Memória de curto prazo (conversa) e longo prazo (persistente entre sessões)
Gateway	Converte APIs, funções Lambda e serviços em ferramentas MCP e conecta servidores MCP existentes
Identity	Identidade, acesso e autenticação do agente , compatível com provedores existentes (Cognito, Okta, Entra ID)
Policy	Regras determinísticas que limitam quais ferramentas e ações o agente pode usar e em quais condições; intercepta cada chamada de ferramenta no Gateway
Code Interpreter	Sandbox isolado para o agente executar código
Browser	Navegador na nuvem para o agente interagir com sites
Observability	Rastreamento e depuração de cada passo do agente (compatível com OpenTelemetry, integrado ao CloudWatch)
Evaluations	Avaliação automatizada da qualidade do agente e das ferramentas

- **Cobrança por consumo**, sem compromisso inicial.

Strands Agents, Kiro e outros serviços agênticos

Serviço	O que é	Quando é a resposta
Strands Agents	SDK open source (Apache 2.0) da AWS, em Python e TypeScript, para construir agentes com abordagem orientada ao modelo: você define um prompt e uma lista de ferramentas, e o modelo planeja e chama as ferramentas. Suporta MCP, A2A, padrões multiagente, memória e qualquer provedor de modelo	"Framework/SDK para escrever agentes em código"
Kiro	Plataforma de desenvolvimento agêntico da AWS (IDE, CLI e outras interfaces) com desenvolvimento orientado a especificações (spec-driven): transforma o pedido em requisitos, design e tarefas antes de gerar código. Tem steering files, agent hooks e suporte a MCP. Substitui o Amazon Q Developer	"Assistente de IA para desenvolver software", "IDE agêntica"
Amazon Quick	Espaço de trabalho de IA agêntica para usuários de negócio: chat, pesquisa, Quick Sight (BI), fluxos (Quick Flows), automação e agentes conectados a dados e aplicações da empresa. Sucessor do Amazon Q Business e do QuickSight	"Funcionários perguntando e automatizando tarefas com dados da empresa", "dashboards com IA"
AWS Transform	Serviço de IA agêntica para migração e modernização: VMware, mainframe, .NET/Windows, upgrades de Java e redução de dívida técnica	"Modernizar aplicações legadas com agentes de IA"
Amazon Nova Act	Serviço para criar agentes que automatizam fluxos em interfaces web (navegador)	"Agente que opera um site como um usuário"
Amazon Bedrock Agents (Classic)	Agentes gerenciados do Bedrock com action groups e Knowledge Bases. Em manutenção desde 30/jul/2026; novas contas devem usar o AgentCore	Aparece em simulados antigos como resposta para "agentes que executam tarefas em várias etapas"

Decisão rápida — IA agêntica

Cenário / requisito	Resposta correta	Distratores clássicos
Assistente que consulta sistemas e executa tarefas em várias etapas	Agente de IA	Chatbot simples, modelo de classificação
Padrão aberto para conectar agentes a ferramentas e dados	Model Context Protocol (MCP)	A2A, REST genérico
Padrão aberto de comunicação entre agentes	Agent-to-Agent (A2A)	MCP
Executar agentes em produção sem gerenciar infraestrutura	Amazon Bedrock AgentCore (Runtime)	EC2, Bedrock Agents Classic para novos clientes
Transformar APIs e funções Lambda em ferramentas MCP	AgentCore Gateway	API Gateway sozinho
Memória do agente entre sessões	AgentCore Memory	S3 genérico, cache
Limitar deterministicamente as ações do agente	Policy in AgentCore	Prompt pedindo para não fazer
Identidade e autenticação do agente	AgentCore Identity	Chave fixa no código
Agente que executa código com segurança	AgentCore Code Interpreter	Lambda sem isolamento
Rastrear cada passo do agente	AgentCore Observability	CloudTrail sozinho
SDK open source para escrever agentes em Python/TypeScript	Strands Agents	SageMaker Pipelines
IDE agêntica com desenvolvimento orientado a especificações	Kiro	Amazon Q Business, CodeBuild
Agentes e BI para usuários de negócio	Amazon Quick	SageMaker Canvas
Modernizar mainframe e .NET com agentes	AWS Transform	Application Migration Service
Supervisor que delega a especialistas	Padrão multiagente supervisor	Swarm

6. Serviços AWS para IA Generativa

Regra de ouro da prova: Amazon Bedrock é a resposta para "usar foundation models de vários provedores por API, sem gerenciar infraestrutura", com Knowledge Bases (RAG), Guardrails, avaliação e customização. **SageMaker AI / JumpStart** é a resposta quando se quer **mais controle** para implantar, ajustar ou treinar modelos na própria infraestrutura gerenciada.

Amazon Bedrock

O que é e o que oferece

- Serviço **totalmente gerenciado e serverless** que dá acesso, por **uma única API**, a foundation models de vários provedores: **Amazon Nova**, Anthropic (Claude), Meta (Llama), Mistral, Cohere, AI21, Stability AI, DeepSeek, OpenAI (modelos open-weight) e outros.
- Privacidade**: seus prompts e dados **não são usados para treinar os modelos base** nem compartilhados com os provedores dos modelos. Os dados ficam na Região escolhida, criptografados em trânsito e em repouso (com chaves do KMS), e o acesso pode ser privado via **AWS PrivateLink**.

Recurso do Bedrock	Para que serve
Playgrounds	Testar modelos e prompts no console
Knowledge Bases	RAG gerenciado : ingere documentos (S3 e outras fontes), faz chunking, gera embeddings, guarda em banco vetorial e recupera trechos com citações
Guardrails	Filtros de conteúdo, tópicos negados, filtros de palavras, PII , verificação de fundamentação (grounding) e verificações de raciocínio automatizado (seção 10)
Model Evaluation	Avaliar e comparar modelos e aplicações RAG com métricas automáticas, LLM como juiz ou avaliadores humanos
Prompt Management	Criar, versionar , testar e reutilizar prompts (seção 8)
Flows	Encadear prompts, modelos, Knowledge Bases e funções em fluxos visuais
Data Automation	Extrair insights de documentos, imagens, áudio e vídeo não estruturados com IA generativa
Customização de modelos	Fine-tuning, continued pre-training, destilação e importação de modelos customizados
Batch inference	Processar grandes volumes de forma assíncrona com preço menor que o on-demand
Cross-Region inference	Distribuir requisições entre Regiões para mais capacidade e resiliência
Prompt caching e Intelligent Prompt Routing	Reduzir custo e latência com cache de prefixos e roteamento entre modelos de uma família conforme a complexidade
Bedrock Marketplace	Descobrir e implantar modelos adicionais especializados

Família Amazon Nova

Modelo	Tipo	Uso
Nova Micro	Compreensão, só texto	Menor latência e custo
Nova Lite	Compreensão multimodal (texto, imagem, vídeo)	Muito baixo custo e rápido

Modelo	Tipo	Uso
Nova Pro	Compreensão multimodal	Melhor equilíbrio entre precisão, velocidade e custo
Nova Premier	Compreensão multimodal	Mais capaz, tarefas complexas; também serve de "professor" na destilação
Nova Canvas	Criativo	Geração e edição de imagens
Nova Reel	Criativo	Geração de vídeos
Nova Sonic	Fala	Conversa fala para fala em tempo real
Nova 2 (Lite, Sonic e outros)	Nova geração	Raciocínio e fala com melhor custo-benefício

- Também existem **Amazon Nova Act** (agentes de navegador) e **Amazon Nova Forge** (criar modelos próprios a partir do Nova). **Amazon Titan Embeddings** e **Nova Multimodal Embeddings** geram embeddings para RAG.

SageMaker AI, JumpStart e outros serviços

Amazon SageMaker AI e SageMaker JumpStart

- **SageMaker JumpStart**: hub de **centenas de modelos pré-treinados e FMs** (inclusive open-weight) para **implantar em endpoints do SageMaker AI** e **ajustar** com seus dados, com poucos cliques. Você escolhe a instância e controla a infraestrutura do endpoint.
- **SageMaker AI**: para **treinar modelos próprios**, fazer fine-tuning avançado, pré-treinar e hospedar com controle total. Chips **AWS Trainium** (treino) e **AWS Inferentia** (inferência) reduzem custo e consumo de energia.
- **Bedrock vs. JumpStart**: Bedrock = API serverless, paga por token, sem gerenciar instâncias. JumpStart = modelo em **endpoint dedicado**, paga pela instância, mais controle.

Amazon Q e a transição para Kiro e Amazon Quick

- **Amazon Q Developer**: assistente de IA generativa para desenvolvedores (código, testes, transformação, operações na AWS). Novas assinaturas bloqueadas desde **15/mai/2026**; suporte até **30/abr/2027**. O sucessor é o **Kiro**.
- **Amazon Q Business**: assistente para funcionários com base nos dados da empresa. **Em manutenção desde 30/jul/2026**; o sucessor é o **Amazon Quick**.
- Em simulados, "Amazon Q" ainda aparece como resposta para "assistente de IA generativa pronto para desenvolvedores ou funcionários". Reconheça o conceito e saiba os sucessores.

Vantagens dos serviços de IA generativa da AWS

- **Acessibilidade e menor barreira de entrada**: usar FMs sem especialistas em ML nem treinamento.
- **Eficiência e custo-benefício**: pagar pelo uso, sem infraestrutura ociosa.
- **Velocidade de lançamento** (speed to market): protótipos em dias.
- **Capacidade de atender aos objetivos de negócio** com escolha de modelos e customização.
- **Benefícios da infraestrutura AWS**: **segurança** (IAM, KMS, PrivateLink, isolamento de dados), **conformidade** (programas e certificações, inclusive **ISO/IEC 42001** para gestão de IA), **responsabilidade compartilhada** clara e **segurança do conteúdo** (Guardrails).

Custos e trade-offs

Opções de preço e fatores de custo

Opção	Como cobra	Quando usar
On-demand (Bedrock)	Por token de entrada e saída, sem compromisso	Uso variável, protótipos, maioria das aplicações
Batch inference (Bedrock)	Por token, com desconto em relação ao on-demand	Grandes volumes sem necessidade de resposta imediata
Provisioned Throughput (Bedrock)	Por unidade de modelo por hora , com ou sem compromisso de prazo	Throughput garantido para cargas altas e previsíveis; em geral necessário para modelos customizados
Modelos customizados	Custo do treinamento (tokens processados) + armazenamento mensal do modelo + inferência	Quando prompt e RAG não bastam
Endpoints do SageMaker AI	Por hora de instância , usada ou não (exceto serverless)	Controle total e modelos auto-hospedados

- **Trade-offs cobrados:** **responsividade** (latência) vs. custo; **disponibilidade e redundância** (cross-Region inference, várias Regiões) vs. custo; **desempenho** (modelo maior) vs. custo por token; **cobertura regional** (nem todo modelo existe em toda Região); **token-based** vs. **throughput provisionado**; custo extra de **modelos customizados**.

Decisão rápida — Serviços de IA generativa

Cenário / requisito	Resposta correta	Distratores clássicos
Usar FMs de vários provedores por API sem gerenciar servidores	Amazon Bedrock	SageMaker AI, EC2 com GPU
Implantar um modelo open-weight em endpoint próprio com poucos cliques	SageMaker JumpStart	Bedrock on-demand
Treinar um modelo do zero com controle total	SageMaker AI	Bedrock Playground
RAG gerenciado com citações	Bedrock Knowledge Bases	Fine-tuning
Bloquear tópicos e filtrar PII nas respostas	Bedrock Guardrails	IAM, Macie
Comparar modelos com métricas e avaliadores humanos	Bedrock Model Evaluation	CloudWatch
Versionar prompts	Bedrock Prompt Management	CodeCommit, S3
Gerar imagens com modelo da Amazon	Amazon Nova Canvas	Nova Reel, Rekognition
Gerar vídeos com modelo da Amazon	Amazon Nova Reel	Nova Canvas
Menor latência e custo para texto simples	Amazon Nova Micro	Nova Premier
Processar milhões de prompts sem urgência, mais barato	Bedrock batch inference	Provisioned Throughput
Throughput garantido para carga alta e previsível	Provisioned Throughput	On-demand
Assistente de código (novo cliente em 2026)	Kiro	Amazon Q Developer
Assistente para funcionários com dados da empresa (novo cliente em 2026)	Amazon Quick	Amazon Q Business
Dados do prompt usados para treinar o modelo base?	Não, no Bedrock	Sim

7. Aplicações com Foundation Models: Design, RAG e Customização

Regra de ouro da prova: a escada de customização, da mais barata à mais cara: **engenharia de prompt / in-context learning** → **RAG** → **fine-tuning** → **continued pre-training** → **pré-treinamento do zero**. **RAG** traz **conhecimento** novo e atualizado sem retreinar; **fine-tuning** muda o **comportamento** (tom, formato, tarefa específica). **Destilação** cria um modelo menor e mais barato a partir de um maior.

Critérios de seleção e parâmetros de inferência

Critérios para escolher um FM

Critério	Pergunta que ele responde
Custo	Quanto custa por token ou por hora, no volume esperado?
Modalidade	Precisa de texto, imagem, vídeo, áudio ou embeddings?
Latência	A aplicação é interativa (chat) ou pode esperar (lote)?
Multilíngue	Precisa atender em português e em outros idiomas?
Tamanho do modelo	Um modelo menor atende? Modelos menores são mais rápidos e baratos
Complexidade do modelo	A tarefa exige raciocínio avançado ou é simples (classificar, extrair)?
Customização	O modelo suporta fine-tuning ou destilação no Bedrock?
Tamanho de entrada e saída	A janela de contexto comporta os documentos? Qual o máximo de tokens de saída?
Prompt caching	O modelo suporta cache de prompt para reduzir custo e latência?
Conformidade e licença	Termos de uso, disponibilidade na Região exigida, origem dos dados de treino

Parâmetros de inferência

Parâmetro	Efeito	Na prática
Temperatura	Controla a aleatoriedade . Baixa (perto de 0) = respostas mais previsíveis e focadas ; alta = mais criativas e variadas	Baixa para respostas factuais, extração e código; alta para brainstorming e textos criativos
Top P (nucleus sampling)	Considera só os tokens cuja probabilidade acumulada chega a P	Valor menor = respostas mais conservadoras
Top K	Considera só os K tokens mais prováveis	K menor = menos variedade
Comprimento máximo (max tokens)	Limita o tamanho da resposta	Controla custo e latência; resposta pode ser cortada
Sequências de parada (stop sequences)	Texto que faz o modelo parar de gerar	Delimitar formatos
Tamanho da entrada	Mais contexto = mais custo e latência, e o limite é a janela de contexto	Envie só o necessário

Retrieval Augmented Generation (RAG)

Como o RAG funciona

RAG busca informações relevantes em uma fonte de conhecimento externa **no momento da pergunta** e as inclui no prompt, para que o modelo responda **com base nesses dados**. Etapas (cobradas em questões de ordenação):

1. **Ingestão**: coletar os documentos da empresa (S3, sites, Confluence, SharePoint...).
2. **Chunking**: dividir os documentos em pedaços.
3. **Embeddings**: converter cada pedaço em vetor com um modelo de embeddings.
4. **Armazenamento**: gravar os vetores em um **banco vetorial**.
5. **Consulta**: converter a pergunta do usuário em embedding.
6. **Recuperação**: buscar os pedaços mais **semelhantes** à pergunta.
7. **Aumento**: inserir os trechos recuperados no prompt.
8. **Geração**: o FM responde usando o contexto, idealmente **com citações**.

Benefícios e aplicações de negócio

- Responde com **dados privados e atualizados** sem retrainar o modelo; basta atualizar a base.
- **Reduz alucinações** e permite **citar as fontes** (transparência e auditoria).
- **Mais barato e rápido** que fine-tuning para injetar conhecimento.
- Respeita permissões quando a recuperação filtra por metadados e perfil do usuário.
- **Aplicações**: assistentes de RH e políticas internas, suporte técnico sobre manuais, atendimento com base em catálogos, pesquisa jurídica, análise de contratos.
- **Na AWS: Amazon Bedrock Knowledge Bases** faz o RAG de ponta a ponta (ingestão, chunking, embeddings, armazenamento, recuperação e geração com citações).

Bancos vetoriais na AWS

Serviço	Como guarda embeddings
Amazon OpenSearch Service (e OpenSearch Serverless)	Mecanismo vetorial (k-NN) com busca híbrida (palavra-chave + semântica). Opção padrão de Knowledge Bases
Amazon Aurora PostgreSQL	Extensão pgvector ; bom quando a aplicação já usa PostgreSQL
Amazon RDS for PostgreSQL	Extensão pgvector
Amazon Neptune (Neptune Analytics)	Busca vetorial combinada com grafos (GraphRAG)
Amazon DocumentDB	Busca vetorial em documentos JSON
Amazon S3 Vectors	Armazenamento vetorial de baixo custo no S3 para grandes volumes

Abordagens de customização

Comparação de custo e esforço

Abordagem	O que muda	Custo e esforço	Quando usar
-----------	------------	-----------------	-------------

Abordagem	O que muda	Custo e esforço	Quando usar
Engenharia de prompt / in-context learning	Só o prompt (instruções e exemplos)	Menor: nenhum treinamento	Sempre o primeiro passo
RAG	O contexto enviado ao modelo	Baixo a médio: banco vetorial, embeddings, tokens de contexto	Conhecimento privado ou que muda com frequência
Fine-tuning	Os pesos do modelo, com dados rotulados (pares prompt-resposta)	Médio a alto: dados, treinamento, hospedagem do modelo customizado	Estilo, tom, formato ou tarefa específica que o prompt não resolve
Continued pre-training	Os pesos, com grandes volumes de dados não rotulados do domínio	Alto	Vocabulário e conhecimento de um domínio (jurídico, médico, financeiro)
Destilação (distillation)	Um modelo aluno menor aprende com as respostas de um modelo professor maior	Médio (treinamento), mas reduz o custo e a latência de inferência	Precisa da qualidade do modelo grande com custo de um pequeno
Pré-treinamento do zero	Cria um FM novo	Maior de todos: dados massivos, meses, muita computação	Raramente; organizações com necessidades e recursos excepcionais

- **Armadilha:** fine-tuning **não** é a melhor forma de ensinar fatos que mudam toda semana. O modelo "congela" o conhecimento no treino; use **RAG**.
- **Armadilha:** RAG não muda o **estilo** do modelo; se o problema é tom ou formato, tente prompt e, depois, fine-tuning.

Agentes em aplicações

O papel dos agentes no design

- Use um agente quando a aplicação precisa **executar ações** ou **combinar várias fontes e ferramentas** em várias etapas, não só responder.
- Um agente pode usar **RAG como uma de suas ferramentas** (consultar a base de conhecimento) ao lado de APIs e bancos de dados.
- Mais autonomia = mais risco: combine com **Guardrails, Policy in AgentCore**, permissões mínimas e **aprovação humana** para ações sensíveis. Veja a seção 5.

Decisão rápida — Design, RAG e customização

Cenário / requisito	Resposta correta	Distratores clássicos
Respostas factuais e consistentes	Temperatura baixa	Temperatura alta
Textos criativos e variados	Temperatura alta	Temperatura 0
Limitar custo e tamanho das respostas	Max tokens menor	Temperatura
Responder com políticas internas que mudam toda semana	RAG (Bedrock Knowledge Bases)	Fine-tuning, pré-treinamento
Citar a fonte da resposta	RAG com citações	Temperatura baixa
Modelo deve responder sempre no tom e formato da marca	Fine-tuning (após tentar prompt)	RAG
Ensinar vocabulário de um domínio com dados não rotulados	Continued pre-training	Fine-tuning com poucos exemplos
Qualidade de modelo grande com custo de modelo pequeno	Destilação	Pré-treinamento

Cenário / requisito	Resposta correta	Distratores clássicos
Opção de customização de menor custo	Engenharia de prompt / in-context learning	Fine-tuning
Opção de customização mais cara	Pré-treinar do zero	RAG
Guardar embeddings junto de um banco PostgreSQL existente	Aurora/RDS PostgreSQL com pgvector	DynamoDB
Busca vetorial gerenciada padrão para RAG	Amazon OpenSearch Service	Redshift
Combinar grafos e vetores	Amazon Neptune	RDS
Primeira etapa do RAG	Ingestão e chunking dos documentos	Geração

8. Engenharia de Prompts

Regra de ouro da prova: um bom prompt é **específico, conciso e estruturado**: diz **o que fazer** (instrução), **com quais informações** (contexto e dados de entrada), **em que formato** (saída) e, quando útil, **com exemplos** (few-shot). **Prompt injection** e **jailbreaking** são os riscos mais cobrados; **Guardrails** e validação de entrada e saída são a defesa.

Construção de prompts

Elementos de um prompt

Elemento	Exemplo
Instrução	"Resuma o texto abaixo em três tópicos."
Contexto	"Você é um analista financeiro escrevendo para a diretoria."
Dados de entrada	O texto, o documento ou a pergunta do usuário
Indicador de saída (formato)	"Responda em JSON com os campos titulo e resumo."
Exemplos	Pares de entrada e saída esperada (few-shot)
Prompt negativo	O que o modelo não deve fazer ou incluir: "Não cite concorrentes." Em geração de imagens, elementos a evitar ("sem texto, sem pessoas")
System prompt	Instruções persistentes que definem papel, tom e limites da aplicação

Técnicas de prompt

Técnicas cobradas

Técnica	Como funciona	Quando usar
Zero-shot	Só a instrução, sem exemplos	Tarefas simples e comuns
Single-shot / one-shot	Um exemplo de entrada e saída	Mostrar o formato esperado
Few-shot	Alguns exemplos	Tarefas com padrão específico (classificar tickets nas categorias da empresa)
Chain-of-thought (CoT)	Pedir que o modelo raciocine passo a passo antes de responder	Problemas de lógica, matemática e várias etapas
Templates de prompt	Estruturas reutilizáveis com variáveis preenchidas em tempo de execução	Padronizar e escalar prompts na aplicação

- **In-context learning** é o nome geral para o modelo "aprender" a tarefa pelos exemplos no próprio prompt, **sem alterar os pesos**. Zero-shot, one-shot e few-shot são formas de in-context learning.

Benefícios e boas práticas

- **Melhora a qualidade da resposta** sem custo de treinamento.
- **Experimentação**: teste variações e compare resultados (Bedrock Playground, Prompt Management, Model Evaluation).
- **Guardrails**: combine prompts com controles de segurança.
- **Descoberta**: explorar o que o modelo sabe fazer.
- **Especificidade e concisão**: instruções claras, sem ambiguidade; peça o formato exato.
- **Divida em várias instruções**: separe tarefas complexas em passos ou em prompts encadeados.
- Coloque as instruções em posição clara, delimite os dados de entrada (tags, aspas) e peça que o modelo diga "não sei" quando a resposta não estiver no contexto.

Riscos e gerenciamento de prompts

Riscos e limitações

Risco	O que é	Defesa
Prompt injection	Texto malicioso (do usuário ou de um documento recuperado) tenta sobrescrever as instruções do sistema	Guardrails (filtro de ataque de prompt), separar instruções de dados, validar entradas e saídas, menor privilégio para ferramentas
Hijacking (sequestro)	Desviar o modelo para outra tarefa ou objetivo	Instruções firmes no system prompt, tópicos negados
Jailbreaking	Contornar as proteções de segurança do modelo com truques (encenação, cenários hipotéticos)	Guardrails, avaliação adversarial (red teaming)
Exposição / vazamento (exposure, leaking)	Fazer o modelo revelar o system prompt , dados sensíveis ou informações de outros usuários	Não colocar segredos no prompt, filtros de PII, controle de acesso na recuperação
Envenenamento (poisoning)	Inserir dados maliciosos nos dados de treino ou na base de conhecimento para manipular respostas	Curadoria e validação das fontes, controle de quem escreve na base

Amazon Bedrock Prompt Management

- Cria, testa, **versiona** e compartilha prompts reutilizáveis com **variáveis**, modelo e parâmetros de inferência associados.
- **Versões imutáveis** permitem comparar, voltar a uma versão anterior e promover um prompt aprovado para produção sem mudar o código da aplicação.
- Integra-se ao **Bedrock Flows** e aos testes comparativos entre variantes de prompt.
- **Estratégia recomendada**: tratar prompts como código: versionar, revisar, testar com um conjunto de avaliação e registrar qual versão está em produção.

Decisão rápida — Engenharia de prompts

Cenário / requisito	Resposta correta	Distratores clássicos
Pedir a tarefa sem exemplos	Zero-shot	Few-shot
Fornecer vários exemplos no prompt	Few-shot	Fine-tuning
Fazer o modelo raciocinar passo a passo	Chain-of-thought	Zero-shot
Reutilizar prompts com variáveis	Templates de prompt	Fine-tuning

Cenário / requisito	Resposta correta	Distratores clássicos
Aprender a tarefa pelo prompt sem mudar pesos	In-context learning	Fine-tuning
Dizer o que o modelo não deve incluir	Prompt negativo	Temperatura
Usuário tenta "ignore as instruções anteriores"	Prompt injection	Alucinação
Truque para contornar as proteções do modelo	Jailbreaking	Poisoning
Documentos maliciosos inseridos na base de conhecimento	Poisoning	Jailbreaking
Modelo revela o system prompt	Exposição / vazamento	Hijacking
Versionar e gerenciar prompts no Bedrock	Bedrock Prompt Management	S3, Git sozinho
Bloquear ataques de prompt	Bedrock Guardrails	IAM, KMS

9. Treinamento, Fine-tuning e Avaliação de FMs

Regra de ouro da prova: **pré-treinamento** usa dados enormes **não rotulados** (autossupervisionado); **fine-tuning** usa dados **rotulados** menores para uma tarefa; **continued pre-training** usa dados **não rotulados do domínio**; **destilação** transfere conhecimento de um modelo grande para um pequeno. Na avaliação: **ROUGE** para **resumo**, **BLEU** para **tradução**, **BERTScore** para **similaridade semântica**, **LLM como juiz** para critérios subjetivos em escala.

Treinamento e fine-tuning

Elementos do treinamento de um FM

Elemento	Dados	Objetivo
Pré-treinamento	Volumes massivos e amplos, não rotulados	Aprender linguagem e conhecimento geral (autossupervisionado)
Fine-tuning	Conjunto menor e rotulado (pares prompt-resposta)	Adaptar a uma tarefa, estilo ou formato
Continued pre-training (pré-treinamento contínuo)	Grandes volumes não rotulados de um domínio	Adaptar o modelo ao vocabulário e ao conhecimento do domínio
Destilação	Respostas geradas por um modelo professor	Criar um modelo aluno menor, mais rápido e mais barato

Métodos de fine-tuning

- **Instruction tuning:** treinar com exemplos de **instruções e respostas**, para o modelo seguir melhor pedidos.
- **Adaptação de domínio:** especializar em uma área (jurídica, médica, atendimento de uma empresa).
- **Transfer learning:** reaproveitar o conhecimento de um modelo pré-treinado e ajustá-lo a uma tarefa nova com poucos dados. É o princípio por trás de todo fine-tuning de FMs.
- **Continued pre-training:** continuar o pré-treinamento com dados do domínio.
- **Técnicas eficientes** (PEFT, como LoRA): ajustam só uma pequena parte dos parâmetros, reduzindo custo.

Preparação de dados para fine-tuning

- **Curadoria:** selecionar exemplos corretos, relevantes e sem duplicatas.
- **Governança:** origem conhecida, direitos de uso, privacidade (remover ou mascarar PII) e conformidade.
- **Tamanho:** dados suficientes para a tarefa; qualidade vale mais que quantidade.
- **Rotulagem:** rótulos consistentes e revisados.
- **Representatividade:** cobrir os casos, idiomas e grupos que o modelo vai atender, evitando viés.
- **RLHF (reinforcement learning from human feedback):** humanos **classificam ou comparam** respostas; um modelo de recompensa aprende essas preferências e orienta o ajuste. Alinha o modelo a respostas **úteis, honestas e seguras**.

Avaliação de foundation models

Abordagens de avaliação

Abordagem	Como funciona	Pontos fortes
Avaliação com humano no loop	Pessoas avaliam respostas por critérios (utilidade, correção, tom)	Captura nuances e qualidade percebida; mais cara e lenta
Conjuntos de dados de benchmark	Conjuntos padronizados de perguntas e respostas esperadas	Comparação objetiva e repetível entre modelos
Amazon Bedrock Model Evaluation	Avaliação automática (métricas e conjuntos prontos ou próprios), LLM como juiz e com equipes humanas (suas ou gerenciadas); também avalia aplicações RAG	Comparar modelos e configurações na AWS

Métricas de avaliação de FMs

Métrica	O que mede	Tarefa típica
ROUGE (Recall-Oriented Understudy for Gisting Evaluation)	Sobreposição de palavras e sequências entre o texto gerado e uma referência, com foco em recall	Resumo
BLEU (Bilingual Evaluation Understudy)	Sobreposição de n-gramas com foco em precisão em relação a traduções de referência	Tradução
BERTScore	Similaridade semântica usando embeddings; reconhece paráfrases com palavras diferentes	Qualidade de texto quando o significado importa mais que as palavras exatas
LLM como juiz (LLM-as-a-judge)	Um modelo avalia as respostas de outro segundo critérios definidos (correção, relevância, completude, nocividade)	Avaliação em escala de critérios subjetivos
Perplexidade	Quão "surpreso" o modelo fica com um texto (menor é melhor)	Qualidade de modelos de linguagem
Acurácia / F1	Acertos em tarefas com resposta fechada	Classificação, extração, perguntas objetivas

Avaliar aplicações e alinhamento com o negócio

- **Aplicações RAG:** avalie a **recuperação** (os trechos certos foram encontrados?) e a **geração** (a resposta é **fiel ao contexto** — faithfulness/groundedness — e relevante?). O Bedrock avalia Knowledge Bases.
- **Agentes:** taxa de conclusão de tarefas, uso correto de ferramentas, número de passos, custo por tarefa. **AgentCore Evaluations** automatiza essas medições.
- **Fluxos (workflows):** sucesso de ponta a ponta, latência e custo de cada etapa.
- **O FM atende ao objetivo de negócio?** Meça **produtividade**, **engajamento do usuário** e a execução correta das tarefas.
- **Métricas de alinhamento com o negócio:** taxa de conclusão de tarefas, satisfação do usuário (CSAT, avaliações) e **custo por interação**.

Decisão rápida — Treinamento e avaliação

Cenário / requisito	Resposta correta	Distratores clássicos
Aprender linguagem geral com dados massivos não rotulados	Pré-treinamento	Fine-tuning
Adaptar com pares de instrução e resposta rotulados	Fine-tuning (instruction tuning)	Continued pre-training
Adaptar ao domínio com muitos documentos não rotulados	Continued pre-training	Fine-tuning supervisionado

Cenário / requisito	Resposta correta	Distratores clássicos
Reaproveitar um modelo pré-treinado para nova tarefa	Transfer learning	Treinar do zero
Alinhar respostas a preferências humanas	RLHF	Clustering
Modelo menor que imita um maior	Destilação	Pré-treinamento
Avaliar qualidade de resumos	ROUGE	BLEU
Avaliar qualidade de traduções	BLEU	ROUGE
Comparar significado mesmo com palavras diferentes	BERTScore	BLEU
Avaliar critérios subjetivos em escala com um modelo	LLM como juiz	ROUGE
Avaliação padronizada e repetível entre modelos	Benchmark datasets	Avaliação ad hoc
Avaliar tom e utilidade percebida	Avaliação humana	Métricas automáticas
Avaliar modelos e RAG na AWS	Bedrock Model Evaluation	CloudWatch, Config
Métrica de negócio para um assistente de atendimento	Taxa de conclusão de tarefas / custo por interação	Perplexidade

10. IA Responsável

Regra de ouro da prova: IA responsável é garantir que o sistema seja **justo, explicável, seguro, robusto, privado, controlável, transparente e bem governado**. Para **filtrar conteúdo nocivo e bloquear tópicos** em IA generativa, a resposta é **Amazon Bedrock Guardrails**. Para **detectar viés e explicar previsões** de modelos de ML, a resposta clássica é **SageMaker Clarify**. Para **documentar** o modelo, **SageMaker Model Cards**.

Características da IA responsável

Dimensões da IA responsável

O guia do exame cita **viés, justiça, inclusão, robustez, segurança e veracidade**. A AWS organiza a IA responsável em oito dimensões:

Dimensão	Significado
Justiça (fairness)	Considerar o impacto em diferentes grupos de pessoas e evitar discriminação
Explicabilidade (explainability)	Entender e avaliar as saídas do sistema
Privacidade e segurança	Obter, usar e proteger dados e modelos adequadamente
Segurança (safety)	Prevenir saídas nocivas e uso indevido
Controlabilidade	Ter mecanismos para monitorar e dirigir o comportamento do sistema
Veracidade e robustez	Obter saídas corretas, mesmo com entradas inesperadas ou adversariais
Governança	Incorporar boas práticas à cadeia de fornecimento de IA, incluindo fornecedores e implantadores
Transparência	Permitir que as partes interessadas façam escolhas informadas sobre o uso do sistema

- **Inclusão:** o sistema deve funcionar bem para pessoas de diferentes idiomas, regiões, idades e capacidades.

Ferramentas para IA responsável na AWS

Ferramenta	O que faz
Amazon Bedrock Guardrails	Salvaguardas configuráveis aplicadas a entradas e saídas de qualquer FM (inclusive fora do Bedrock, via API ApplyGuardrail)
SageMaker Clarify	Detecta viés nos dados (antes do treino) e no modelo (depois do treino) e explica previsões mostrando a importância de cada feature. <i>Em manutenção desde 30/jul/2026</i>
SageMaker Model Monitor	Monitora drift de dados, de qualidade e de viés em produção. <i>Em manutenção desde 30/jul/2026</i>
Amazon Augmented AI (A2I)	Envia previsões de baixa confiança para revisão humana . <i>Em manutenção desde 30/jul/2026</i>
SageMaker Model Cards	Documentação padronizada do modelo: uso pretendido, dados, métricas, riscos, avaliação
Bedrock Model Evaluation	Avalia modelos inclusive em robustez e toxicidade , com métricas automáticas, LLM como juiz ou humanos
AWS AI Service Cards	Documentos da AWS sobre uso pretendido, limitações e boas práticas dos serviços de IA dela

Filtros do Amazon Bedrock Guardrails

Política	O que faz	Exemplo
Filtros de conteúdo	Detectam e bloqueiam categorias nocivas (ódio, insultos, sexual, violência, má conduta) em texto e imagem, com intensidade ajustável; inclui filtro de ataques de prompt	Bloquear linguagem ofensiva e tentativas de jailbreak
Tópicos negados	Bloqueiam assuntos definidos em linguagem natural	Um banco proíbe o assistente de dar "recomendações de investimento"
Filtros de palavras	Bloqueiam palavras e expressões específicas, incluindo palavrões	Nomes de concorrentes
Filtros de informações sensíveis	Detectam PII e padrões personalizados (regex) para bloquear ou mascarar	Mascarar CPF, e-mail e telefone nas respostas
Verificação de fundamentação contextual (contextual grounding check)	Detecta respostas não fundamentadas na fonte ou irrelevantes para a pergunta	Reduzir alucinações em RAG
Verificações de raciocínio automatizado (automated reasoning checks)	Validam matematicamente a resposta contra regras e políticas formalizadas	Conferir se a resposta respeita uma política de RH

Dados, viés e riscos

Características de bons conjuntos de dados

- **Inclusivos e diversos:** representam os grupos, idiomas e situações do mundo real.
- **Fontes curadas:** origem conhecida, qualidade verificada, direitos de uso claros.
- **Balanceados:** sem uma classe ou grupo dominando os demais. Dados desbalanceados produzem modelos enviesados e métricas enganosas.

Viés e variância

- **Viés alto** (high bias): o modelo é **simples demais** e erra sistematicamente, até nos dados de treino → **underfitting**.
- **Variância alta** (high variance): o modelo **decora** os dados de treino e falha com dados novos → **overfitting**.
- **Efeitos:** resultados **injustos para grupos demográficos** (ex.: aprovar menos crédito para um grupo sub-representado nos dados), **imprecisão** e perda de confiança.
- **Como corrigir overfitting:** mais dados, regularização, modelo mais simples, parar o treino antes (early stopping).
Underfitting: modelo mais complexo, mais features, treinar por mais tempo.

Como detectar e monitorar viés, confiabilidade e veracidade

- **Analisar a qualidade dos rótulos:** rótulos errados ou inconsistentes transmitem viés.
- **Auditorias humanas:** revisores avaliam amostras de saídas.
- **Análise por subgrupos:** medir o desempenho **separadamente para cada grupo** demográfico; um modelo com boa média pode falhar com um grupo específico.
- **Monitoramento contínuo** em produção (drift de viés) e avaliação periódica.

Riscos legais da IA generativa

- **Violação de propriedade intelectual:** conteúdo gerado parecido com obras protegidas ou modelos treinados com dados sem direito de uso.
- **Saídas enviesadas** que geram discriminação e responsabilização.
- **Perda da confiança do cliente** após respostas erradas, ofensivas ou vazamentos.
- **Risco ao usuário final:** decisões ou orientações erradas em saúde, finanças ou segurança.
- **Alucinações** apresentadas como fatos.

Seleção responsável de modelos

- **Considerações ambientais e de sustentabilidade:** escolher o **menor modelo que atende** à tarefa, reaproveitar modelos pré-treinados em vez de treinar do zero, usar hardware eficiente (**AWS Trainium, AWS Inferentia, Graviton**) e Regiões com energia mais limpa.
- Avaliar também licença, documentação (model cards), origem dos dados e resultados de avaliação de segurança do modelo.

Transparência e explicabilidade

Modelos transparentes vs. caixa-preta

- **Transparentes e explicáveis:** é possível entender **como** chegam a uma decisão. Exemplos: regressão linear, árvores de decisão, modelos baseados em regras.
- **Não transparentes** (caixa-preta): redes neurais profundas e LLMs com bilhões de parâmetros; difícil saber por que produziram uma saída.
- **Transparência** refere-se a informar como o sistema foi construído, com quais dados e para qual uso.
Explicabilidade refere-se a explicar **uma saída específica** (ex.: quais features pesaram na negativa de crédito).

Ferramentas de transparência e explicabilidade

- **SageMaker Model Cards:** documentam o modelo para auditoria e governança.
- **SageMaker Clarify:** explicabilidade com importância de features (SHAP).
- **Bedrock Model Evaluations:** resultados comparáveis de qualidade e segurança.
- **Modelos, dados e licenças open source:** permitem inspecionar pesos, dados de treino e termos de uso.
- **AWS AI Service Cards:** transparência sobre os serviços de IA da AWS.

Trade-offs entre segurança, transparência e desempenho

- Modelos mais **interpretáveis** costumam ter **desempenho menor** em tarefas complexas; modelos mais poderosos são menos interpretáveis. É preciso **medir interpretabilidade e desempenho** e escolher conforme o risco do caso de uso.
- Expor detalhes demais (dados de treino, prompts, regras) pode facilitar ataques, e esconder demais reduz a confiança. O equilíbrio depende do público e da regulação.

Design centrado no humano para IA explicável

- **Mecanismos de feedback do usuário:** botões de avaliação, correções e canais para contestar decisões.

- **Transparência das decisões de IA:** informar quando o usuário está interagindo com IA, mostrar as fontes e o nível de confiança e explicar em linguagem simples.
- **Supervisão humana** para decisões de alto impacto e possibilidade de revisão.
- Interfaces que ajudam o usuário a **calibrar a confiança** (nem confiar cegamente, nem descartar).

Decisão rápida — IA responsável

Cenário / requisito	Resposta correta	Distratores clássicos
Bloquear conteúdo ofensivo nas respostas do FM	Bedrock Guardrails (filtros de conteúdo)	IAM, Macie
Impedir que o assistente fale de um assunto	Guardrails — tópicos negados	Prompt negativo sozinho
Mascarar dados pessoais nas respostas	Guardrails — filtro de informações sensíveis	KMS
Detectar respostas não fundamentadas na fonte	Guardrails — contextual grounding check	Temperatura alta
Detectar viés nos dados e explicar previsões de ML	SageMaker Clarify	Model Cards, CloudTrail
Documentar uso pretendido e limitações do modelo	SageMaker Model Cards	Model Registry
Revisão humana de previsões de baixa confiança	Amazon A2I (em manutenção) / revisão humana	Rekognition
Modelo decora o treino e falha em produção	Variância alta (overfitting)	Viés alto
Modelo simples demais, erra sempre	Viés alto (underfitting)	Variância alta
Descobrir se o modelo falha com um grupo específico	Análise por subgrupos	Acurácia geral
Dados com um grupo sub-representado	Conjunto desbalanceado → coletar/balancear dados	Aumentar a temperatura
Escolha de modelo com menor impacto ambiental	Menor modelo que atende, hardware eficiente	Maior modelo disponível
Decisão que precisa ser explicada ao cliente	Modelo interpretável + explicabilidade	LLM caixa-preta
Conteúdo gerado parecido com obra protegida	Risco de propriedade intelectual	Alucinação

11. Segurança, Conformidade e Governança para IA

Regra de ouro da prova: a segurança de IA usa os **mesmos blocos da AWS** — **IAM** com menor privilégio, **KMS** para criptografia, **PrivateLink** para tráfego privado, **Macie** para PII no S3, **CloudTrail** para auditoria, **Config** para conformidade, **Inspector** para vulnerabilidades, **Artifact** para relatórios — mais os controles específicos de IA: **Guardrails**, **AgentCore Identity** e **Policy in AgentCore**.

Proteger sistemas de IA

Serviços e recursos de segurança

Serviço ou recurso	Papel na segurança de IA
IAM (roles, políticas, permissões)	Controlar quem pode invocar quais modelos, acessar Knowledge Bases e dados de treino; roles com menor privilégio para aplicações e agentes
Criptografia (AWS KMS, TLS)	Dados de treino, modelos customizados, Knowledge Bases e logs criptografados em repouso com chaves do KMS; TLS em trânsito
Amazon Macie	Descobrir PII e dados sensíveis em buckets S3 antes de usá-los em treino ou RAG
AWS PrivateLink (VPC endpoints)	Acessar o Bedrock e o SageMaker AI sem passar pela internet pública
Modelo de responsabilidade compartilhada	A AWS protege a infraestrutura e os serviços gerenciados; o cliente protege seus dados, prompts, acessos, configurações e aplicações
Amazon Bedrock AgentCore Identity	Identidade e credenciais dos agentes , com acesso delegado a ferramentas e integração a provedores de identidade
Policy in AgentCore	Regras determinísticas (linguagem compatível com Cedar) que definem quais ferramentas e ações o agente pode executar e sob quais condições
Amazon Bedrock Guardrails	Filtrar entradas e saídas, bloquear ataques de prompt e PII
AWS Secrets Manager	Guardar chaves de API e credenciais usadas por aplicações e agentes

- **Responsabilidade compartilhada na IA generativa:** ao usar o Bedrock, a AWS cuida da infraestrutura, da hospedagem dos modelos e do isolamento dos dados; o cliente é responsável por **quem acessa, quais dados envia, quais guardrails configura, como a aplicação usa as respostas** e pela conformidade do seu caso de uso.

Considerações de segurança e privacidade

Consideração	Como tratar
Segurança da aplicação	Validar entradas, autenticar usuários, limitar taxas, seguir boas práticas de desenvolvimento
Deteção de ameaças	Amazon GuardDuty (inclusive proteção para cargas de IA) e monitoramento de uso anômalo
Gestão de vulnerabilidades	Amazon Inspector em instâncias, contêineres e Lambda que hospedam a aplicação
Proteção da infraestrutura	VPC, security groups, PrivateLink, menor privilégio
Prompt injection	Guardrails, separar instruções de dados, limitar permissões de ferramentas
Criptografia em repouso e em trânsito	KMS e TLS

Consideração	Como tratar
Prevenção de vazamento de dados	Não enviar dados desnecessários ao modelo, mascarar PII, filtrar a recuperação pelas permissões do usuário
Filtragem e validação da saída	Guardrails, validar formato e conteúdo antes de exibir ou executar
Trilha de auditoria e logs das interações	CloudTrail registra as chamadas de API; o model invocation logging do Bedrock grava prompts e respostas no CloudWatch Logs ou no S3
Toxicidade	Filtros de conteúdo e avaliação de toxicidade

Detecção de alucinação e grounding

- **Fundamentação com RAG** (RAG grounding): responder a partir de documentos confiáveis, **com citações**, e instruir o modelo a dizer "não sei" quando a resposta não estiver no contexto.
- **Validação da saída**: verificar a resposta contra fontes, regras ou outro modelo; **contextual grounding check** e **automated reasoning checks** do Guardrails.
- **Pontuação de confiança** (confidence scoring): atribuir um nível de confiança e encaminhar respostas de baixa confiança a um humano ou pedir mais informações.
- Também ajudam: **temperatura baixa**, prompts específicos e ferramentas para cálculos e consultas em vez de "memória" do modelo.

Origem dos dados e engenharia de dados segura

- **Citação de fontes e documentação da origem dos dados**: saber de onde veio cada dado de treino e cada trecho usado na resposta.
- **Linhagem de dados** (data lineage): rastrear a origem e as transformações dos dados até o modelo.
- **Catálogo de dados**: AWS Glue Data Catalog e Lake Formation mantêm metadados e permissões.
- **SageMaker Model Cards**: registram dados usados, finalidade e avaliação.
- **Boas práticas de engenharia de dados segura**: **avaliar a qualidade** dos dados; aplicar **tecnologias de preservação de privacidade** (anonimização, mascaramento, tokenização, privacidade diferencial, dados sintéticos); **controlar o acesso** (Lake Formation, IAM); garantir a **integridade** (versionamento, checksums, controle de quem altera).

Governança e conformidade

Serviços de governança e conformidade

Serviço	Papel
AWS Config	Registrar configurações e avaliar conformidade dos recursos (ex.: endpoints e buckets criptografados)
Amazon Inspector	Encontrar vulnerabilidades nas cargas que hospedam IA
AWS Artifact	Relatórios de conformidade da AWS (SOC, ISO, incluindo ISO/IEC 42001 de sistema de gestão de IA)
AWS CloudTrail	Auditoria de quem chamou quais APIs (invocações de modelos, alterações em guardrails)
AWS Trusted Advisor	Recomendações de segurança, custo e limites
AWS Audit Manager	Coletar evidências para auditorias, com frameworks prontos (inclusive para IA generativa)
Amazon CloudWatch	Métricas, logs e alarmes de uso e desempenho

Estratégias de governança de dados

- **Ciclo de vida dos dados:** coleta, uso, arquivamento e exclusão definidos.
- **Logs:** registrar acessos, invocações e alterações.
- **Residência:** manter dados na Região exigida por lei ou contrato.
- **Monitoramento e observação:** acompanhar uso, qualidade e desvios continuamente.
- **Retenção:** guardar dados e logs pelo tempo exigido e não mais que isso.

Processos e frameworks de governança

- **Políticas** de uso aceitável de IA, aprovação de casos de uso e classificação de risco.
- **Cadência de revisão e estratégias de revisão** (revisões periódicas de modelos, dados, prompts e incidentes).
- **Padrões de transparência:** informar usuários sobre o uso de IA e documentar modelos.
- **Requisitos de treinamento das equipes** em uso seguro e responsável de IA.
- **Regulações e padrões externos:** **ISO/IEC 42001** (gestão de IA), **NIST AI Risk Management Framework**, **EU AI Act** (classificação por nível de risco) e leis de proteção de dados como **LGPD** e **GDPR**.

Generative AI Security Scoping Matrix

Framework da AWS que classifica o uso de IA generativa em **cinco escopos**, do menor ao maior controle (e responsabilidade) do cliente:

Escopo	Tipo	Exemplo
1	Aplicação para consumidor	Funcionários usando um chatbot público de IA
2	Aplicação corporativa (SaaS com IA)	Software empresarial com recursos de IA generativa embutidos
3	Modelos pré-treinados	Construir a aplicação sobre um FM via API (ex.: Amazon Bedrock)
4	Modelos ajustados (fine-tuned)	Ajustar um FM com os próprios dados
5	Modelos treinados pela própria empresa	Treinar um modelo do zero

- Quanto **maior o escopo**, mais responsabilidades de segurança, privacidade, governança e conformidade ficam com o cliente (dados de treino, pesos do modelo, avaliação).

Decisão rápida — Segurança e governança

Cenário / requisito	Resposta correta	Distratores clássicos
Invocar o Bedrock sem passar pela internet	AWS PrivateLink (VPC endpoint)	NAT Gateway, Direct Connect sozinho
Encontrar PII em dados de treino no S3	Amazon Macie	Comprehend, Inspector
Criptografar dados de treino e modelos customizados	AWS KMS	ACM, Secrets Manager
Controlar quem pode invocar cada modelo	IAM (políticas com menor privilégio)	Guardrails
Auditar quem chamou o modelo e quando	AWS CloudTrail	CloudWatch métricas
Registrar prompts e respostas	Bedrock model invocation logging	Config
Identidade e credenciais de agentes	AgentCore Identity	Access keys fixas
Limitar ações de agentes com regras determinísticas	Policy in AgentCore	Prompt de sistema

Cenário / requisito	Resposta correta	Distratores clássicos
Relatórios de conformidade da AWS (ex.: ISO 42001)	AWS Artifact	Audit Manager
Coletar evidências para auditoria	AWS Audit Manager	Artifact
Verificar conformidade de configurações	AWS Config	CloudTrail
Vulnerabilidades nas instâncias que hospedam o modelo	Amazon Inspector	GuardDuty
Reduzir alucinações com fontes confiáveis	RAG com citações + grounding check	Temperatura alta
Rastrear origem e transformações dos dados	Linhagem de dados (data lineage)	Fine-tuning
Empresa usando um FM via Bedrock: qual escopo?	Escopo 3 — modelos pré-treinados	Escopo 1, escopo 5
Empresa treinando o próprio FM	Escopo 5	Escopo 3

12. Padrões recorrentes e palavras-chave

As questões do AI Practitioner giram em torno de poucas decisões: qual técnica, qual nível de customização, qual serviço e qual controle de risco. Esta seção reúne as palavras do enunciado que apontam para cada resposta e os pares que mais se confundem.

Palavras-chave do enunciado

Se o enunciado diz...	Pense em...
"Número contínuo", "prever valor"	Regressão
"Categoria", "sim ou não"	Classificação
"Sem rótulos", "agrupar", "segmentar"	Clustering (não supervisionado)
"Recompensa", "tentativa e erro"	Aprendizado por reforço
"Resultado exato sempre", "regra fixa"	Não usar ML
"Sem treinar modelo", "serviço pronto"	Serviço de IA gerenciado (Rekognition, Textract, Comprehend...)
"Vários FMs por API", "serverless"	Amazon Bedrock
"Modelo pré-treinado em endpoint próprio"	SageMaker JumpStart
"Dados privados", "atualizados", "citar fontes"	RAG (Bedrock Knowledge Bases)
"Tom", "estilo", "formato específico"	Fine-tuning
"Menor custo de customização"	Engenharia de prompt / in-context learning
"Modelo menor com qualidade do maior"	Destilação
"Respostas consistentes e factuais"	Temperatura baixa
"Raciocinar passo a passo"	Chain-of-thought
"Exemplos no prompt"	Few-shot
"Ignore as instruções anteriores"	Prompt injection
"Bloquear tópicos", "filtrar conteúdo", "mascarar PII na resposta"	Bedrock Guardrails
"Resposta inventada"	Alucinação → RAG, grounding check
"Executa tarefas em várias etapas com ferramentas"	Agente (AgentCore, Strands Agents)
"Conectar agentes a ferramentas de forma padronizada"	MCP
"Viés e explicabilidade de modelo de ML"	SageMaker Clarify
"Documentar o modelo"	SageMaker Model Cards
"Sem internet pública"	AWS PrivateLink
"PII em buckets S3"	Amazon Macie
"Quem chamou o modelo"	AWS CloudTrail
"Relatório de conformidade da AWS"	AWS Artifact
"Resumo" (avaliação)	ROUGE
"Tradução" (avaliação)	BLEU

Pares que mais se confundem

Par	Como separar
IA vs. ML vs. deep learning vs. GenAI	Círculos concêntricos: IA ⊃ ML ⊃ deep learning ⊃ GenAI; IA agêntica é uma arquitetura que usa GenAI
Algoritmo vs. modelo	Algoritmo é o método; modelo é o resultado treinado
Treinamento vs. inferência	Treinar ajusta parâmetros; inferir usa o modelo para prever
Parâmetro vs. hiperparâmetro	Parâmetro é aprendido; hiperparâmetro é escolhido antes do treino
Overfitting vs. underfitting	Overfitting = variância alta, decora o treino; underfitting = viés alto, simples demais
Precisão vs. recall	Precisão evita falsos positivos; recall evita falsos negativos
Inferência em tempo real vs. assíncrona vs. batch vs. serverless	Imediata; fila com payload grande; lote offline; intermitente sem instância
RAG vs. fine-tuning	RAG muda o contexto (conhecimento atual); fine-tuning muda os pesos (comportamento)
Fine-tuning vs. continued pre-training	Fine-tuning usa dados rotulados ; continued pre-training usa dados não rotulados do domínio
Bedrock vs. SageMaker AI	Bedrock = FMs por API serverless; SageMaker AI = construir, treinar e hospedar com controle
Bedrock vs. SageMaker JumpStart	Pagar por token sem instância vs. modelo em endpoint dedicado pago por hora
Comprehend vs. Textract	Comprehend entende texto (sentimento, entidades); Textract extrai texto e tabelas de documentos
Transcribe vs. Polly	Transcribe: fala → texto; Polly: texto → fala
Rekognition vs. Textract	Rekognition analisa imagens (rostos, objetos); Textract lê documentos
Lex vs. Bedrock	Lex: bot baseado em intenções; Bedrock: FMs para conversas abertas e geração
Guardrails vs. IAM	Guardrails controla o conteúdo ; IAM controla quem acessa
Guardrails vs. Clarify	Guardrails protege aplicações de GenAI em tempo real; Clarify analisa viés e explicabilidade de modelos de ML
Model Cards vs. AI Service Cards	Model Cards documentam seus modelos; AI Service Cards documentam os serviços de IA da AWS
MCP vs. A2A	MCP conecta agente a ferramentas e dados; A2A conecta agente a agente
Strands Agents vs. AgentCore	Strands é o SDK para escrever o agente; AgentCore é a plataforma para executar e operar
Kiro vs. Amazon Quick	Kiro é para desenvolvedores ; Amazon Quick é para usuários de negócio
ROUGE vs. BLEU vs. BERTScore	Resumo (recall) vs. tradução (precisão) vs. similaridade semântica
Prompt injection vs. jailbreaking vs. poisoning	Sobrescrever instruções vs. contornar proteções vs. contaminar dados de treino ou da base
CloudTrail vs. model invocation logging	CloudTrail: quem chamou a API; invocation logging: conteúdo dos prompts e respostas

Afirmações falsas que aparecem como alternativa

- "Fine-tuning é a melhor forma de manter o modelo atualizado com dados que mudam diariamente" — **falso**, use RAG.
- "Aumentar a temperatura reduz alucinações" — **falso**, temperatura alta aumenta a variação.

- "O Amazon Bedrock usa os prompts dos clientes para treinar os modelos base" — **falso**.
- "Acurácia é sempre a melhor métrica" — **falso** com classes desbalanceadas.
- "Treinar um FM do zero é a opção de menor custo" — **falso**, é a mais cara.
- "Guardrails substituem o controle de acesso do IAM" — **falso**, são complementares.
- "IA é sempre a melhor solução para automatizar decisões" — **falso** quando o resultado precisa ser exato ou o custo supera o benefício.
- "Modelos maiores são sempre a melhor escolha" — **falso**: custam mais, têm mais latência e maior impacto ambiental.
- "RAG altera os pesos do modelo" — **falso**, só adiciona contexto.
- "Um agente deve ter acesso amplo a todas as ferramentas para ser útil" — **falso**, aplique menor privilégio e Policy.

13. Mapa de Domínios do Exame

Cada domínio oficial tem um peso diferente na nota final (20/24/28/14/14%). Esta seção cruza os tópicos das seções 1 a 11 com o domínio que eles testam, para priorizar a revisão pelo que realmente pesa na prova.

Domínio 1 — Fundamentals of AI and ML (20%)

Tópico	Onde revisar
Termos básicos, IA vs. ML vs. deep learning vs. GenAI vs. IA agêntica	Seção 1
Tipos de inferência, de dados e de aprendizado	Seção 1
Quando usar e quando não usar IA; regressão, classificação, clustering	Seção 2
Aplicações reais e serviços de IA gerenciados	Seção 2
ML tradicional vs. foundation models	Seção 2
Pipeline de IA/ML, fontes de modelos, uso em produção, serviços por etapa	Seção 3
MLOps e métricas de modelo e de negócio	Seção 3

Domínio 2 — Fundamentals of GenAI (24%)

Tópico	Onde revisar
Tokens, chunking, embeddings, vetores, transformers, FMs, multimodal, difusão	Seção 4
Casos de uso e ciclo de vida de FMs	Seção 4
Preço por tokens e engenharia de contexto	Seção 4
Conceitos de IA agêntica, MCP, padrões multiagente, memória, ferramentas	Seção 5
Vantagens, limitações, seleção de modelos e métricas de negócio	Seção 4
Bedrock, SageMaker AI, JumpStart, Amazon Quick, Kiro, Strands Agents, AgentCore	Seções 5 e 6
Vantagens, benefícios de infraestrutura e trade-offs de custo	Seção 6

Domínio 3 — Applications of Foundation Models (28%)

Tópico	Onde revisar
Critérios de seleção de FMs e parâmetros de inferência	Seção 7
RAG, Bedrock Knowledge Bases e bancos vetoriais	Seção 7
Custos de customização (pré-treino, fine-tuning, in-context, RAG, destilação)	Seção 7
Papel dos agentes e aplicações de negócio	Seções 5 e 7
Elementos, técnicas, boas práticas e riscos de prompts; Prompt Management	Seção 8
Pré-treinamento, fine-tuning, continued pre-training, destilação, preparação de dados, RLHF	Seção 9
Avaliação de FMs e aplicações; ROUGE, BLEU, BERTScore, LLM como juiz; métricas de negócio	Seção 9

Domínio 4 — Guidelines for Responsible AI (14%)

Tópico	Onde revisar
Dimensões da IA responsável e Bedrock Guardrails	Seção 10
Seleção responsável de modelos e sustentabilidade	Seção 10
Riscos legais da IA generativa	Seção 10
Conjuntos de dados, viés e variância, detecção de viés	Seção 10
Transparência, explicabilidade, Model Cards, trade-offs, design centrado no humano	Seção 10

Domínio 5 — Security, Compliance, and Governance for AI Solutions (14%)

Tópico	Onde revisar
IAM, KMS, Macie, PrivateLink, responsabilidade compartilhada, AgentCore Identity, Policy, Guardrails	Seção 11
Citação de fontes, linhagem, catalogação, Model Cards	Seção 11
Engenharia de dados segura e considerações de segurança e privacidade	Seção 11
Detecção de alucinação e grounding	Seções 10 e 11
Config, Inspector, Artifact, CloudTrail, Trusted Advisor	Seção 11
Governança de dados, processos, Generative AI Security Scoping Matrix	Seção 11

Observação sobre o modelo de pontuação

O AIF-C01 usa pontuação **compensatória**: não é preciso atingir a nota mínima em cada domínio separadamente, só na prova como um todo. **Aplicações de foundation models (28%)** e **fundamentos de IA generativa (24%)** somam 52% da nota: as seções 4 a 9 deste guia têm o maior retorno por hora de estudo. Os domínios 4 e 5 (28% juntos) são curtos e muito "decoráveis": revise as seções 10 e 11 na véspera.

14. Autoteste — Flashcards de Revisão Rápida

Cada card abaixo esconde a resposta: clique para expandir só depois de tentar responder mentalmente. O objetivo é forçar recall ativo, não releitura passiva. Uma rodada de 15 a 20 cards por dia nos dias antes da prova cobre todo o banco.

Fundamentos de IA e ML

Qual é a relação entre IA, machine learning, deep learning e IA generativa?

RESPOSTA

São círculos concêntricos: **IA** é o campo amplo; **ML** aprende com dados; **deep learning** é ML com redes neurais profundas; **IA generativa** usa deep learning para criar conteúdo novo. **IA agêntica** é uma arquitetura que usa modelos generativos para planejar e agir.

Qual é a diferença entre algoritmo e modelo?

RESPOSTA

O **algoritmo** é o método de aprendizado; o **modelo** é o resultado do treinamento, com os parâmetros aprendidos, usado para inferência.

O que é inferência?

RESPOSTA

Usar um modelo treinado para fazer previsões ou gerar saídas a partir de dados novos.

Um modelo acerta 99% nos dados de treino e 60% em dados novos. Qual é o problema?

RESPOSTA

Overfitting (variância alta): o modelo decorou o treino e não generaliza.

Um modelo erra muito até nos dados de treino. Qual é o problema?

RESPOSTA

Underfitting (viés alto): o modelo é simples demais para o padrão.

Qual tipo de aprendizado usa dados rotulados?

RESPOSTA

Supervisionado (classificação e regressão).

Qual tipo de aprendizado encontra grupos em dados sem rótulos?

RESPOSTA

Não supervisionado, por exemplo com **clustering**.

Um sistema aprende a jogar recebendo pontos por boas jogadas e penalidades por más. Qual tipo de aprendizado?

RESPOSTA

Aprendizado por reforço.

Cite quatro tipos de dados usados em modelos de IA.

RESPOSTA

Rotulados e não rotulados, tabulares, séries temporais, imagens, texto, estruturados e não estruturados.

Qual tipo de inferência usar para pontuar milhões de registros uma vez por noite?

RESPOSTA

Inferência em lote (batch), como o SageMaker Batch Transform ou a batch inference do Bedrock.

Qual tipo de inferência do SageMaker AI atende a payloads grandes e processamento longo, com resultado entregue no S3?

RESPOSTA

Inferência assíncrona.

Qual tipo de inferência atende a tráfego intermitente sem gerenciar instâncias, aceitando cold start?

RESPOSTA

Inferência serverless.

Casos de uso e serviços de IA

Quando a IA/ML não é a solução adequada?

RESPOSTA

Quando o **custo supera o benefício**, quando é preciso um **resultado exato e determinístico** em vez de uma previsão, quando faltam dados de qualidade ou quando a explicabilidade total é obrigatória e o modelo não a oferece.

Prever o valor de venda de um imóvel é classificação ou regressão?

RESPOSTA

Regressão, porque a saída é um número contínuo.

Identificar se uma transação é fraudulenta é classificação ou regressão?

RESPOSTA

Classificação (binária).

Qual serviço detecta rostos e conteúdo impróprio em imagens?

RESPOSTA

Amazon Rekognition.

Qual serviço extrai formulários e tabelas de documentos digitalizados?

RESPOSTA

Amazon Textract.

Qual serviço identifica sentimento, entidades e PII em textos?

RESPOSTA

Amazon Comprehend.

Transcribe ou Polly: qual converte áudio de chamadas em texto?

RESPOSTA

Amazon Transcribe. O Polly faz o contrário (texto para fala).

Qual serviço cria chatbots baseados em intenções, com a tecnologia da Alexa?

RESPOSTA

Amazon Lex.

Qual serviço gera recomendações personalizadas de produtos?

RESPOSTA

Amazon Personalize.

Quando um modelo de ML tradicional é preferível a um foundation model?

RESPOSTA

Quando a tarefa é uma **previsão específica com dados estruturados**, quando a **regulação exige explicar cada decisão**, ou quando há restrições operacionais de **latência, custo por previsão ou determinismo**.

Qual é a recomendação atual da AWS para busca e perguntas sobre documentos internos, já que o Kendra entrou em manutenção?

RESPOSTA

Amazon Bedrock Knowledge Bases (RAG gerenciado).

Ciclo de vida e MLOps

Coloque em ordem: avaliação, coleta de dados, implantação, engenharia de features, treinamento, objetivo de negócio, monitoramento.

RESPOSTA

Objetivo de negócio → coleta de dados → engenharia de features → treinamento → avaliação → implantação → monitoramento.

O que é análise exploratória de dados (EDA)?

RESPOSTA

Examinar os dados para entender distribuições, correlações, valores faltantes, outliers e desbalanceamento antes de preparar e treinar.

Qual é a diferença entre parâmetro e hiperparâmetro?

RESPOSTA

Parâmetros (pesos) são aprendidos no treino. **Hiperparâmetros** (taxa de aprendizado, épocas) são definidos antes e ajustados em busca da melhor configuração.

Qual recurso do SageMaker oferece ML sem código para analistas de negócio?

RESPOSTA

SageMaker Canvas.

Qual recurso do SageMaker armazena e compartilha features para treino e inferência?

RESPOSTA

SageMaker Feature Store.

Qual recurso do SageMaker é um hub de modelos pré-treinados para implantar com poucos cliques?

RESPOSTA

SageMaker JumpStart.

Quais são as duas formas principais de usar um modelo em produção?

RESPOSTA

API gerenciada (ex.: Amazon Bedrock, menor esforço operacional) ou **API auto-hospedada** (ex.: endpoint do SageMaker AI, EC2 ou EKS, mais controle).

O que é data drift e como tratar?

RESPOSTA

Mudança na distribuição dos dados de entrada em produção, que degrada o modelo. Trata-se com **monitoramento contínuo** e **retreinamento**.

Cite quatro conceitos de MLOps.

RESPOSTA

Experimentação, processos repetíveis, sistemas escaláveis, gestão de dívida técnica, prontidão para produção, monitoramento e retreinamento de modelos.

Por que a acurácia pode enganar em detecção de fraude?

RESPOSTA

Porque as classes são **desbalanceadas**: um modelo que diz "não fraude" sempre teria acurácia altíssima sem detectar nada. Use recall, precisão, F1 ou AUC.

Em diagnóstico de doenças, qual métrica priorizar?

RESPOSTA

Recall, porque não detectar um doente (falso negativo) é o erro mais caro.

Em um filtro que bloqueia e-mails, qual métrica priorizar para não bloquear mensagens legítimas?

RESPOSTA

Precisão, porque o falso positivo é o erro mais caro.

O que é o F1 score?

RESPOSTA

A média harmônica entre precisão e recall; equilibra as duas, útil com classes desbalanceadas.

Cite três métricas de negócio para avaliar um modelo de ML.

RESPOSTA

Custo por usuário, custos de desenvolvimento, feedback dos clientes e ROI.

Fundamentos de IA generativa

O que é um token?

RESPOSTA

A unidade de texto processada pelo modelo (palavra, parte de palavra ou pontuação). Contexto e preço são medidos em tokens.

O que são embeddings?

RESPOSTA

Vetores numéricos que representam o **significado** de textos, imagens ou áudio; conteúdos semelhantes ficam próximos no espaço vetorial.

Para que serve o chunking?

RESPOSTA

Dividir documentos em pedaços menores antes de gerar embeddings, para melhorar a recuperação e caber na janela de contexto.

Qual arquitetura é a base dos LLMs modernos?

RESPOSTA

Transformer, com mecanismo de atenção.

Como funciona um modelo de difusão?

RESPOSTA

Parte de ruído aleatório e o remove passo a passo até gerar a imagem (ou vídeo) descrita.

O que é um foundation model?

RESPOSTA

Um modelo grande pré-treinado em dados amplos, reaproveitável e adaptável a muitas tarefas.

Cite as etapas do ciclo de vida de um FM.

RESPOSTA

Seleção de dados, seleção do modelo, pré-treinamento, fine-tuning, avaliação, implantação e feedback.

Como o preço por tokens afeta custo e desempenho?

RESPOSTA

Mais tokens de entrada e saída aumentam o **custo** e a **latência**. Tokens de saída costumam ser mais caros. Reduz-se com modelos menores, prompts enxutos, limite de saída, prompt caching e batch.

O que é engenharia de contexto?

RESPOSTA

Decidir e montar o que entra na janela de contexto a cada chamada (instruções, histórico, documentos, resultados de ferramentas, memória), tratando o contexto como um recurso limitado e caro.

Cite quatro desvantagens da IA generativa.

RESPOSTA

Alucinações, baixa interpretabilidade, imprecisão e não determinismo (além de viés, custo e latência).

Cite quatro vantagens da IA generativa.

RESPOSTA

Adaptabilidade, responsividade, capacidade conversacional e capacidade de gerar conteúdo.

Cite fatores para escolher um modelo de IA generativa.

RESPOSTA

Tipo de modelo, desempenho, capacidades, restrições, conformidade, custo, latência e complexidade.

IA agêntica

Quais são os componentes de um agente de IA?

RESPOSTA

Um **modelo** que raciocina, **instruções**, **ferramentas** para agir, **memória** (curto e longo prazo) e um **loop de orquestração** (planejar, agir, observar).

O que é o Model Context Protocol (MCP)?

RESPOSTA

Um protocolo aberto que padroniza como agentes e aplicações de IA se conectam a ferramentas, dados e sistemas externos, em arquitetura cliente-servidor.

Qual é a diferença entre MCP e A2A?

RESPOSTA

MCP conecta agentes a **ferramentas e dados**; **A2A** padroniza a comunicação **entre agentes**.

Cite três padrões de sistemas multiagente.

RESPOSTA

Supervisor/orquestrador, agentes como ferramentas, swarm e grafo/workflow.

Qual é a diferença entre memória de curto e de longo prazo em agentes?

RESPOSTA

Curto prazo: contexto da conversa ou tarefa atual. **Longo prazo**: fatos e preferências que persistem entre sessões.

O que é o Amazon Bedrock AgentCore?

RESPOSTA

Plataforma para construir, implantar e operar agentes com segurança e em escala, com qualquer framework e modelo, sem gerenciar infraestrutura (Runtime, Harness, Memory, Gateway, Identity, Policy, Code Interpreter, Browser, Observability, Evaluations).

Qual componente do AgentCore transforma APIs e funções Lambda em ferramentas MCP?

RESPOSTA

AgentCore Gateway.

O que é o Strands Agents?

RESPOSTA

SDK open source da AWS, em Python e TypeScript, para construir agentes com abordagem orientada ao modelo: você define prompt e ferramentas, e o modelo planeja e chama as ferramentas.

O que é o Kiro?

RESPOSTA

A plataforma de **desenvolvimento agêntico** da AWS (IDE, CLI), com desenvolvimento orientado a especificações. Substitui o Amazon Q Developer.

O que aconteceu com o Amazon Bedrock Agents em julho de 2026?

RESPOSTA

Virou **Bedrock Agents Classic** e entrou em **modo de manutenção** (sem novos clientes desde 30/jul/2026). A recomendação é usar o **Bedrock AgentCore** (harness gerenciado ou agentes em código).

Qual serviço usa agentes de IA para modernizar mainframe, .NET e VMware?

RESPOSTA

AWS Transform.

Serviços de IA generativa

O que é o Amazon Bedrock?

RESPOSTA

Serviço serverless que dá acesso por API a foundation models de vários provedores, com Knowledge Bases, Guardrails, avaliação, gerenciamento de prompts e customização.

O Amazon Bedrock usa os prompts e dados dos clientes para treinar os modelos base?

RESPOSTA

Não. Os dados não são usados para treinar os modelos base nem compartilhados com os provedores.

Bedrock ou SageMaker JumpStart: qual implanta o modelo em um endpoint dedicado cobrado por hora de instância?

RESPOSTA

SageMaker JumpStart. O Bedrock on-demand cobra por token, sem instância.

Qual opção de preço do Bedrock dá throughput garantido para carga alta e previsível?

RESPOSTA

Provisioned Throughput.

Qual opção do Bedrock processa grandes volumes sem urgência com preço menor?

RESPOSTA

Batch inference.

Qual modelo Amazon Nova gera imagens? E vídeos?

RESPOSTA

Nova Canvas gera imagens; **Nova Reel** gera vídeos.

Qual modelo Amazon Nova é só texto e tem a menor latência?

RESPOSTA

Nova Micro.

Qual é o sucessor do Amazon Q Business para novos clientes?

RESPOSTA

Amazon Quick, espaço de trabalho de IA agêntica que inclui chat, pesquisa, fluxos, automação e o Quick Sight.

Cite três benefícios da infraestrutura AWS para IA generativa.

RESPOSTA

Segurança (IAM, KMS, PrivateLink, isolamento de dados), conformidade (certificações como ISO/IEC 42001), responsabilidade compartilhada clara e segurança do conteúdo (Guardrails).

Design, RAG e customização

Qual efeito tem uma temperatura baixa?

RESPOSTA

Respostas mais **previsíveis, focadas e consistentes**. Temperatura alta gera respostas mais criativas e variadas.

O que é RAG?

RESPOSTA

Retrieval Augmented Generation: recuperar trechos relevantes de uma base de conhecimento no momento da pergunta e incluí-los no prompt para o modelo responder com base neles.

Coloque em ordem as etapas do RAG: geração, embeddings dos documentos, recuperação, chunking, armazenamento no banco vetorial.

RESPOSTA

Chunking → embeddings dos documentos → armazenamento no banco vetorial → recuperação → geração.

Qual recurso do Bedrock implementa RAG gerenciado?

RESPOSTA

Amazon Bedrock Knowledge Bases.

Cite quatro serviços AWS que armazenam embeddings em banco vetorial.

RESPOSTA

Amazon OpenSearch Service, Amazon Aurora PostgreSQL (pgvector), Amazon RDS for PostgreSQL (pgvector) e Amazon Neptune (também DocumentDB e S3 Vectors).

Ordene do menor para o maior custo: fine-tuning, pré-treinamento do zero, engenharia de prompt, RAG.

RESPOSTA

Engenharia de prompt → RAG → fine-tuning → pré-treinamento do zero.

Um assistente precisa responder com base em políticas internas que mudam toda semana. RAG ou fine-tuning?

RESPOSTA

RAG: basta atualizar a base de conhecimento, sem retreinar.

O modelo precisa sempre responder no formato e tom da marca, e o prompt não resolveu. Qual abordagem?

RESPOSTA

Fine-tuning com exemplos rotulados.

O que é destilação de modelos?

RESPOSTA

Treinar um modelo **aluno** menor para imitar as respostas de um modelo **professor** maior, reduzindo custo e latência de inferência.

Engenharia de prompts

Quais são os elementos de um bom prompt?

RESPOSTA

Instrução, contexto, dados de entrada, formato de saída e, quando útil, exemplos e prompts negativos.

Qual é a diferença entre zero-shot, one-shot e few-shot?

RESPOSTA

Zero-shot: sem exemplos. One-shot: um exemplo. Few-shot: alguns exemplos no prompt.

O que é chain-of-thought?

RESPOSTA

Pedir ao modelo que raciocine passo a passo antes de responder, melhorando tarefas de lógica e várias etapas.

O que é um prompt negativo?

RESPOSTA

Instrução sobre o que o modelo **não** deve fazer ou incluir (ou elementos a evitar em uma imagem gerada).

O que é prompt injection?

RESPOSTA

Texto malicioso que tenta sobrescrever as instruções do sistema, vindo do usuário ou de um documento recuperado.

Qual é a diferença entre jailbreaking e poisoning?

RESPOSTA

Jailbreaking contorna as proteções do modelo com truques no prompt. **Poisoning** contamina os dados de treino ou a base de conhecimento.

Para que serve o Amazon Bedrock Prompt Management?

RESPOSTA

Criar, testar, **versionar** e reutilizar prompts com variáveis e configurações, promovendo versões aprovadas sem mudar o código.

Treinamento e avaliação

Qual é a diferença entre fine-tuning e continued pre-training?

RESPOSTA

Fine-tuning usa dados **rotulados** (prompt-resposta) para uma tarefa. **Continued pre-training** usa grandes volumes **não rotulados** do domínio.

O que é instruction tuning?

RESPOSTA

Fine-tuning com pares de instrução e resposta para o modelo seguir melhor os pedidos.

O que é RLHF?

RESPOSTA

Reinforcement learning from human feedback: humanos avaliam respostas, um modelo de recompensa aprende as preferências e orienta o ajuste do modelo.

Cite cinco cuidados na preparação de dados para fine-tuning.

RESPOSTA

Curadoria, governança, tamanho adequado, rotulagem consistente e representatividade.

Qual métrica avalia a qualidade de resumos?

RESPOSTA

ROUGE.

Qual métrica avalia a qualidade de traduções?

RESPOSTA

BLEU.

Qual métrica compara o significado mesmo com palavras diferentes?

RESPOSTA

BERTScore.

O que é LLM como juiz?

RESPOSTA

Usar um modelo para avaliar as respostas de outro segundo critérios definidos, em escala.

Como avaliar uma aplicação RAG?

RESPOSTA

Avaliar a **recuperação** (trechos corretos?) e a **geração** (resposta fiel ao contexto e relevante?), por exemplo com o Bedrock Model Evaluation.

Cite três métricas de alinhamento com o negócio para aplicações de IA.

RESPOSTA

Taxa de conclusão de tarefas, satisfação do usuário e custo por interação.

IA responsável

Cite seis características da IA responsável citadas no guia.

RESPOSTA

Viés, justiça, inclusão, robustez, segurança e veracidade.

Quais políticas o Amazon Bedrock Guardrails oferece?

RESPOSTA

Filtros de conteúdo (incluindo ataques de prompt), tópicos negados, filtros de palavras, filtros de informações sensíveis (PII), verificação de fundamentação contextual e verificações de raciocínio automatizado.

Qual ferramenta detecta viés e explica previsões de modelos de ML?

RESPOSTA

SageMaker Clarify (em manutenção desde 30/jul/2026).

O que são SageMaker Model Cards?

RESPOSTA

Documentação padronizada do modelo: uso pretendido, dados, métricas, avaliação e riscos, para transparência e governança.

O que é análise por subgrupos?

RESPOSTA

Medir o desempenho do modelo separadamente para cada grupo demográfico, revelando falhas escondidas na média.

Cite três riscos legais da IA generativa.

RESPOSTA

Violação de propriedade intelectual, saídas enviesadas, perda da confiança do cliente, risco ao usuário final e alucinações.

Cite características de um bom conjunto de dados.

RESPOSTA

Inclusivo, diverso, de fontes curadas e balanceado.

Qual é o trade-off entre interpretabilidade e desempenho?

RESPOSTA

Modelos mais interpretáveis (árvores, regressão) costumam ter desempenho menor em tarefas complexas; modelos mais poderosos são menos interpretáveis.

Cite dois princípios de design centrado no humano para IA explicável.

RESPOSTA

Mecanismos de feedback do usuário e transparência das decisões de IA (inclusive supervisão humana em decisões de alto impacto).

Como escolher um modelo de forma sustentável?

RESPOSTA

Usar o menor modelo que atende, reaproveitar modelos pré-treinados e usar hardware eficiente como Trainium e Inferentia.

Segurança, conformidade e governança

Como acessar o Amazon Bedrock sem passar pela internet pública?

RESPOSTA

Com **AWS PrivateLink** (interface VPC endpoint).

Qual serviço descobre PII em dados de treino armazenados no S3?

RESPOSTA

Amazon Macie.

Qual é a responsabilidade do cliente ao usar o Bedrock?

RESPOSTA

Controlar o acesso (IAM), os dados que envia, os guardrails, a criptografia com suas chaves, como a aplicação usa as respostas e a conformidade do caso de uso. A AWS protege a infraestrutura e o serviço.

Para que serve o Policy in AgentCore?

RESPOSTA

Definir regras determinísticas sobre quais ferramentas e ações um agente pode usar e em quais condições, interceptando cada chamada de ferramenta.

Como registrar os prompts e respostas de um modelo no Bedrock?

RESPOSTA

Com o **model invocation logging**, que envia os registros ao CloudWatch Logs ou ao S3. O CloudTrail registra as chamadas de API.

Cite três técnicas para detectar alucinações ou fundamentar respostas.

RESPOSTA

Grounding com RAG e citações, validação da saída (inclusive contextual grounding check) e pontuação de confiança.

O que é linhagem de dados?

RESPOSTA

O rastreamento da origem e das transformações dos dados até o modelo, essencial para auditoria.

Cite tecnologias de preservação de privacidade.

RESPOSTA

Anonimização, mascaramento, tokenização, privacidade diferencial e dados sintéticos.

Onde obter o relatório ISO/IEC 42001 da AWS?

RESPOSTA

No **AWS Artifact**.

Cite cinco estratégias de governança de dados do guia.

RESPOSTA

Ciclo de vida dos dados, logs, residência, monitoramento/observação e retenção.

Quais são os cinco escopos da Generative AI Security Scoping Matrix?

RESPOSTA

1 — aplicação para consumidor; 2 — aplicação corporativa; 3 — modelos pré-treinados; 4 — modelos ajustados (fine-tuned); 5 — modelos treinados pela própria empresa.

Pegadinhas Duplas (confusões mais recorrentes)

RAG, fine-tuning ou prompt: qual responde "dados de ontem", "tom da marca" e "menor custo para começar"?

RESPOSTA

Dados de ontem → **RAG**. Tom da marca → **fine-tuning**. Menor custo para começar → **engenharia de prompt**.

Guardrails, IAM ou Macie: qual responde "bloquear um tópico", "quem pode invocar o modelo" e "PII nos dados de treino do S3"?

RESPOSTA

Bloquear tópico → **Guardrails**. Quem pode invocar → **IAM**. PII no S3 → **Macie**.

ROUGE, BLEU ou BERTScore: qual responde "resumo", "tradução" e "mesmo significado com outras palavras"?

RESPOSTA

Resumo → **ROUGE**. Tradução → **BLEU**. Mesmo significado → **BERTScore**.

Precisão ou recall: qual priorizar para "não deixar fraude passar" e "não bloquear cliente bom"?

RESPOSTA

Não deixar fraude passar → **recall**. Não bloquear cliente bom → **precisão**.

Strands Agents, AgentCore ou Kiro: qual responde "escrever o agente em Python", "executar o agente em produção" e "IDE com IA para desenvolver"?

RESPOSTA

Escrever o agente → **Strands Agents**. Executar em produção → **AgentCore**. IDE com IA → **Kiro**.

15. Mapa de cobertura do guia oficial e questões de múltipla resposta

O [guia oficial do AIF-C01](#) divide a prova em **14 tarefas**. A tabela localiza a revisão de cada tarefa neste material. Cobrir as tarefas publicadas **não garante** conhecer todas as questões: o guia não é uma lista exaustiva, e a [lista de serviços no escopo](#) está sujeita a alterações. O [histórico de revisões](#) mostra o que mudou na versão 1.1.

Tarefa oficial	Decisões e conceitos a dominar	Onde revisar
1.1 Conceitos e terminologia de IA	Termos básicos, IA vs. ML vs. GenAI vs. agêntica, tipos de inferência, dados e aprendizado	Seção 1
1.2 Casos de uso práticos	Quando usar ou não IA, regressão/classificação/clustering, aplicações, serviços gerenciados, ML tradicional vs. FM	Seção 2
1.3 Ciclo de vida de IA/ML	Pipeline, fontes de modelos, uso em produção, serviços por etapa, MLOps, métricas	Seção 3
2.1 Conceitos de GenAI	Tokens, chunking, embeddings, transformers, difusão, casos de uso, ciclo do FM, preço por tokens, engenharia de contexto, IA agêntica e MCP	Seções 4 e 5
2.2 Capacidades e limitações	Vantagens, desvantagens, seleção de modelos, valor e métricas de negócio	Seção 4
2.3 Infraestrutura e tecnologias AWS	Bedrock, SageMaker AI, JumpStart, Quick, Kiro, Strands Agents, AgentCore; vantagens, benefícios e trade-offs de custo	Seções 5 e 6
3.1 Design de aplicações com FMs	Critérios de seleção, parâmetros de inferência, RAG, bancos vetoriais, custos de customização, agentes	Seções 5 e 7
3.2 Engenharia de prompts	Elementos, técnicas, boas práticas, riscos, Prompt Management	Seção 8
3.3 Treinamento e fine-tuning	Pré-treinamento, fine-tuning, continued pre-training, destilação, preparação de dados, RLHF	Seção 9
3.4 Avaliação de FMs	Humano no loop, benchmarks, Bedrock Model Evaluation, ROUGE/BLEU/BERTScore/LLM como juiz, avaliação de RAG e agentes, métricas de negócio	Seção 9
4.1 Sistemas de IA responsáveis	Dimensões, Guardrails, seleção sustentável, riscos legais, datasets, viés e variância, detecção de viés	Seção 10
4.2 Transparência e explicabilidade	Modelos transparentes vs. caixa-preta, Model Cards, trade-offs, design centrado no humano	Seção 10
5.1 Proteger sistemas de IA	IAM, KMS, Macie, PrivateLink, responsabilidade compartilhada, AgentCore Identity e Policy, Guardrails, linhagem, dados seguros, alucinação e grounding	Seção 11
5.2 Governança e conformidade	Config, Inspector, Artifact, CloudTrail, Trusted Advisor, governança de dados, processos, Scoping Matrix	Seção 11

Como resolver múltipla resposta, ordenação e correspondência

O AIF-C01 tem quatro formatos: **múltipla escolha**, **múltipla resposta** (marque exatamente a quantidade pedida), **ordenação** (3 a 5 itens na sequência correta) e **correspondência** (associar 3 a 7 pares). Nenhum formato dá crédito parcial. Nas questões abaixo, responda antes de abrir a solução.

1. Uma empresa quer que o assistente responda com base em manuais internos atualizados diariamente e cite as fontes. Escolha DUAS: (A) usar Bedrock Knowledge Bases; (B) fazer fine-tuning diário do modelo; (C) armazenar embeddings em um banco vetorial como OpenSearch Service; (D) aumentar a temperatura; (E) pré-treinar um modelo do zero.

RESPOSTA

A e C. RAG com Knowledge Bases e um banco vetorial traz dados atuais com citações. Fine-tuning diário e pré-treino são caros e lentos; temperatura alta aumenta a variação. Revise a seção 7.

2. Quais medidas reduzem alucinações? Escolha DUAS: (A) fundamentar respostas com RAG e citações; (B) usar a verificação de fundamentação contextual do Guardrails; (C) aumentar a temperatura para 1; (D) remover o system prompt; (E) aumentar o tamanho máximo da resposta.

RESPOSTA

A e B. Grounding e validação da saída reduzem respostas inventadas. As outras opções não ajudam ou pioram. Revise as seções 10 e 11.

3. Um banco usa um FM no Bedrock e precisa impedir conselhos de investimento e mascarar CPFs nas respostas. Escolha DUAS configurações do Guardrails: (A) tópicos negados; (B) filtro de informações sensíveis; (C) política do IAM; (D) chave do KMS; (E) Amazon Macie.

RESPOSTA

A e B. Tópicos negados bloqueiam o assunto e o filtro de informações sensíveis mascara PII. IAM, KMS e Macie têm outras funções. Revise a seção 10.

4. Uma empresa precisa usar o Bedrock com dados confidenciais. Escolha DUAS medidas de segurança: (A) acessar via AWS PrivateLink; (B) aplicar políticas do IAM com menor privilégio; (C) tornar o bucket de dados público; (D) colocar credenciais no prompt; (E) desativar o CloudTrail.

RESPOSTA

A e B. Tráfego privado e acesso mínimo. As demais aumentam o risco. Revise a seção 11.

5. Quais são limitações da IA generativa? Escolha DUAS: (A) alucinações; (B) não determinismo; (C) incapacidade de processar linguagem natural; (D) exigência de dados rotulados para qualquer uso; (E) impossibilidade de gerar código.

RESPOSTA

A e B. C, D e E são falsas: FMs processam linguagem, funcionam sem rótulos via prompt e geram código. Revise a seção 4.

6. Um time quer construir e operar agentes em produção na AWS. Escolha DUAS: (A) escrever o agente com Strands Agents; (B) executá-lo no Amazon Bedrock AgentCore Runtime; (C) usar Amazon Polly para orquestrar ferramentas; (D) criar um novo agente no Bedrock Agents Classic em uma conta nova; (E) treinar um FM do zero para cada agente.

RESPOSTA

A e B. Strands é o SDK e AgentCore a plataforma de execução. Polly é voz, Agents Classic não aceita contas novas desde 30/jul/2026, e treinar do zero é desnecessário. Revise a seção 5.

7. Quais são características de um conjunto de dados que reduz viés? Escolha TRÊS: (A) inclusivo; (B) balanceado; (C) de fontes curadas; (D) com um único grupo demográfico; (E) sem revisão de rótulos; (F) o maior possível, sem curadoria.

RESPOSTA

A, B e C. Diversidade, equilíbrio e curadoria reduzem viés. D, E e F o aumentam. Revise a seção 10.

8. ORDENAÇÃO — Coloque as etapas do pipeline de ML na ordem: (1) implantação; (2) coleta de dados; (3) treinamento; (4) definição do objetivo de negócio; (5) avaliação.

RESPOSTA

4 → 2 → 3 → 5 → 1: objetivo de negócio, coleta de dados, treinamento, avaliação e implantação. Revise a seção 3.

9. ORDENAÇÃO — Ordene as abordagens de customização da mais barata para a mais cara: (1) fine-tuning; (2) engenharia de prompt; (3) pré-treinamento do zero; (4) RAG.

RESPOSTA

2 → 4 → 1 → 3: prompt, RAG, fine-tuning e pré-treinamento do zero. Revise a seção 7.

10. CORRESPONDÊNCIA — Associe cada tarefa ao serviço: (a) extrair tabelas de notas fiscais; (b) transcrever chamadas; (c) analisar sentimento de avaliações; (d) detectar rostos em fotos. Serviços: Rekognition, Comprehend, Textract, Transcribe.

RESPOSTA

(a) **Textract**; (b) **Transcribe**; (c) **Comprehend**; (d) **Rekognition**. Revise a seção 2.

11. CORRESPONDÊNCIA — Associe cada métrica à tarefa: (a) ROUGE; (b) BLEU; (c) recall; (d) BERTScore. Tarefas: tradução, resumo, similaridade semântica, não deixar passar casos positivos.

RESPOSTA

(a) **Resumo**; (b) **tradução**; (c) **não deixar passar casos positivos**; (d) **similaridade semântica**. Revise as seções 3 e 9.

12. CORRESPONDÊNCIA — Associe cada escopo da Generative AI Security Scoping Matrix ao exemplo: (a) escopo 1; (b) escopo 3; (c) escopo 4; (d) escopo 5. Exemplos: treinar um FM do zero; funcionário usando chatbot público; aplicação sobre FM via Bedrock; FM ajustado com dados da empresa.

RESPOSTA

(a) **Chatbot público**; (b) **aplicação sobre FM via Bedrock**; (c) **FM ajustado com dados da empresa**; (d) **treinar um FM do zero**. Revise a seção 11.

Síntese de revisão

Este guia organiza a revisão pelos quatro domínios do exame e reúne formatos de consulta rápida e prática ativa.

- Os pesos oficiais são 20% para fundamentos de IA e ML, 24% para fundamentos de IA generativa, 28% para aplicações de foundation models, 14% para IA responsável e 14% para segurança, conformidade e governança.
- As tabelas de decisão rápida ao fim de cada capítulo e os padrões recorrentes (seção 12) concentram as palavras-chave e os pares de conceitos e serviços que mais se confundem.
- O mapa de domínios (seção 13) orienta prioridades; serviços, nomes e disponibilidade foram conferidos em setembro de 2026, após a revisão 1.1 do guia e as mudanças de julho de 2026.
- O autoteste e as questões de múltipla resposta, ordenação e correspondência (seções 14 e 15) oferecem 133 perguntas para revisão ativa.
- O mapa da seção 15 relaciona as 14 tarefas publicadas no guia oficial às seções correspondentes.