

KUBERNETES

ARQUITETURA • WORKLOADS • OPERAÇÃO

Do Pod à produção

Da arquitetura do cluster ao Helm: Pods, Deployments, volumes, Services, Ingress e Gateway API, autoescalonamento, agendamento, políticas, Network Policies e RBAC, com tabelas de decisão, pegadinhas e flashcards. Conferido com o Kubernetes 1.37.

CINCO BLOCOS DO GUIA

01

Fundamentos
Capítulos 1 a 3

02

Workloads e cluster
Capítulos 4 a 7

03

Dados, rede e
configuração
Capítulos 8 a 12

04

Operação e segurança
Capítulos 13 a 17

05

Helm e revisão
Capítulos 18 a 21

Sumário

COMO USAR ESTE GUIA

Versões e atualizações	6	Mapa do guia	7
Método para investigar problemas no cluster	6		

CAPÍTULO 1 – CONTÊINERES, RUNTIMES E O PADRÃO OCI

1.1	Engine, runtime e as camadas por baixo do contêiner	8	1.2.1	OCI: o formato comum	9
1.1.1	Container engine	8	1.2.2	CRI: como o kubelet fala com o runtime	9
1.1.2	Níveis de runtime	8	1.2.3	Do kubelet ao processo	9
1.2	Os padrões OCI e CRI	9	1.3	Decisão rápida — Runtimes	10

CAPÍTULO 2 – KUBERNETES: ORIGEM E ARQUITETURA

2.1	De onde veio o Kubernetes	11	2.2.6	Alta disponibilidade	13
2.1.1	Borg, Omega e Kubernetes	11	2.3	Portas usadas pelo cluster	13
2.1.2	O que o Kubernetes faz (e o que não faz)	11	2.3.1	Control plane	13
2.2	Arquitetura do cluster	12	2.3.2	Nós de trabalho	13
2.2.1	Control plane e nós	12	2.4	Objetos e conceitos-chave	14
2.2.2	Componentes do control plane	12	2.4.1	Principais objetos	14
2.2.3	Componentes de cada nó	12	2.4.2	Anatomia de um manifesto	14
2.2.4	Add-ons essenciais	12	2.5	Decisão rápida — Arquitetura	14
2.2.5	O que acontece quando você cria um Deployment	12			

CAPÍTULO 3 – KUBECTL E CLUSTERS LOCAIS

3.1	Instalar o kubectl	16	3.4	Primeiros comandos	19
3.1.1	Linux, macOS e Windows	16	3.4.1	Explorar o cluster	19
3.2	Configurar o kubectl	16	3.4.2	Primeiro Pod e primeiro Service	20
3.2.1	Kubeconfig e contextos	16	3.4.3	Imperativo e declarativo	20
3.2.2	Autocompletar e alias	17	3.4.4	Formatos de saída e seletores	20
3.3	Clusters locais e distribuições	17	3.5	Labels, seletores e annotations	21
3.3.1	Opções para estudar e para produção	17	3.5.1	Labels	21
3.3.2	kind	18	3.5.2	Annotations	21
3.3.3	Minikube	19	3.6	Decisão rápida — kubectl e clusters locais	21

CAPÍTULO 4 – PODS

4.1	O que é um Pod	23	4.4	Interagir com um Pod em execução	25
4.1.1	Características	23	4.4.1	exec, attach, port-forward, cp e debug	25
4.2	Criar e inspecionar Pods	23	4.5	Ciclo de vida do Pod	26
4.2.1	Manifesto comentado	23	4.5.1	Fases e estados	26
4.2.2	apply, create e replace	24	4.6	Recursos: requests e limits	27
4.2.3	Logs	24	4.6.1	Como funcionam	27
4.3	Pods com vários contêineres	24	4.6.2	Classes de QoS	27
4.3.1	Padrões de uso	24	4.6.3	Testar os limites e ajustar sem recriar	28

4.7	Volume emptyDir	28	4.8	Decisão rápida — Pods	29
4.7.1	Como funciona	28			

CAPÍTULO 5 – DEPLOYMENTS E REPLICASETS

5.1	Deployment, ReplicaSet e Pod	30	5.3.1	RollingUpdate e Recreate	32
5.1.1	A hierarquia	30	5.4	Rollout e rollback	33
5.1.2	Manifesto comentado	31	5.4.1	Acompanhar, pausar, voltar	33
5.2	Criar, inspecionar e escalar	32	5.5	ReplicaSet diretamente	33
5.2.1	Comandos do dia a dia	32	5.5.1	Quando e por que não	33
5.3	Estratégias de atualização	32	5.6	Decisão rápida — Deployments	34

CAPÍTULO 6 – DAEMONSETS E PROBES

6.1	DaemonSet	35	6.2.2	Mecanismos de teste	37
6.1.1	Para que serve	35	6.2.3	Parâmetros	38
6.1.2	Comandos e atualização	37	6.2.4	Exemplo completo	38
6.2	Probes	37	6.2.5	Boas práticas e armadilhas	38
6.2.1	Os três tipos	37	6.3	Decisão rápida — DaemonSets e probes	39

CAPÍTULO 7 – INSTALANDO UM CLUSTER COM KUBEADM

7.1	Formas de ter um cluster	40	7.3.1	kubeadm init e kubeadm join	42
7.1.1	Comparação	40	7.3.2	Kubeconfig do administrador	43
7.2	Preparar os nós	40	7.3.3	Escolher o CNI	43
7.2.1	Requisitos	40	7.4	Operar o cluster	43
7.2.2	Módulos do kernel, sysctl e runtime	41	7.4.1	Manutenção do dia a dia	43
7.2.3	Pacotes do Kubernetes	41	7.5	Decisão rápida — Instalação	44
7.3	Criar o cluster	42			

CAPÍTULO 8 – VOLUMES E ARMAZENAMENTO PERSISTENTE

8.1	Tipos de volume	45	8.3.1	Vínculo estático (PV criado à mão)	46
8.1.1	Efêmeros e persistentes	45	8.3.2	Vínculo dinâmico (o caso comum)	47
8.2	StorageClass	45	8.3.3	Modos de acesso	47
8.2.1	O que define	45	8.3.4	Estados e ciclo de vida	47
8.3	PersistentVolume e PersistentVolumeClaim	46	8.4	Decisão rápida — Armazenamento	48

CAPÍTULO 9 – SERVICES, ENDPOINTS e DNS

9.1	Como um Service funciona	49	9.2.2	Opções úteis	50
9.1.1	Seletores, EndpointSlices e kube-proxy	49	9.3	DNS dentro do cluster	51
9.1.2	Portas	49	9.3.1	Nomes	51
9.2	Tipos de Service	50	9.4	Decisão rápida — Services	51
9.2.1	Visão geral	50			

CAPÍTULO 10 – STATEFULSETS

10.1	Garantias do StatefulSet	52	10.3	Escala, atualização e remoção	54
10.1.1	Deployment × StatefulSet	52	10.3.1	Comportamentos	54
10.2	Criar um StatefulSet	53	10.4	Decisão rápida — StatefulSets	54
10.2.1	Service headless e StatefulSet	53			

CAPÍTULO 11 – CONFIGMAPS E SECRETS

11.1	ConfigMaps	55	11.2.2	Tipos	56
11.1.1	Criar	55	11.2.3	Exemplo: nginx com HTTPS	57
11.1.2	Consumir no Pod	56	11.3	Segredos em cofres externos	58
11.2	Secrets	56	11.3.1	External Secrets Operator	58
11.2.1	Base64 não é criptografia	56	11.4	Decisão rápida – Configuração e segredos	59

CAPÍTULO 12 – INGRESS, GATEWAY API E CERTIFICADOS

12.1	Ingress	61	12.2.1	Modelo	62
12.1.1	Componentes	61	12.3	Certificados com cert-manager	63
12.1.2	ingress-nginx aposentado	62	12.3.1	Como funciona	63
12.2	Gateway API	62	12.4	Decisão rápida – Entrada de tráfego	64

CAPÍTULO 13 – METRICS SERVER E AUTOESCALONAMENTO

13.1	Metrics Server	66	13.2.2	Algoritmo	67
13.1.1	Instalação e uso	66	13.2.3	Teste de carga	68
13.2	HorizontalPodAutoscaler	67	13.2.4	Outros escaladores	68
13.2.1	Manifesto	67	13.3	Decisão rápida – Autoescalamento	68

CAPÍTULO 14 – AGENDAMENTO: TAINTS, TOLERATIONS E AFINIDADE

14.1	Labels nos nós	70	14.3	Afinidade e antiafinidade	71
14.1.1	Organizar o cluster	70	14.3.1	nodeAffinity	71
14.2	Taints e tolerations	70	14.3.2	podAffinity, podAntiAffinity e distribuição	72
14.2.1	Efeitos	70	14.3.3	Prioridade e disrupções	72
			14.4	Decisão rápida – Agendamento	72

CAPÍTULO 15 – POLÍTICAS E CONTROLE DE ADMISSÃO

15.1	O caminho de um pedido	74	15.3.1	Regras em CEL, sem webhook	75
15.1.1	Etapas	74	15.4	Kyverno	75
15.2	Pod Security Admission	74	15.4.1	O que faz	75
15.2.1	Padrões por namespace	74	15.4.2	Tipos de política	76
15.3	ValidatingAdmissionPolicy	75	15.5	Decisão rápida – Políticas	77

CAPÍTULO 16 – NETWORK POLICIES

16.1	Como funcionam	79	16.2.1	Negar tudo e liberar o necessário	80
16.1.1	Regras fundamentais	79	16.2.2	Testar	81
16.1.2	Seletores: E e OU	79	16.3	Decisão rápida – Network Policies	81
16.2	Receitas	80			

CAPÍTULO 17 – RBAC E CONTROLE DE ACESSO

17.1	Identities	83	17.2	Roles e bindings	84
17.1.1	Usuários, grupos e ServiceAccounts	83	17.2.1	Anatomia de uma regra	84
17.1.2	Criar um usuário com certificado	84	17.2.2	Cuidados de segurança	86
17.1.3	ServiceAccounts e tokens	84	17.3	Decisão rápida – RBAC	86

CAPÍTULO 18 – HELM

18.1	Instalar e usar charts	87	18.2.1	Estrutura	88
18.1.1	Instalação	87	18.2.2	Templates	89
18.1.2	Comandos do dia a dia	87	18.2.3	Validar e publicar	90
18.2	Criar um chart	88	18.3	Decisão rápida — Helm	90

CAPÍTULO 19 – PEGADINHAS E INFORMAÇÕES DESATUALIZADAS

19.1	Afirmções falsas clássicas	92	19.3	Pares que mais se confundem	94
19.2	Informações desatualizadas em materiais antigos	93			

CAPÍTULO 20 – REFERÊNCIA RÁPIDA DE COMANDOS

20.1	Contexto, descoberta e diagnóstico	96	20.3	Rollouts, nós e autoescalonamento	97
20.2	Criar e alterar	96	20.4	Ferramentas do ecossistema	97

CAPÍTULO 21 – AUTOTESTE – FLASHCARDS DE REVISÃO

21.1	Runtimes e arquitetura	98	21.6	Cluster, armazenamento e Services	104
21.2	kubectl e primeiros passos	99	21.7	Configuração, entrada de tráfego e certificados	105
21.3	Pods	100	21.8	Autoescalonamento, agendamento e políticas	107
21.4	Deployments, ReplicaSets e DaemonSets	102	21.9	Network Policies, RBAC e Helm	108
21.5	Probes	103			

Como usar este guia

- Os capítulos seguem o caminho de quem está aprendendo Kubernetes: primeiro os contêineres e os runtimes por baixo do cluster, depois a arquitetura, o `kubectl` e os clusters locais, e então os objetos, começando pelo Pod.
- Cada capítulo de conteúdo termina com uma tabela de **Decisão rápida**: situações típicas, a abordagem recomendada e o erro mais comum.
- Os manifestos YAML e os comandos podem ser executados em um cluster local (kind ou Minikube, capítulo 3). Onde o resultado depende da versão do cluster, o guia indica.
- O capítulo **Pegadinhas e informações desatualizadas** reúne os erros de conceito mais frequentes e o que mudou em relação a cursos e tutoriais mais antigos.
- O **Autoteste**, no fim, tem flashcards que escondem a resposta até você clicar.

Versões e atualizações

Os comportamentos deste guia foram conferidos na documentação oficial (kubernetes.io) em **setembro de 2026**. Nessa data, a versão mais recente era o **Kubernetes 1.37**, e as versões com suporte eram **1.35, 1.36 e 1.37**.

Item	Situação em set/2026
Ritmo de lançamentos	Cerca de 3 versões menores por ano (uma a cada ~4 meses)
Suporte de cada versão menor	Cerca de 1 ano de correções; o projeto mantém as 3 versões mais recentes
Diferença de versão do <code>kubectl</code>	O <code>kubectl</code> pode estar uma versão menor acima ou abaixo do cluster (um <code>kubectl</code> 1.37 fala com clusters 1.36, 1.37 e 1.38)
Docker Engine como runtime	O dockershim foi removido na 1.24 (2022). Os nós usam containerd ou CRI-O; o Docker só com o adaptador <code>cri-dockerd</code> . Imagens criadas com Docker continuam funcionando
Sidecars nativos	Estáveis desde a 1.33 : <code>init containers</code> com <code>restartPolicy: Always</code>
Redimensionar CPU e memória de um Pod em execução	Estável desde a 1.35 (<i>in-place resize</i>)
Recursos declarados no nível do Pod	Beta na 1.37 (<code>PodLevelResources</code>)
Modo padrão do kube-proxy	<code>iptables</code> ; o <code>nftables</code> está disponível e deve virar o padrão em uma versão futura

Materiais publicados antes de 2024 costumam mostrar saídas com `docker://` nos IDs de contêiner, clusters 1.24 ou anteriores e versões antigas do kind e do Minikube. Os conceitos continuam valendo; os detalhes, nem sempre.

Método para investigar problemas no cluster

- 1. Olhe o estado real:** `kubectl get` mostra o resumo; `kubectl describe` mostra a configuração e, no fim, os **eventos**, que quase sempre explicam o problema (imagem que não baixa, falta de recursos, falha de probe).
- 2. Leia os logs do contêiner**, e os da execução anterior se ele reiniciou: `kubectl logs <pod> --previous`.
- 3. Suba na hierarquia:** um Pod é criado por um ReplicaSet, que é criado por um Deployment. Se o Pod está certo mas não é recriado, o problema está no controlador acima dele.
- 4. Compare o desejado com o observado:** o Kubernetes é declarativo. A pergunta é sempre "o que eu pedi (`spec`) e o que o cluster conseguiu (`status`)?".

5. Não conserte o Pod à mão: Pods são descartáveis. A correção vai no manifesto, que é reaplicado.

Mapa do guia

Bloco	Capítu- los	O que você deve dominar ao final
Fundamentos	1 a 3	Engine, runtime, OCI e CRI; arquitetura do cluster; <code>kubectl</code> , <code>kubeconfig</code> e clusters locais
Workloads e cluster	4 a 7	Pods, recursos e probes; Deployments, ReplicaSets e DaemonSets; instalar um cluster com <code>kubeadm</code>
Dados, rede e configuração	8 a 12	Volumes e StorageClasses; Services e DNS; StatefulSets; ConfigMaps, Secrets e cofres externos; Ingress, Gateway API e cert-manager
Operação e segurança	13 a 17	Metrics Server e HPA; taints, tolerations e afinidade; políticas de admissão e Kyverno; Network Policies; RBAC
Pacotes e revisão	18 a 21	Helm; pegadinhas e informações desatualizadas; referência de comandos; flashcards

Contêineres, Runtimes e o Padrão OCI

Ideia central: o Kubernetes **não executa contêineres sozinho**. Em cada nó, o **kubelet** pede a um **container runtime** (containerd ou CRI-O) que crie os contêineres, por meio de uma interface padronizada, a **CRI**. O runtime, por sua vez, usa um executor de baixo nível (runc ou crun) que segue o padrão **OCI**. Entender essas camadas explica boa parte das mensagens de erro e das mudanças recentes do ecossistema.

1.1 Engine, runtime e as camadas por baixo do contêiner

1.1.1 Container engine

Um **container engine** é a ferramenta completa que o usuário opera: baixa e constrói imagens, cria redes e volumes, oferece uma CLI e uma API e, no fim, pede a um runtime que execute o contêiner.

Ferramenta	O que é	Observação
Docker Engine	Engine completo (CLI, API, build, redes, volumes)	Usa o containerd como runtime e o runc como executor
Podman	Engine sem daemon, rootless por padrão, CLI compatível com a do Docker	Usa o conmon para supervisionar e o crun ou o runc para executar
nerdctl	CLI no estilo Docker para usar o containerd diretamente	Útil para depurar nós que só têm containerd
CRI-O	Runtime feito sob medida para o Kubernetes	Não é um engine de uso geral: não tem comando para o usuário construir imagens nem gerenciar contêineres fora do cluster

- Em um nó Kubernetes **não é preciso ter o Docker**. O kubelet fala direto com o runtime, e as ferramentas de inspeção do nó são o `crictl` (para qualquer runtime CRI) ou o `nerdctl`.

1.1.2 Níveis de runtime

Nível	O que faz	Exemplos
Baixo nível (OCI runtime)	Recebe um diretório com o sistema de arquivos e um <code>config.json</code> , cria namespaces e cgroups e inicia o processo. Não sabe baixar imagens	runc (referência da OCI, em Go), crun (em C, mais leve e rápido), youki (em Rust)
Alto nível (CRI runtime)	Baixa e armazena imagens, prepara o sistema de arquivos, gerencia o ciclo de vida dos contêineres e chama o runtime de baixo nível	containerd , CRI-O
Sandbox	Coloca uma camada entre o contêiner e o kernel do host, interceptando as chamadas de sistema	gVisor (<code>runsc</code>), que implementa um "kernel" em espaço de usuário
Virtualizado	Roda cada Pod dentro de uma microVM com kernel próprio	Kata Containers , Firecracker (via Kata)

- Runtimes sandbox e virtualizados trocam um pouco de desempenho por **isolamento mais forte**, útil para código não confiável e ambientes multi-tenant. No Kubernetes, eles são escolhidos por Pod com uma **RuntimeClass** (`spec.runtimeClassName`).

1.2 Os padrões OCI e CRI

1.2.1 OCI: o formato comum

A **Open Container Initiative** foi criada em **2015**, sob a Linux Foundation, com a participação de Docker, CoreOS, Google, IBM, Microsoft, Red Hat, VMware e outras empresas. Ela mantém três especificações:

Especificação	Define	Por que importa
Image spec	Formato da imagem (manifest, config, camadas)	Uma imagem criada com Docker, Podman ou BuildKit roda em qualquer runtime compatível
Runtime spec	Como executar um contêiner a partir de um bundle	Permite trocar runc por crun, gVisor ou Kata sem mudar a imagem
Distribution spec	API de registries	Docker Hub, GHCR, ECR, Harbor falam a mesma língua

- O **runc** nasceu da biblioteca libcontainer, que o Docker doou à OCI, e é o runtime de referência da especificação.

1.2.2 CRI: como o kubelet fala com o runtime

- A **Container Runtime Interface** é uma API gRPC definida pelo Kubernetes. O kubelet chama operações como "crie o sandbox do Pod", "baixe a imagem", "inicie o contêiner", e o runtime responde. Qualquer runtime que implemente a CRI v1 serve.
- Dockershim**: o Docker Engine não implementa a CRI. Por anos o kubelet carregou um adaptador interno para ele, o dockershim, que foi **removido na versão 1.24**. Quem ainda quer Docker Engine nos nós usa o adaptador externo **cri-dockerd** (mantido pela Mirantis). A grande maioria dos clusters usa containerd ou CRI-O.

Runtime	Socket CRI padrão
containerd	unix:///run/containerd/containerd.sock
CRI-O	unix:///run/crio/crio.sock
Docker Engine + cri-dockerd	unix:///run/cri-dockerd.sock

1.2.3 Do kubelet ao processo

- O **kubelet** recebe um Pod designado ao seu nó.
 - Chama o runtime pela **CRI** para criar o **sandbox do Pod** (o namespace de rede compartilhado, mantido pelo contêiner "pause").
 - O **plugin CNI** configura a interface de rede e o IP do Pod.
 - O runtime **baixa as imagens** (se necessário) e prepara o sistema de arquivos de cada contêiner.
 - O runtime chama o **runc** (ou outro OCI runtime), que cria namespaces e cgroups e inicia o processo.
 - O kubelet acompanha o estado dos contêineres e o reporta ao API server.
- Driver de cgroup**: o kubelet e o runtime precisam usar o **mesmo** driver. Em distribuições com systemd e cgroup v2, o recomendado é `systemd`. Driver diferente entre os dois é uma causa clássica de nós instáveis em clusters montados à mão.

1.3 Decisão rápida — Runtimes

Situação	Abordagem recomendada	Erro comum
Escolher o runtime de um cluster novo	containerd ou CRI-O	Instalar Docker Engine nos nós "porque sempre foi assim"
Inspecionar contêineres em um nó sem Docker	<code>crictl ps</code> , <code>crictl logs</code> , <code>crictl images</code>	Procurar o comando <code>docker</code> no nó
Imagens criadas com Docker vão rodar no cluster?	Sim: seguem o padrão OCI	Reescrever Dockerfiles por causa da remoção do dockershim
Rodar código não confiável com isolamento forte	RuntimeClass com gVisor ou Kata Containers	Confiar só no isolamento padrão do runc
Nó com Pods reiniciando sem motivo aparente em cluster montado à mão	Conferir se kubelet e runtime usam o mesmo driver de cgroup (<code>systemd</code>)	Reinstalar o cluster inteiro

Kubernetes: Origem e Arquitetura

Ideia central: o Kubernetes é um sistema **declarativo**. Você descreve o estado desejado (três réplicas desta imagem, expostas nesta porta), o **API server** guarda essa descrição no **etcd**, e vários **controladores** trabalham em laços contínuos para aproximar o estado real do desejado. Todo o resto (scheduler, kubelet, kube-proxy) são peças desse ciclo.

2.1 De onde veio o Kubernetes

2.1.1 Borg, Omega e Kubernetes

- O Google executa praticamente tudo em contêineres há mais de duas décadas. Para isso, criou três sistemas de gerenciamento de clusters:

Sistema	Contexto	Legado
Borg	Primeiro sistema, interno. Unificou serviços de longa duração e jobs em lote, antes tratados por sistemas separados	Continua sendo o principal gerenciador interno do Google
Omega	Sucessor interno, com arquitetura mais consistente e estado central compartilhado	Muitas ideias voltaram para o Borg
Kubernetes	Criado em 2014 , já como open source , com foco na experiência de quem desenvolve e opera aplicações	Doado à CNCF em 2015, junto com a versão 1.0

- O nome vem do grego e significa "**timoneiro**" (piloto de navio), daí o leme no logotipo. A abreviação **k8s** segue a convenção de numerônimos: **k** + 8 letras + **s**, como **i18n** para *internationalization*.
- Ideias que vieram do Borg: agrupar contêineres em Pods, rótulos (labels) para selecionar objetos, um IP por Pod e controladores que reconciliam estado.

2.1.2 O que o Kubernetes faz (e o que não faz)

Faz	Não faz (por conta própria)
Agenda contêineres nos nós conforme recursos e restrições	Construir imagens ou fazer CI/CD
Recria contêineres e Pods que falham (<i>self-healing</i>)	Oferecer banco de dados, fila ou cache prontos
Escala réplicas, manual ou automaticamente	Monitorar e registrar logs de forma completa (precisa de ferramentas do ecossistema)
Descoberta de serviços (DNS) e balanceamento entre Pods	Garantir que a aplicação seja resiliente: ela precisa tratar falhas e sinais
Atualizações graduais e rollback	Substituir boas práticas de segurança da aplicação e das imagens
Entrega de configuração e segredos	Gerenciar a infraestrutura física do cluster
Orquestração de volumes persistentes	

2.2 Arquitetura do cluster

2.2.1 Control plane e nós

Um cluster tem dois papéis:

- **Control plane** (antes chamado de *master*): toma as decisões do cluster e guarda o estado.
- **Nós de trabalho** (*workers*): executam os Pods das aplicações.

Em clusters gerenciados (EKS, GKE, AKS), o provedor opera o control plane e você só vê os nós de trabalho.

2.2.2 Componentes do control plane

Componente	Papel
kube-apiserver	A porta de entrada do cluster. Expõe a API REST (JSON ou Protobuf sobre HTTPS), autentica, autoriza, valida e grava os objetos. Todos os componentes, e o <code>kubectl</code> , conversam com o cluster por ele. É o único que fala com o <code>etcd</code>
etcd	Banco chave-valor distribuído e consistente (consenso Raft) onde fica todo o estado do cluster: especificações, status, configurações e segredos. Pode rodar nos nós de control plane (<i>stacked</i>) ou em um cluster próprio (<i>external</i>)
kube-scheduler	Observa Pods sem nó definido e escolhe o nó de cada um. Primeiro filtra os nós viáveis (recursos solicitados, taints, afinidade, portas, volumes) e depois pontua os restantes. Decide com base nos requests declarados, não no uso real de CPU e memória
kube-controller-manager	Executa os controladores (Deployment, ReplicaSet, Node, Job, EndpointSlice, ServiceAccount e outros). Cada um observa um tipo de objeto e age para que o estado real chegue ao desejado
cloud-controller-manager	Opcional. Integra o cluster ao provedor de nuvem: cria load balancers, rotas e verifica se as máquinas ainda existem

2.2.3 Componentes de cada nó

Componente	Papel
kubelet	Agente que roda em todos os nós (inclusive nos de control plane). Recebe os Pods designados ao nó, pede ao runtime que os execute, roda as probes, monta volumes e reporta o estado ao API server
kube-proxy	Implementa os Services no nó: programa regras (iptables, IPVS ou nftables) que levam o tráfego do IP virtual do Service para os Pods. Alguns plugins de rede, como o Cilium, o substituem por eBPF
Container runtime	containerd ou CRI-O (capítulo 1)

2.2.4 Add-ons essenciais

- **CNI (plugin de rede)**: dá IP a cada Pod e conecta Pods entre nós. Sem ele, os nós ficam `NotReady`. Exemplos: Calico, Cilium, Flannel, os plugins das nuvens (VPC CNI da AWS). O kube-proxy **não** faz a rede dos Pods; quem faz é o CNI.
- **CoreDNS**: DNS interno. Resolve nomes como `meu-servico.meu-namespace.svc.cluster.local`.
- **metrics-server**: coleta uso de CPU e memória para o `kubectl top` e o autoescalamento.
- **Ingress controller ou Gateway API**: entrada HTTP/HTTPS no cluster.

2.2.5 O que acontece quando você cria um Deployment

1. O `kubectl` envia o manifesto ao **API server**, que autentica, autoriza, valida e grava o Deployment no **etcd**.
2. O **controlador de Deployment** percebe o objeto novo e cria um **ReplicaSet**.

3. O **controlador de ReplicaSet** percebe que faltam Pods e cria os objetos **Pod**, ainda sem nó.
4. O **scheduler** escolhe um nó para cada Pod e grava essa decisão (o *binding*).
5. O **kubelet** do nó escolhido vê o Pod, chama o runtime pela CRI e o CNI configura a rede.
6. O kubelet reporta o status (`Running`, `Ready`). Se o contêiner cair, o kubelet o reinicia; se o Pod ou o nó sumir, o ReplicaSet cria outro Pod.

- Nenhum componente dá ordens diretas a outro: todos **observam** o API server e agem sobre o que mudou. Esse modelo de laços de reconciliação é o que torna o cluster resistente a falhas.

2.2.6 Alta disponibilidade

- Para estudo**, um cluster de **um nó** (control plane e workloads juntos) é suficiente.
- Em produção**, o control plane precisa de **pelo menos 3 nós** para que o etcd mantenha o quórum com a perda de um deles (a mesma lógica de quórum do Raft: $N \text{ nós toleram } (N - 1) / 2 \text{ falhas}$). Os nós de trabalho são dimensionados pela carga, com no mínimo dois para que as aplicações sobrevivam à perda de um nó.
- Por padrão, os nós de control plane têm um **taint** que impede Pods comuns de rodarem neles.

2.3 Portas usadas pelo cluster

2.3.1 Control plane

Protocolo	Porta	Uso	Quem acessa
TCP	6443	API server	Todos (usuários, nós, componentes)
TCP	2379–2380	etcd (clientes e comunicação entre membros)	kube-apiserver, etcd
TCP	10250	API do kubelet	O próprio nó e o control plane
TCP	10259	kube-scheduler	O próprio nó
TCP	10257	kube-controller-manager	O próprio nó

2.3.2 Nós de trabalho

Protocolo	Porta	Uso	Quem acessa
TCP	10250	API do kubelet	O próprio nó e o control plane
TCP	10256	kube-proxy (health check)	O próprio nó e load balancers
TCP e UDP	30000–32767	Services do tipo NodePort	Todos

- Todas as portas podem ser alteradas. É comum colocar o API server atrás de um load balancer na porta 443, mantendo 6443 nos nós.
- Além dessas, o **plugin CNI** usa as suas próprias portas entre nós (por exemplo, VXLAN em 4789/UDP no Flannel e no Calico, BGP em 179/TCP no Calico). Consulte a documentação do plugin escolhido.

2.4 Objetos e conceitos-chave

2.4.1 Principais objetos

Objeto	Para que serve
Pod	Menor unidade que o Kubernetes agenda: um ou mais contêineres que compartilham rede e volumes
ReplicaSet	Mantém um número fixo de Pods idênticos em execução
Deployment	Gerencia ReplicaSets para fazer atualizações graduais e rollback de aplicações sem estado
DaemonSet	Garante um Pod em cada nó (ou em um grupo de nós)
StatefulSet	Pods com identidade e armazenamento estáveis (bancos, filas)
Job / CronJob	Tarefas que terminam; o CronJob as agenda periodicamente
Service	Nome e IP estáveis para um grupo de Pods, com balanceamento (tipos ClusterIP, NodePort, LoadBalancer)
Namespace	Divide o cluster em espaços lógicos para organizar objetos, permissões e cotas
ConfigMap / Secret	Configuração e dados sensíveis entregues aos Pods
PersistentVolume / PersistentVolumeClaim	Armazenamento que sobrevive aos Pods

- O Kubernetes **não gerencia contêineres diretamente**: tudo é feito por meio de Pods, que por sua vez costumam ser criados por controladores (Deployment, StatefulSet, DaemonSet, Job).

2.4.2 Anatomia de um manifesto

Todo objeto tem a mesma estrutura:

```
apiVersion: apps/v1      # grupo/versão da API do tipo de objeto
kind: Deployment         # tipo do objeto
metadata:                # identificação
  name: web
  namespace: default
  labels:
    app: web
spec:                   # estado DESEJADO, escrito por você
  replicas: 3
  # ...
status:                # estado OBSERVADO, escrito pelo cluster (não se escreve no manifesto)
  readyReplicas: 3
```

- `apiVersion`: objetos do núcleo usam só `v1` (Pod, Service, ConfigMap); os demais usam `grupo/versão` (`apps/v1` para Deployment, `batch/v1` para Job). `kubectl api-resources` lista todos os tipos, e `kubectl explain deployment.spec.strategy` documenta cada campo.
- Labels** são pares chave-valor usados para **selecionar** objetos: um Service encontra seus Pods, e um Deployment reconhece os seus, por meio de seletores de labels. **Annotations** guardam informações que não servem para seleção (descrições, configurações de ferramentas).

Decisão rápida — Arquitetura

2.5

Situação	Abordagem recomendada	Erro comum
Control plane de produção	3 nós (ou serviço gerenciado)	Um único nó de control plane
Nós aparecem <code>NotReady</code> logo após criar o cluster	Instalar o plugin CNI	Reiniciar o kubelet repetidamente
Pod fica <code>Pending</code> com nós "ociosos"	Conferir os requests e os eventos do scheduler	Supor que o scheduler olha o uso real
Liberar acesso ao cluster em um firewall	6443 para o API server; 10250 entre control plane e nós; portas do CNI entre nós	Abrir 2379 (etcd) para fora do control plane
Descobrir campos de um objeto	<code>kubectl explain <tipo>.<campo></code>	Copiar YAML de blogs sem saber o que cada campo faz
Onde fica o estado do cluster?	No etcd, acessado só pelo API server	Editar arquivos nos nós
Quem cria os Pods de um Deployment?	O controlador de ReplicaSet, a partir do ReplicaSet criado pelo Deployment	Achar que o scheduler cria Pods

kubectl e Clusters Locais

***Ideia central:** o `kubectl` é um cliente da API do Kubernetes. Ele lê o `kubeconfig` para saber **qual cluster**, **qual usuário** e **qual namespace** usar. Para aprender, um cluster local com **kind** ou **Minikube** sobe em minutos e pode ser apagado sem cerimônia.*

3.1 Instalar o kubectl

3.1.1 Linux, macOS e Windows

```
# Linux (x86-64; para ARM troque amd64 por arm64)
curl -LO "https://dl.k8s.io/release/$(curl -L -s
https://dl.k8s.io/release/stable.txt)/bin/linux/amd64/kubectl"
curl -LO "https://dl.k8s.io/release/$(curl -L -s
https://dl.k8s.io/release/stable.txt)/bin/linux/amd64/kubectl.sha256"
echo "$(cat kubectl.sha256) kubectl" | sha256sum --check      # deve imprimir "kubectl: OK"
sudo install -o root -g root -m 0755 kubectl /usr/local/bin/kubectl

# macOS (Homebrew; sem sudo)
brew install kubectl

# Windows
winget install -e --id Kubernetes.kubectl      # ou: choco install kubernetes-cli

kubectl version --client
```

- **Confira o checksum** quando baixar o binário: é a garantia de que ele não foi corrompido nem adulterado.
- **Nunca rode o Homebrew com `sudo`**: ele não precisa e passa a criar arquivos com dono errado.
- **Versão**: use um `kubectl` de no máximo **uma versão menor de diferença** do cluster. `kubectl version` (sem `--client`) mostra as duas versões e avisa quando a diferença é grande demais.
- Nos repositórios de pacotes das distribuições (apt, dnf), use os repositórios oficiais `pkgs.k8s.io`, que têm um repositório por versão menor. Os antigos `apt.kubernetes.io` e `yum.kubernetes.io` foram desativados em 2024.

3.2 Configurar o kubectl

3.2.1 Kubeconfig e contextos

- O kubeconfig fica em `~/.kube/config` (ou nos arquivos da variável `KUBECONFIG`, separados por `:`, que são mesclados). Ele tem três listas: **clusters** (endereço do API server e CA), **users** (credenciais) e **contexts** (combinação de cluster + usuário + namespace padrão).

```
kubectl config get-contexts                # lista; * marca o atual
kubectl config current-context
kubectl config use-context kind-estudo      # troca de cluster
kubectl config set-context --current --namespace=loja # namespace padrão do contexto
kubectl cluster-info                       # endereço do API server e do CoreDNS
```

- Ferramentas como kind, Minikube e as CLIs das nuvens (`aws eks update-kubeconfig`, `gcloud container clusters get-credentials`) **adicionam contextos** ao seu kubeconfig automaticamente.
- O kubeconfig contém **credenciais do cluster**: trate como segredo e não versione.
- Os utilitários **kubectx** e **kubens** (instaláveis pelo gerenciador de plugins **krew**) trocam de contexto e de namespace com menos digitação.

3.2.2 Autocompletar e alias

```
# Bash (requer o pacote bash-completion)
source <(kubectl completion bash)
echo 'source <(kubectl completion bash)' >> ~/.bashrc
echo 'alias k=kubectl' >> ~/.bashrc
echo 'complete -o default -F __start_kubectl k' >> ~/.bashrc

# Zsh
echo 'source <(kubectl completion zsh)' >> ~/.zshrc
echo 'alias k=kubectl' >> ~/.zshrc
```

- No Bash, o `complete -o default -F __start_kubectl k` faz o autocompletar funcionar também com o alias `k`. No Zsh, o completar do alias já funciona.
- Também existem `kubectl completion fish` e `kubectl completion powershell`.

3.3 Clusters locais e distribuições

3.3.1 Opções para estudar e para produção

Ferramenta	Como roda	Produção?	Quando usar
kind (<i>Kubernetes in Docker</i>)	Cada nó é um contêiner (Docker, Podman ou nerdctl)	Não	Estudo, testes automatizados e CI; clusters com vários nós em segundos
Minikube	VM ou contêiner local, com addons prontos (dashboard, ingress, metrics-server)	Não	Estudo e desenvolvimento, com experiência "tudo incluído"
k3d	k3s dentro de contêineres	Não	Como o kind, usando k3s
Docker Desktop / Rancher Desktop	Cluster embutido na aplicação de desktop	Não	Quem já usa essas ferramentas
k3s (SUSE/Rancher)	Distribuição leve em um único binário	Sim	Edge, IoT, Raspberry Pi, clusters pequenos
MicroK8s (Canonical)	Pacote snap com addons	Sim	Edge, IoT, estações Ubuntu
k0s (Mirantis)	Distribuição em um único binário, "zero friction"	Sim	Instalação e manutenção simplificadas
kubeadm	Ferramenta oficial para montar clusters em máquinas próprias	Sim	Aprender a fundo e montar clusters <i>on-premises</i>

Ferramenta	Como roda	Produção?	Quando usar
EKS, GKE, AKS	Control plane gerenciado pelo provedor	Sim	A maioria dos ambientes de produção em nuvem

3.3.2 kind

```
# Instalação (Linux x86-64). Versão estável em set/2026: v0.33.0
curl -Lo ./kind https://kind.sigs.k8s.io/dl/v0.33.0/kind-linux-amd64
chmod +x ./kind && sudo mv ./kind /usr/local/bin/kind
# macOS: brew install kind | Windows: choco install kind ou winget install Kubernetes.kind

kind create cluster --name estudo      # contexto criado: kind-estudo
kind get clusters
kubectl get nodes
kind delete cluster --name estudo
```

Cluster com vários nós:

```
# kind-3nos.yaml
kind: Cluster
apiVersion: kind.x-k8s.io/v1alpha4
nodes:
  - role: control-plane
  - role: worker
  - role: worker
```

```
kind create cluster --name multi --config kind-3nos.yaml
kind create cluster --name antigo --image kindest/node:<versão> # outra versão do Kubernetes (tags nas
notas de versão do kind)
kind load docker-image minha-app:dev --name multi              # enviar uma imagem local aos nós
kind delete clusters --all
```

- O contexto de cada cluster se chama `kind-<nome>`.
- `kind load docker-image` evita publicar em um registry imagens construídas localmente; nesse caso, use uma tag diferente de `latest` ou `imagePullPolicy: IfNotPresent`, para o kubelet não tentar baixá-la.
- O kind detecta sozinho Docker, Podman ou nerdctl; para forçar um deles, use `KIND_EXPERIMENTAL_PROVIDER=podman`.

3.3.3 Minikube

```
# Requisitos: 2 CPUs, 2 GB de memória livre, 20 GB de disco e um driver (Docker, Podman, QEMU, KVM, Hyper-V, VirtualBox...)
curl -LO https://github.com/kubernetes/minikube/releases/latest/download/minikube-linux-amd64
sudo install minikube-linux-amd64 /usr/local/bin/minikube
# macOS: brew install minikube | Windows: winget install Kubernetes.minikube

minikube start                                # escolhe o driver disponível
minikube start --driver=docker --kubernetes-version=v1.36.5
minikube start --nodes 3 -p multi             # perfil "multi" com 3 nós
minikube status
minikube ip                                  # IP do nó
minikube ssh                                  # entra no nó
minikube dashboard                           # painel web
minikube addons list && minikube addons enable metrics-server
minikube logs
minikube stop                                 # para sem apagar
minikube delete                               # apaga o cluster
minikube delete --all --purge                 # apaga tudo, inclusive ~/.minikube
```

- Com o driver **Docker**, não é preciso hypervisor nem virtualização aninhada; é a opção mais comum hoje. Drivers de VM (KVM, Hyper-V, VirtualBox, QEMU) exigem virtualização habilitada no processador e no firmware.
- Cada **perfil** (-p) é um cluster independente, com contexto próprio.

3.4 Primeiros comandos

3.4.1 Explorar o cluster

```
kubectl get nodes -o wide                     # nós, versões, IPs, runtime
kubectl get namespaces                         # default, kube-system, kube-public, kube-node-lease
kubectl get pods -n kube-system               # componentes do cluster
kubectl get pods -A -o wide                   # todos os namespaces, com IP e nó
kubectl api-resources                         # tipos de objeto e abreviações (po, deploy, svc, ns, cm...)
kubectl explain pod.spec.containers           # documentação dos campos
```

Namespace	Conteúdo
default	Onde vão os objetos criados sem -n
kube-system	Componentes do cluster (CoreDNS, kube-proxy, CNI e, em clusters kubeadm, os Pods estáticos do control plane)
kube-public	Dados legíveis por qualquer um, inclusive sem autenticação
kube-node-lease	Objetos Lease que os nós renovam como sinal de vida

3.4.2 Primeiro Pod e primeiro Service

```
kubectl run web --image=nginx:1.29 --port=80      # cria um Pod
kubectl get pods                                  # STATUS Running, READY 1/1
kubectl expose pod web --port=80                  # cria um Service ClusterIP
kubectl get svc                                    # o Service "kubernetes" (10.96.0.1:443) já existia
kubectl port-forward pod/web 8080:80              # acesse http://localhost:8080
kubectl delete svc web && kubectl delete pod web
```

- `kubectl expose` precisa saber a porta. Sem `--port` no `expose` e sem `containerPort` declarado no Pod, o comando falha com `couldn't find port via --port flag or introspection`.
- Um Service **ClusterIP** só é acessível **dentro do cluster**. Para testar da sua máquina, use `kubectl port-forward` ou um Service NodePort ou LoadBalancer.
- O Service `kubernetes` no namespace `default` é o endereço interno do próprio API server.

3.4.3 Imperativo e declarativo

Forma	Exemplo	Quando usar
Comandos imperativos	<code>kubectl run</code> , <code>kubectl create deployment</code> , <code>kubectl scale</code> , <code>kubectl expose</code>	Testes rápidos e geração de esqueletos
Configuração imperativa com arquivos	<code>kubectl create -f</code> , <code>kubectl replace -f</code> , <code>kubectl delete -f</code>	Criar uma vez; falha se o objeto já existe (<code>create</code>)
Configuração declarativa	<code>kubectl apply -f arquivo.yaml</code> OU <code>-f diretório/</code>	Padrão do dia a dia : cria ou atualiza; os arquivos ficam no Git

- **Gerar YAML sem criar nada**: `--dry-run=client -o yaml` produz um manifesto para editar.

```
kubectl run web --image=nginx:1.29 --port=80 --dry-run=client -o yaml > pod.yaml
kubectl create deployment web --image=nginx:1.29 --replicas=3 --dry-run=client -o yaml > deploy.yaml
kubectl apply -f deploy.yaml
kubectl diff -f deploy.yaml          # mostra o que mudaria antes de aplicar
```

- `--dry-run=server` envia o pedido ao API server, que valida tudo (inclusive webhooks de admissão) sem gravar.

3.4.4 Formatos de saída e seletores

Opção	Resultado
<code>-o wide</code>	Colunas extras (IP do Pod, nó)
<code>-o yaml</code> / <code>-o json</code>	Objeto completo, com <code>status</code>
<code>-o name</code>	Só tipo/nome (útil em scripts)
<code>-o jsonpath='{.items[*].metadata.name}'</code>	Campos específicos
<code>-o custom-columns=NAME:.metadata.name,NO:.spec.nodeName</code>	Tabela sob medida
<code>-l app=web</code> / <code>-l 'tier in (front,back)'</code>	Filtra por labels
<code>--field-selector status.phase=Running</code>	Filtra por campos
<code>-w</code> / <code>--watch</code>	Acompanha mudanças em tempo real

- `kubectl get all` **não mostra "tudo"**: lista só alguns tipos (Pods, Services, Deployments, ReplicaSets, StatefulSets, DaemonSets, Jobs, CronJobs). ConfigMaps, Secrets, Ingresses e PVCs, por exemplo, ficam de fora. Para vários tipos específicos: `kubectl get pod,svc,cm`.

3.5 Labels, seletores e annotations

3.5.1 Labels

- **Labels** são pares chave-valor usados para **identificar e selecionar** objetos. Services, Deployments, NetworkPolicies, afinidades e o próprio `kubectl` escolhem objetos por labels.
- Formato da chave: prefixo opcional com domínio (`app.kubernetes.io/`) + nome de até 63 caracteres. Os valores também têm até 63 caracteres.
- **Labels recomendadas**: `app.kubernetes.io/name`, `app.kubernetes.io/instance`, `app.kubernetes.io/version`, `app.kubernetes.io/component`, `app.kubernetes.io/part-of`, `app.kubernetes.io/managed-by`.

```
kubectl label pod web ambiente=producao          # adiciona
kubectl label pod web ambiente=homologacao --overwrite
kubectl label pod web ambiente-                  # remove
kubectl get pods -l 'ambiente=producao,tier in (web,api)'
kubectl get pods -l '!canary'                   # sem a label canary
kubectl get pods --show-labels
kubectl get pods -L app,ambiente                # labels como colunas
```

- Em um Deployment, as labels em `metadata.labels` são **do Deployment**; as dos Pods ficam em `spec.template.metadata.labels`. Filtrar Pods pelas labels do Deployment não retorna nada.

3.5.2 Annotations

- **Annotations** guardam informações que **não servem para seleção**: descrições, links, configurações de ferramentas (controladores de entrada, cert-manager, Prometheus) e dados gerados por ferramentas. Não têm o limite de 63 caracteres no valor.

```
kubectl annotate deployment web descricao="API de pedidos"
kubectl annotate deployment web descricao="API de pedidos v2" --overwrite
kubectl annotate deployment web descricao-
kubectl get deployment web -o jsonpath='{.metadata.annotations}'
```

3.6 Decisão rápida — kubectl e clusters locais

Situação	Abordagem recomendada	Erro comum
Cluster para estudar com vários nós	kind com arquivo de configuração	Máquinas virtuais montadas à mão
Cluster local com dashboard e addons prontos	Minikube	kind esperando addons prontos
Cluster pequeno em produção (edge, IoT)	k3s, MicroK8s ou k0s	kind ou Minikube em produção
Comando foi para o cluster errado	Conferir <code>kubectl config current-context</code> antes; <code>kubectx/kubens</code>	Um único kubeconfig sem nomes claros

Situação	Abordagem recomendada	Erro comum
Criar o primeiro YAML de um objeto	<code>kubectl create ... --dry-run=client -o yaml</code>	Escrever o manifesto do zero
Atualizar objetos a partir de arquivos	<code>kubectl apply -f</code> (e <code>kubectl diff</code> antes)	<code>kubectl create -f</code> repetidas vezes
Testar um Service ClusterIP da sua máquina	<code>kubectl port-forward</code>	Tentar acessar o IP do Service de fora do cluster
Usar uma imagem local no kind	<code>kind load docker-image</code> + tag fixa	Tag latest com <code>imagePullPolicy: Always</code>
<code>kubectl</code> muito diferente da versão do cluster	Manter no máximo uma versão menor de diferença	Ignorar o aviso do <code>kubectl version</code>

Pods

*Ideia central: o Pod é a menor unidade que o Kubernetes agenda: um ou mais contêineres que **compartilham o mesmo IP, a mesma rede** (localhost) **e os mesmos volumes**, e que sempre rodam juntos no mesmo nó. Pods são **descartáveis**: quando um some, ninguém o "conserta"; um controlador cria outro, com outro nome e outro IP.*

4.1 O que é um Pod

4.1.1 Características

- **Um IP por Pod:** todos os contêineres do Pod compartilham o namespace de rede e se falam por localhost. Por isso, dois contêineres do mesmo Pod **não podem** escutar na mesma porta.
- **Volumes compartilhados:** um volume declarado no Pod pode ser montado em vários dos seus contêineres.
- **Agendados juntos:** todos os contêineres de um Pod vão para o **mesmo nó**, sempre.
- **Efêmeros:** um Pod não é movido para outro nó. Se o nó cair ou o Pod for apagado, ele deixa de existir; um Deployment ou outro controlador cria um **novo** Pod no lugar.
- **Um Pod "solto"** (criado diretamente, sem controlador) só tem seus contêineres reiniciados pelo kubelet enquanto existir. Se for apagado ou o nó falhar, **nada o recria**. Em produção, Pods são criados por **Deployments**, StatefulSets, DaemonSets ou Jobs.
- **Uma aplicação por Pod:** escalar significa criar mais Pods, não mais contêineres dentro do mesmo Pod. Coloque dois contêineres no mesmo Pod só quando eles precisam, de fato, viver juntos.

4.2 Criar e inspecionar Pods

4.2.1 Manifesto comentado

```
apiVersion: v1
kind: Pod
metadata:
  name: web
  labels:
    app: web          # usado por Services e seletores
spec:
  containers:
    - name: nginx      # nome do contêiner dentro do Pod
      image: nginx:1.29 # sempre com tag; evite latest
      ports:
        - containerPort: 80 # documenta a porta (e permite nomeá-la)
```

```

kubectl apply -f pod.yaml
kubectl get pods                # NAME, READY (prontos/total), STATUS, RESTARTS, AGE
kubectl get pod web -o wide     # IP do Pod e nó
kubectl get pod web -o yaml     # objeto completo, com status, uid e nodeName
kubectl describe pod web        # configuração + eventos
kubectl delete pod web          # ou: kubectl delete -f pod.yaml

```

- `containerPort` é **informativo**, como o `EXPOSE` do Docker: o contêiner escuta na porta mesmo sem declará-la. Declarar ajuda o `kubectl expose` e permite dar nomes às portas (`name: http`).
- `imagePullPolicy`: com tag `latest` ou sem tag, o padrão é `Always`; com qualquer outra tag, `IfNotPresent`. Use tags fixas (ou digests) para saber exatamente o que está rodando.

4.2.2 `apply`, `create` e `replace`

Comando	Objeto não existe	Objeto já existe
<code>kubectl create -f</code>	Cria	Erro <code>AlreadyExists</code>
<code>kubectl apply -f</code>	Cria	Atualiza com as diferenças do arquivo
<code>kubectl replace -f</code>	Erro	Substitui o objeto inteiro

- Muitos campos de um Pod são **imutáveis** depois de criado (a imagem pode mudar; a lista de portas, os volumes e os comandos, não). Para mudar um Pod solto, apague e crie de novo. Em um Deployment, basta alterar o template: ele cria Pods novos.

4.2.3 Logs

```

kubectl logs web                # saída do contêiner (STDOUT e STDERR)
kubectl logs -f web             # acompanha em tempo real
kubectl logs web -c sidecar     # contêiner específico em Pods com vários
kubectl logs web --all-containers
kubectl logs web --previous     # execução ANTERIOR (essencial em CrashLoopBackOff)
kubectl logs -l app=web --since=10m # vários Pods por label
kubectl logs deploy/web         # um Pod do Deployment

```

4.3 Pods com vários contêineres

4.3.1 Padrões de uso

Padrão	O que o contêiner auxiliar faz	Exemplo
Sidecar	Complementa a aplicação principal durante toda a vida do Pod	Coletor de logs, proxy de service mesh, sincronizador de arquivos
Ambassador	Proxy local para serviços externos	A aplicação fala com <code>localhost:6379</code> , e o ambassador encaminha para o Redis certo
Adapter	Traduz a saída da aplicação para um formato padrão	Converte métricas da aplicação para o formato do Prometheus
Init container	Roda antes dos contêineres principais, até terminar	Esperar uma dependência, aplicar migrações, baixar configuração

```

apiVersion: v1
kind: Pod
metadata:
  name: web-com-logs
spec:
  volumes:
    - name: logs
      emptyDir: {}
  initContainers:
    - name: preparar                                # init container comum: roda e termina
      image: busybox:1.37
      command: ["sh", "-c", "echo configurado > /logs/inicio.txt"]
      volumeMounts: [{ name: logs, mountPath: /logs }]
    - name: coletor                                # sidecar nativo (estável desde a 1.33)
      image: busybox:1.37
      restartPolicy: Always
      command: ["sh", "-c", "tail -F /logs/acesso.log"]
      volumeMounts: [{ name: logs, mountPath: /logs }]
  containers:
    - name: app
      image: busybox:1.37
      command: ["sh", "-c", "while true; do date >> /logs/acesso.log; sleep 5; done"]
      volumeMounts: [{ name: logs, mountPath: /logs }]

```

- **Sidecars nativos:** um init container com `restartPolicy: Always` inicia **antes** dos contêineres principais, continua rodando junto com eles e só é encerrado **depois** que eles terminam. Isso resolve dois problemas antigos dos sidecars declarados em `containers`: a aplicação iniciando antes do proxy, e Jobs que nunca terminavam porque o sidecar continuava vivo.
- **Contêiner que termina logo:** imagens como `alpine` ou `busybox` executam um shell e saem imediatamente sem nada a prender. Em exemplos e depuração, use um processo que fique em primeiro plano (`sleep infinity`); em aplicações reais, o processo principal é a própria aplicação.

4.4 Interagir com um Pod em execução

4.4.1 `exec`, `attach`, `port-forward`, `cp` e `debug`

Comando	O que faz
<code>kubectl exec web -- ls /usr/share/nginx/html</code>	Executa um comando novo no contêiner
<code>kubectl exec -it web -c app -- sh</code>	Shell interativo (<code>-i</code> mantém STDIN, <code>-t</code> aloca terminal; <code>-c</code> escolhe o contêiner)
<code>kubectl attach -it web -c app</code>	Conecta ao STDIN/STDOUT do processo principal ; não cria processo novo
<code>kubectl port-forward pod/web 8080:80</code>	Encaminha uma porta local para o Pod (também <code>svc/</code> e <code>deploy/</code>)
<code>kubectl cp web:/etc/nginx/nginx.conf ./nginx.conf</code>	Copia arquivos (exige <code>tar</code> na imagem)
<code>kubectl debug -it web --image=busybox:1.37 --target=app</code>	Adiciona um contêiner efêmero de depuração ao Pod, compartilhando o namespace de processos do contêiner alvo
<code>kubectl debug node/<nó> -it --image=ubuntu</code>	Pod de depuração com acesso ao sistema de arquivos do nó (em <code>/host</code>)

- **Prefira `exec` a `attach`:** o `attach` só faz sentido para processos interativos. Em um servidor como o `nginx`, ele apenas mostra a saída do processo principal.

- Ao sair de um `exec -it` com `exit` ou Ctrl+D, só o shell criado termina; o contêiner continua.
- **Imagens mínimas** (distroless, scratch) não têm shell: use `kubectl debug` com contêineres efêmeros, recurso estável desde a 1.25.

4.5 Ciclo de vida do Pod

4.5.1 Fases e estados

Fase do Pod	Significado
Pending	Aceito pelo cluster, mas algum contêiner ainda não rodou (esperando agendamento ou download de imagem)
Running	Associado a um nó, com pelo menos um contêiner rodando ou reiniciando
Succeeded	Todos os contêineres terminaram com sucesso e não serão reiniciados (Jobs)
Failed	Todos terminaram e pelo menos um falhou
Unknown	O estado não pôde ser obtido (em geral, o nó parou de responder)

Motivo que aparece em STATUS	Causa comum	Onde investigar
ContainerCreating	Baixando a imagem, montando volumes	<code>describe</code> (eventos)
ErrImagePull / ImagePullBackOff	Nome ou tag errados, registry privado sem <code>imagePullSecrets</code> , limite de pulls	<code>describe</code>
CrashLoopBackOff	O contêiner inicia e sai repetidamente; o kubelet espera cada vez mais entre as tentativas (de 10 s até 5 min)	<code>logs --previous</code> , código de saída em <code>describe</code>
OOMKilled	O contêiner passou do limite de memória (código de saída 137)	<code>describe</code> (Last State)
CreateContainerConfigError	ConfigMap ou Secret referenciado não existe	<code>describe</code>
Pending sem nó	Nenhum nó com recursos (requests) suficientes, taints, afinidade impossível	<code>describe</code> (eventos FailedScheduling)
Completed	O processo principal terminou com código 0	Esperado em Jobs; em Deployments, o processo não está rodando em primeiro plano

- `restartPolicy` do Pod: `Always` (padrão, obrigatório em Deployments), `OnFailure` ou `Never` (usados em Jobs). Quem reinicia o contêiner é o **kubelet**, no mesmo nó, mantendo o Pod.
- **Encerramento gracioso**: ao apagar um Pod, o kubelet envia **SIGTERM** ao processo principal de cada contêiner, espera `terminationGracePeriodSeconds` (padrão **30 s**) e então envia **SIGKILL**. Um hook `preStop` roda antes do SIGTERM. Ao mesmo tempo, o Pod sai dos endpoints dos Services, para não receber tráfego novo.
- `kubectl delete pod web --grace-period=0 --force` apaga o objeto sem esperar o nó confirmar. Use só quando o nó está inacessível: em StatefulSets, pode levar a duas instâncias com a mesma identidade.

4.6 Recursos: requests e limits

4.6.1 Como funcionam

```
spec:
  containers:
    - name: app
      image: nginx:1.29
      resources:
        requests:          # o que o scheduler reserva no nó
          cpu: 250m
          memory: 128Mi
        limits:            # o máximo que o contêiner pode usar
          cpu: 500m
          memory: 256Mi
```

	requests	limits
Quem usa	O scheduler , para escolher um nó com capacidade livre	O kubelet e o kernel (cgroups), durante a execução
CPU	Garantia de fatia de CPU sob disputa	Limite rígido: o contêiner é estrangulado (throttling), não morto
Memória	Reserva para o agendamento	Passou do limite: o contêiner é morto por OOM (OOMKilled, código 137) e reiniciado

- **Unidades de CPU:** 1 = um núcleo (vCPU). Frações em **milicores**: 500m = 0.5 = meio núcleo. O menor valor é 1m.
- **Unidades de memória:** em bytes, com sufixos **binários** Ki, Mi, Gi (potências de 1024) ou **decimais** k, M, G (potências de 1000). 128Mi = 134.217.728 bytes; 128M = 128.000.000 bytes. Cuidado: 128m (minúsculo) significa 0,128 **byte**, um erro comum.
- **Sem requests**, o scheduler supõe que o Pod não precisa de nada e pode lotar um nó. **Sem limits**, um contêiner pode consumir a memória do nó inteiro e provocar despejo (*eviction*) de outros Pods.

4.6.2 Classes de QoS

Classe	Quando o Pod recebe	Prioridade para ser despejado quando o nó fica sem memória
Guaranteed	Todos os contêineres com requests iguais aos limits, para CPU e memória	Última
Burstable	Pelo menos um request ou limit definido, sem atender ao Guaranteed	Intermediária
BestEffort	Nenhum request nem limit	Primeira

- A classe aparece em `kubectl describe pod (QoS Class)` e em `kubectl get pod -o jsonpath='{.status.qosClass}'`.

4.6.3 Testar os limites e ajustar sem recriar

```
kubectl run carga --image=ubuntu:24.04 --restart=Never \
  --overrides='{ "spec": { "containers": [ { "name": "carga", "image": "ubuntu:24.04", "command":
[ "sleep", "infinity" ],
  "resources": { "requests": { "memory": "64Mi", "cpu": "250m" }, "limits": { "memory": "128Mi", "cpu": "500m" } } } ] } }'
kubectl exec -it carga -- bash -c 'apt-get update -qq && apt-get install -y -qq stress'
kubectl exec -it carga -- stress --vm 1 --vm-bytes 100M --timeout 20s # abaixo do limite: roda
kubectl exec -it carga -- stress --vm 1 --vm-bytes 200M --timeout 20s # acima: o worker do stress é
morto por OOM
kubectl top pod carga # exige metrics-server
```

- Quando o processo que passa do limite **não é o principal** (como o worker do `stress`), só ele morre. Quando é o processo principal, o contêiner inteiro termina com `OOMKilled` e é reiniciado.
- Redimensionamento sem recriar o Pod** (estável desde a 1.35): altere CPU e memória pelo subrecurso `resize`. A CPU muda sem reiniciar o contêiner; para a memória, o campo `resizePolicy` define se o contêiner precisa reiniciar.

```
kubectl patch pod carga --subresource=resize \
-p '{ "spec": { "containers": [ { "name": "carga", "resources": { "requests": { "cpu": "500m" }, "limits":
{ "cpu": "1" } } } ] } }'
```

- Recursos declarados **no nível do Pod** (`spec.resources`, um orçamento para todos os contêineres) estão em **beta** na 1.37 e dependem do recurso `PodLevelResources` estar ativo no cluster.

4.7 Volume emptyDir

4.7.1 Como funciona

- Um `emptyDir` é criado **vazio** quando o Pod é agendado em um nó e **apagado quando o Pod é removido**. Ele sobrevive à reinicialização de contêineres, mas não à troca de Pod.
- É muito usado para **compartilhar arquivos entre contêineres do mesmo Pod** (aplicação e sidecar), para cache e para arquivos temporários grandes (fora da camada gravável do contêiner).
- `medium: Memory` monta um **tmpfs** (RAM): é rápido, e o que for gravado **conta no limite de memória** do contêiner. `sizeLimit` limita o tamanho; se for ultrapassado, o Pod é despejado.

```
spec:
  containers:
    - name: app
      image: ubuntu:24.04
      command: ["sleep", "infinity"]
      volumeMounts:
        - name: temporario
          mountPath: /dados
  volumes:
    - name: temporario
      emptyDir:
        sizeLimit: 256Mi
        # medium: Memory
```

- Para dados que precisam sobreviver ao Pod, use volumes persistentes (PersistentVolumeClaim), assunto de um capítulo próprio.

4.8 Decisão rápida — Pods

Situação	Abordagem recomendada	Erro comum
Rodar uma aplicação em produção	Deployment (ou outro controlador), nunca um Pod solto	<code>kubectl run</code> e esquecer
Aplicação e coletor de logs juntos	Sidecar nativo (init container com <code>restartPolicy: Always</code>) + <code>emptyDir</code>	Dois processos no mesmo contêiner
Preparar algo antes de a aplicação subir	Init container	<code>sleep</code> no comando da aplicação
Pod em <code>CrashLoopBackOff</code>	<code>kubectl logs --previous</code> e o código de saída no <code>describe</code>	Apagar o Pod repetidas vezes
Pod em <code>Pending</code>	Eventos do <code>describe</code> : requests, taints, afinidade	Aumentar o limit (o scheduler olha os requests)
Contêiner morto com 137	<code>OOMKilled</code> : rever o limite de memória ou o consumo da aplicação	Aumentar a CPU
Aplicação lenta mas nunca reinicia	Conferir throttling de CPU (limit baixo demais)	Procurar vazamento de memória
Depurar imagem sem shell	<code>kubectl debug</code> com contêiner efêmero	Trocar a imagem por uma com shell
Pod importante não pode ser despejado primeiro	QoS Guaranteed (requests = limits)	Deixar sem requests e limits
Ajustar CPU de um Pod em execução	<code>kubectl patch --subresource=resize (1.35+)</code>	Apagar e recriar o Pod
Testar a aplicação da sua máquina	<code>kubectl port-forward</code>	Criar um Service LoadBalancer só para testar

Deployments e ReplicaSets

Ideia central: um **Deployment** gerencia **ReplicaSets**, e cada **ReplicaSet** gerencia **Pods**. O **ReplicaSet** só sabe manter *N* cópias de um mesmo **template**; o **Deployment** é quem sabe **trocar de versão**: a cada mudança no **template** dos **Pods**, ele cria um **ReplicaSet** novo, aumenta esse e diminui o antigo, e guarda os anteriores para **rollback**.

5.1 Deployment, ReplicaSet e Pod

5.1.1 A hierarquia

```
Deployment web (estado desejado: 3 réplicas de nginx:1.29)
└─ ReplicaSet web-5d8f7c9b6d (um por versão do template; os antigos ficam com 0 réplicas)
    ├── Pod web-5d8f7c9b6d-4kq2x
    ├── Pod web-5d8f7c9b6d-9z17m
    └─ Pod web-5d8f7c9b6d-xw3pd
```

- O sufixo do **ReplicaSet** é o `pod-template-hash`, calculado a partir do **template** dos **Pods**; o **Kubernetes** o acrescenta como **label** nos **Pods** e no seletor do **ReplicaSet**, para que **ReplicaSets** de versões diferentes não disputem os mesmos **Pods**.
- Os **Pods** têm um `ownerReference` apontando para o **ReplicaSet**, que aponta para o **Deployment**. `kubectl describe pod` mostra `Controlled By: ReplicaSet/...`. Apagar o **Deployment** apaga, em cascata, os **ReplicaSets** e os **Pods**.

5.1.2 Manifesto comentado

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: web
  labels:
    app: web
spec:
  replicas: 3
  revisionHistoryLimit: 10           # ReplicaSets antigos guardados para rollback (padrão 10)
  progressDeadlineSeconds: 600      # tempo sem progresso até o rollout ser marcado como falho
  (padrão 600)
  minReadySeconds: 0                # segundos que um Pod novo precisa ficar pronto para contar como
  disponível
  selector:
    matchLabels:
      app: web                       # PRECISA casar com as labels do template; imutável depois de
  criado
  strategy:
    type: RollingUpdate
    rollingUpdate:
      maxSurge: 25%                  # Pods a mais permitidos durante a troca (padrão 25%)
      maxUnavailable: 25%           # Pods a menos permitidos durante a troca (padrão 25%)
  template:                          # o "molde" dos Pods
    metadata:
      labels:
        app: web
    spec:
      containers:
        - name: nginx
          image: nginx:1.29
          ports:
            - containerPort: 80
          resources:
            requests: { cpu: 250m, memory: 128Mi }
            limits: { cpu: 500m, memory: 256Mi }
```

- **Seletor e labels do template precisam casar**, ou o API server recusa o Deployment. O seletor **não pode ser alterado** depois (a mudança exige recriar o Deployment).
- **Labels do Deployment** (em `metadata.labels`) e **labels dos Pods** (em `template.metadata.labels`) são coisas diferentes: `kubectl get pods -l app=web` filtra pelas labels dos **Pods**. Um filtro que não casa com elas não retorna nada, mesmo com os Pods rodando.

5.2 Criar, inspecionar e escalar

5.2.1 Comandos do dia a dia

```
kubectl apply -f deploy.yaml
kubectl create deployment web --image=nginx:1.29 --replicas=3          # forma imperativa
kubectl get deployments          # NAME, READY (3/3), UP-TO-DATE, AVAILABLE, AGE
kubectl get rs -l app=web        # DESIRED, CURRENT, READY
kubectl get pods -l app=web -o wide
kubectl describe deployment web  # estratégia, condições, ReplicaSet novo e antigos, eventos
kubectl scale deployment web --replicas=5
kubectl set image deployment/web nginx=nginx:1.29.1
kubectl edit deployment web      # edição direta no cluster
```

Coluna de <code>kubectl get deployments</code>	Significado
READY	Réplicas prontas / desejadas
UP-TO-DATE	Réplicas já com o template mais recente
AVAILABLE	Réplicas prontas há pelo menos <code>minReadySeconds</code>

- **Escalar não cria revisão:** só mudanças no **template dos Pods** (`spec.template`) criam um ReplicaSet novo. Mudar `replicas` altera o ReplicaSet atual.
- `kubectl scale`, `set image` e `edit` mudam o objeto **no cluster**, mas não no seu arquivo. No próximo `kubectl apply` do arquivo antigo, a mudança é desfeita. Para manter o Git como fonte da verdade, altere o YAML e aplique.
- **Quando há autoescalamento (HPA)**, retire `replicas` do manifesto, para o `apply` não brigar com o HPA.

5.3 Estratégias de atualização

5.3.1 RollingUpdate e Recreate

Estratégia	Como funciona	Quando usar
RollingUpdate (padrão)	Cria Pods da versão nova e remove os da antiga aos poucos, respeitando <code>maxSurge</code> e <code>maxUnavailable</code>	A maioria das aplicações sem estado; exige que duas versões convivam por alguns minutos
Recreate	Remove todos os Pods antigos e só então cria os novos	Aplicações que não podem ter duas versões ao mesmo tempo (migração de esquema incompatível, licença por instância, volume <code>ReadWriteOnce</code> compartilhado). Tem indisponibilidade

- `maxSurge`: quantos Pods **acima** de `replicas` podem existir durante a troca. Percentuais são arredondados **para cima**.
- `maxUnavailable`: quantos Pods **abaixo** de `replicas` podem ficar indisponíveis. Percentuais são arredondados **para baixo**. Os dois não podem ser 0 ao mesmo tempo.
- **Exemplo:** `replicas: 10`, `maxSurge: 1`, `maxUnavailable: 2`. Durante o rollout, o total nunca passa de **11** Pods, e pelo menos **8** ficam disponíveis. O controlador pode derrubar 2 antigos e criar 1 novo logo de início, e segue trocando conforme os novos ficam prontos.
- **Zero indisponibilidade planejada:** `maxUnavailable: 0` e `maxSurge: 1` (ou mais), com **readiness probe** configurada. Sem readiness probe, o Pod é considerado pronto assim que o contêiner inicia, e o rollout avança mesmo

com a aplicação ainda carregando (capítulo 6).

- **Blue/green e canário** não são estratégias nativas do Deployment. São feitos com dois Deployments e um Service (ou Ingress/Gateway), ou com ferramentas como Argo Rollouts e Flagger.

5.4 Rollout e rollback

5.4.1 Acompanhar, pausar, voltar

```
kubectl rollout status deployment/web          # espera o fim (útil em CI; sai com erro se
estourar o prazo)
kubectl rollout history deployment/web          # revisões
kubectl rollout history deployment/web --revision=3  # template de uma revisão
kubectl annotate deployment/web kubernetes.io/change-cause="nginx 1.29.1: correção de segurança"
kubectl rollout undo deployment/web            # volta para a revisão anterior
kubectl rollout undo deployment/web --to-revision=2
kubectl rollout pause deployment/web            # junta várias mudanças...
kubectl set image deployment/web nginx=nginx:1.29.2
kubectl set resources deployment/web -c nginx --limits=memory=512Mi
kubectl rollout resume deployment/web           # ...em um único rollout
kubectl rollout restart deployment/web          # recria os Pods sem mudar a imagem
```

- **Rollback é um rollout para trás:** o Deployment volta a escalar o ReplicaSet da revisão anterior (que estava com 0 réplicas). A revisão restaurada recebe o **próximo número** de revisão e sai da lista com o número antigo: depois de voltar da revisão 3 para a 2, o histórico mostra 1, 3 e 4.
- **CHANGE-CAUSE:** preenchido pela anotação `kubernetes.io/change-cause`. A antiga flag `--record` está **obsoleta**.
- O rollback só é possível para revisões ainda guardadas (`revisionHistoryLimit`, padrão 10).
- `rollout restart` muda uma anotação de data no template, o que dispara um rollout normal: útil para recarregar ConfigMaps e Secrets lidos só na inicialização.
- `kubectl rollout` funciona com **Deployments, DaemonSets e StatefulSets**. ReplicaSets, Jobs e CronJobs não têm rollout.
- Rollout que não avança (imagem inexistente, Pods que nunca ficam prontos) é marcado com a condição `Progressing=False` e o motivo `ProgressDeadlineExceeded` depois de `progressDeadlineSeconds`. O Kubernetes **não faz rollback sozinho**: o `rollout status` falha, e a decisão de voltar é sua (ou da ferramenta de deploy).

5.5 ReplicaSet diretamente

5.5.1 Quando e por que não

- Um **ReplicaSet** mantém um número de Pods iguais. Ele **não atualiza** Pods existentes: se você mudar a imagem no template de um ReplicaSet, os Pods em execução continuam com a imagem antiga. Só os Pods criados **depois** (porque outro morreu ou foi apagado) usam a nova, e o grupo fica com versões misturadas.
- Por isso, crie **Deployments**, não ReplicaSets. O ReplicaSet criado à mão só faz sentido em cenários muito específicos de orquestração customizada.
- **Adoção de Pods:** um ReplicaSet assume qualquer Pod sem dono cujas labels casem com o seletor. Um Pod solto com as mesmas labels pode ser "adotado" e contar como réplica, e o ReplicaSet então cria menos Pods do que você esperava.
- **ReplicationController** é o antecessor do ReplicaSet (seletor só por igualdade) e está obsoleto.

- Apagar só o ReplicaSet mantendo os Pods: `kubectl delete rs <nome> --cascade=orphan`.

```
# Ver a imagem de cada Pod (útil para achar versões misturadas)
kubectl get pods -l app=web \
  -o custom-columns='POD:.metadata.name,IMAGEM:.spec.containers[*].image'
```

5.6 Decisão rápida — Deployments

Situação	Abordagem recomendada	Erro comum
Aplicação sem estado com várias réplicas	Deployment	ReplicaSet ou Pods soltos
Atualizar sem indisponibilidade	RollingUpdate com <code>maxUnavailable: 0</code> , <code>maxSurge ≥ 1</code> e <code>readiness probe</code>	RollingUpdate sem <code>readiness probe</code>
Versões antiga e nova não podem coexistir	Recreate (aceitando a janela de indisponibilidade)	RollingUpdate e torcer
Nova versão com problema	<code>kubectl rollout undo</code> e corrigir o manifesto no Git	Editar Pods à mão
Saber o motivo de cada revisão	Anotação <code>kubernetes.io/change-cause</code>	<code>--record</code> (obsoleto)
Várias mudanças em um só rollout	<code>rollout pause</code> , mudanças, <code>rollout resume</code>	Três rollouts seguidos
Recarregar configuração lida na inicialização	<code>kubectl rollout restart</code>	Apagar os Pods um por um
Pipeline deve falhar se o deploy não ficar saudável	<code>kubectl rollout status --timeout=5m</code>	<code>kubectl apply</code> e seguir
<code>kubectl get pods -l ...</code> não retorna nada	Conferir as labels do template (<code>kubectl get pods --show-labels</code>)	Filtrar pelas labels do Deployment
Mudar o seletor de um Deployment	Criar um Deployment novo (o seletor é imutável)	Editar o seletor e aplicar

DaemonSets e Probes

***Ideia central:** um **DaemonSet** garante um **Pod por nó** (ou por grupo de nós), inclusive nos nós que entrarem depois, e é a forma padrão de rodar agentes de infraestrutura. As **probes** dizem ao Kubernetes se um contêiner está **vivo** (liveness), **pronto para tráfego** (readiness) ou **ainda iniciando** (startup). Sem elas, o cluster só sabe se o processo existe.*

6.1 DaemonSet

6.1.1 Para que serve

- Roda uma cópia de um Pod em **cada nó elegível**. Nó novo no cluster ganha o Pod automaticamente; nó removido leva o Pod junto.
- Casos típicos: **coletores de logs** (Fluent Bit, Vector), **agentes de métricas** (Prometheus node-exporter, agente do Datadog), **plugins de rede** (Calico, Cilium) e o **kube-proxy**, **agentes de segurança** (Falco), drivers de armazenamento (CSI node plugin).
- **Não há replicas**: o número de Pods é o número de nós elegíveis.

```

apiVersion: apps/v1
kind: DaemonSet
metadata:
  name: node-exporter
  namespace: monitoring
spec:
  selector:
    matchLabels:
      app: node-exporter
  updateStrategy:
    type: RollingUpdate
    rollingUpdate:
      maxUnavailable: 1          # padrão: um nó por vez
  template:
    metadata:
      labels:
        app: node-exporter
    spec:
      hostNetwork: true          # usa a rede do nó (as métricas são do nó)
      hostPID: true
      tolerations:               # também roda nos nós de control plane
        - key: node-role.kubernetes.io/control-plane
          operator: Exists
          effect: NoSchedule
      containers:
        - name: node-exporter
          image: quay.io/prometheus/node-exporter:v1.9.1
          args:
            - --path.procfs=/host/proc
            - --path.sysfs=/host/sys
            - --path.rootfs=/host/root
          ports:
            - containerPort: 9100
          resources:
            requests: { cpu: 50m, memory: 32Mi }
            limits: { memory: 64Mi }
          volumeMounts:
            - { name: proc, mountPath: /host/proc, readOnly: true }
            - { name: sys, mountPath: /host/sys, readOnly: true }
            - { name: root, mountPath: /host/root, readOnly: true, mountPropagation: HostToContainer }
      volumes:
        - { name: proc, hostPath: { path: /proc } }
        - { name: sys, hostPath: { path: /sys } }
        - { name: root, hostPath: { path: / } }

```

- **Montar /proc e /sys não basta:** o node-exporter precisa saber onde eles estão (`--path.procfs` , `--path.sysfs`), senão lê o /proc do próprio contêiner.
- `hostNetwork: true` faz o Pod usar o IP e as portas do **nó**: com ela, a `containerPort` já é a porta do nó e não é preciso `hostPort`. Use com cuidado (conflito de portas, menos isolamento); é aceitável para agentes de nó.
- **Tolerations:** por padrão, os nós de control plane têm um taint que afasta Pods comuns. Agentes que precisam rodar também neles declaram a toleration correspondente. O DaemonSet já recebe automaticamente tolerations para nós com problemas (`not-ready` , `unreachable` , pressão de disco e de memória).
- **Só alguns nós:** `nodeSelector` (ex.: `gpu: "true"`) ou `affinity` no template.

6.1.2 Comandos e atualização

```
kubectl apply -f node-exporter.yaml
kubectl get daemonset -n monitoring # DESIRED, CURRENT, READY, UP-TO-DATE, AVAILABLE, NODE SELECTOR
kubectl get pods -n monitoring -l app=node-exporter -o wide # um por nó
kubectl describe ds node-exporter -n monitoring
kubectl rollout status ds/node-exporter -n monitoring
kubectl rollout undo ds/node-exporter -n monitoring
kubectl delete ds node-exporter -n monitoring
```

updateStrategy	Comportamento
RollingUpdate (padrão)	Troca os Pods nó a nó, respeitando <code>maxUnavailable</code> (padrão 1); <code>maxSurge</code> permite subir o novo antes de derrubar o antigo no mesmo nó
OnDelete	O template muda, mas cada Pod só é recriado quando você o apaga (controle manual, nó a nó)

- **Não existe** `kubectl create daemonset`. Para ter um esqueleto, gere um Deployment com `kubectl create deployment ... --dry-run=client -o yaml`, troque `kind` para `DaemonSet` e remova `replicas`, `strategy` e `status`.

6.2 Probes

6.2.1 Os três tipos

Probe	Pergunta	Se falhar	Quando usar
liveness-Probe	"O contêiner está vivo ou travou?"	O kubelet reinicia o contêiner (o Pod continua o mesmo)	Aplicações que podem travar sem sair (deadlock, loop)
readiness-Probe	"Pode receber tráfego agora?"	O Pod é retirado dos endpoints dos Services (não reinicia) e aparece como <code>0/1</code> em <code>READY</code>	Praticamente toda aplicação que recebe tráfego
startup-Probe	"Já terminou de iniciar?"	Após <code>failureThreshold × periodSeconds</code> , o contêiner é reiniciado	Aplicações de inicialização lenta; enquanto ela não passa, <code>liveness</code> e <code>readiness</code> não rodam

- A **readiness** roda durante **toda** a vida do contêiner, não só no início. Um Pod pode sair do balanceamento temporariamente (sobrecarga, dependência indisponível) e voltar sem reiniciar.
- Durante um **rollout**, o Deployment só considera um Pod novo disponível quando a `readiness` passa. É ela que impede que uma versão quebrada substitua a anterior.

6.2.2 Mecanismos de teste

Mecanismo	Sucesso quando	Exemplo
<code>httpGet</code>	Resposta HTTP de 200 a 399	<code>path: /healthz</code> , <code>port: 8080</code>
<code>tcpSocket</code>	A conexão TCP abre	<code>port: 5432</code>
<code>exec</code>	O comando termina com código 0	<code>command: ["pg_isready", "-U", "app"]</code>
<code>grpc</code>	O serviço de health do gRPC responde <code>SERVING</code>	<code>port: 9090</code>

6.2.3 Parâmetros

Campo	Padrão	Significado
<code>initialDelaySeconds</code>	0	Espera antes da primeira verificação
<code>periodSeconds</code>	10	Intervalo entre verificações
<code>timeoutSeconds</code>	1	Tempo máximo de cada verificação; passou disso, conta como falha
<code>successThreshold</code>	1	Sucessos seguidos para voltar a "ok" (liveness e startup só aceitam 1)
<code>failureThreshold</code>	3	Falhas seguidas para agir (reiniciar ou retirar do tráfego)
<code>terminationGracePeriodSeconds</code>	O do Pod	Tempo de encerramento quando a liveness ou a startup provoca reinício

- **Tempo até agir:** por volta de `failureThreshold × periodSeconds`. Com os padrões, uma aplicação travada é reiniciada em cerca de 30 s. O `timeoutSeconds` **não** é um intervalo entre tentativas: é o prazo de cada tentativa.

6.2.4 Exemplo completo

```
containers:
- name: api
  image: minha-org/api:2.3.0
  ports:
    - name: http
      containerPort: 8080
  startupProbe:
    # até 30 × 5 s = 150 s para iniciar
    httpGet: { path: /healthz, port: http }
    periodSeconds: 5
    failureThreshold: 30
  livenessProbe:
    # verifica só o próprio processo
    httpGet: { path: /healthz, port: http }
    periodSeconds: 10
    timeoutSeconds: 2
    failureThreshold: 3
  readinessProbe:
    # pode incluir dependências essenciais
    httpGet: { path: /ready, port: http }
    periodSeconds: 5
    timeoutSeconds: 2
    failureThreshold: 2
```

```
kubectl describe pod <pod>    # linhas Liveness:, Readiness:, Startup: e eventos "Unhealthy"
kubectl get pods -w           # READY 0/1 enquanto a readiness não passa; RESTARTS subindo se a
liveness falha
```

- Evento típico de falha: `Warning Unhealthy ... Liveness probe failed: HTTP probe failed with statuscode: 404`, seguido de `Container nginx failed liveness probe, will be restarted`.

6.2.5 Boas práticas e armadilhas

- **Liveness não deve depender de serviços externos:** se o banco cair e a liveness checar o banco, **todos** os Pods reiniciam em cadeia, sem resolver nada. Liveness verifica se **o processo** está saudável; dependências vão, no máximo, na readiness.

- **Não use** `initialDelaySeconds` **grande na liveness para "dar tempo" de iniciar**: use uma **startupProbe**. Ela protege a inicialização lenta sem atrasar a detecção de travamentos depois.
- **Mesma verificação e mesmos tempos em liveness e readiness** fazem o contêiner ser reiniciado no mesmo momento em que sai do tráfego. Deixe a liveness mais tolerante.
- `timeoutSeconds: 1` é curto para endpoints que fazem trabalho de verdade; sob carga, a probe falha e o contêiner reinicia justamente quando mais é preciso.
- **Endpoint leve**: `/healthz` não deve consultar tudo, gerar log a cada chamada nem exigir autenticação.
- `exec` **custa caro** em escala: cria um processo a cada verificação. Prefira HTTP, TCP ou gRPC.

6.3 Decisão rápida — DaemonSets e probes

Situação	Abordagem recomendada	Erro comum
Agente de logs ou métricas em todos os nós	DaemonSet com requests e limits pequenos	Deployment com réplicas iguais ao número de nós
Agente também nos nós de control plane	Toleration para <code>node-role.kubernetes.io/control-plane</code>	Remover o taint dos nós de control plane
Agente só nos nós com GPU	<code>nodeSelector</code> ou <code>affinity</code> no template do DaemonSet	Um DaemonSet por nó
Atualizar um DaemonSet crítico com controle manual	<code>updateStrategy: OnDelete</code>	Apagar o DaemonSet e criar de novo
Pod não deve receber tráfego enquanto carrega cache	<code>readinessProbe</code>	<code>livenessProbe</code> com <code>initialDelaySeconds</code> alto
Aplicação Java/.NET leva 2 minutos para subir	<code>startupProbe</code> com <code>failureThreshold × periodSeconds > tempo de subida</code>	Liveness que mata o contêiner antes de ele terminar de iniciar
Banco de dados fora do ar	Readiness pode refletir isso; liveness não	Liveness que checka o banco e reinicia tudo
Aplicação trava de vez em quando sem sair	<code>livenessProbe</code> no endpoint do próprio processo	Esperar alguém notar e apagar o Pod
Rollout avança com a versão nova quebrada	<code>readinessProbe</code> + <code>maxUnavailable: 0</code> + <code>rollout status</code> no pipeline	Rollout sem probes

Instalando um Cluster com kubeadm

Ideia central: o **kubeadm** é a ferramenta oficial para montar um cluster "de verdade" em máquinas próprias. Ele gera certificados, sobe o control plane como **Pods estáticos** e emite o comando de entrada dos nós. Mas não faz tudo: o runtime, os pacotes, o **plugin de rede (CNI)**, o balanceador do API server em alta disponibilidade e as atualizações são responsabilidade de quem opera.

7.1 Formas de ter um cluster

7.1.1 Comparação

Opção	O que é	Quando faz sentido
Serviço gerenciado (EKS, GKE, AKS)	O provedor opera o control plane, faz atualizações e alta disponibilidade	A maioria dos ambientes de produção em nuvem
kubeadm	Ferramenta oficial que monta o cluster nas suas máquinas	On-premises, estudo aprofundado, base de outras ferramentas
Kubespray	Playbooks Ansible que usam o kubeadm por baixo	Muitos nós, on-premises, automação com Ansible
kops	Cria e mantém clusters em nuvem pública (forte na AWS)	Quem quer operar o control plane na nuvem sem serviço gerenciado
Cluster API	Clusters descritos como objetos Kubernetes, gerenciados a partir de outro cluster	Frotas de clusters, plataformas internas
k3s, k0s, MicroK8s, Talos	Distribuições completas, prontas para produção	Edge, clusters pequenos, operação simplificada
kind, Minikube	Clusters locais	Estudo e testes (capítulo 3)

7.2 Preparar os nós

7.2.1 Requisitos

- Linux com **2 CPUs** e **2 GB de RAM** ou mais em cada máquina (o control plane precisa de pelo menos isso; os workers, do que as aplicações pedirem).
- Rede entre todos os nós; **hostname**, **endereço MAC** e `product_uuid` **únicos** em cada um.
- Portas liberadas (capítulo 2): **6443** no control plane, **10250** em todos os nós, **2379–2380** entre os membros do etcd, **30000–32767** se houver NodePort, e as **portas do CNI** escolhido. A porta 10255 (API somente leitura do kubelet) vem **desativada** em clusters kubeadm.
- Swap:** por padrão, o kubelet **não inicia** se detectar swap. Desative (`sudo swapoff -a` e remova a linha do `/etc/fstab`) ou configure explicitamente o kubelet para tolerá-la (`failSwapOn: false`), sabendo das implicações para limites de memória.

7.2.2 Módulos do kernel, sysctl e runtime

```
# Módulos e parâmetros de rede (em todos os nós)
cat <<EOF | sudo tee /etc/modules-load.d/k8s.conf
overlay
br_netfilter
EOF
sudo modprobe overlay && sudo modprobe br_netfilter

cat <<EOF | sudo tee /etc/sysctl.d/k8s.conf
net.ipv4.ip_forward = 1
net.bridge.bridge-nf-call-iptables = 1
net.bridge.bridge-nf-call-ip6tables = 1
EOF
sudo sysctl --system

# containerd (pacote containerd.io do repositório do Docker, ou o da distribuição)
sudo apt-get install -y containerd.io
sudo mkdir -p /etc/containerd
containerd config default | sudo tee /etc/containerd/config.toml
sudo sed -i 's/SystemdCgroup = false/SystemdCgroup = true/' /etc/containerd/config.toml
sudo systemctl restart containerd
```

- `net.ipv4.ip_forward` é obrigatório. Os parâmetros `bridge-nf-call-*` (e o módulo `br_netfilter`) são exigidos por muitos CNIs para que o tráfego das bridges passe pelo iptables.
- `SystemdCgroup = true` faz o containerd usar o driver de cgroup **systemd**, o mesmo que o kubeadm configura no kubelet. Confira no `config.toml` gerado que a chave existe e mudou: o formato do arquivo muda entre versões maiores do containerd. Nas versões recentes do Kubernetes, o kubelet também consegue descobrir o driver pelo próprio runtime.

7.2.3 Pacotes do Kubernetes

```
sudo apt-get update && sudo apt-get install -y apt-transport-https ca-certificates curl gpg
curl -fsSL https://pkgs.k8s.io/core:/stable:/v1.37/deb/Release.key \
| sudo gpg --dearmor -o /etc/apt/keyrings/kubernetes-apt-keyring.gpg
echo 'deb [signed-by=/etc/apt/keyrings/kubernetes-apt-keyring.gpg]
https://pkgs.k8s.io/core:/stable:/v1.37/deb/ /' \
| sudo tee /etc/apt/sources.list.d/kubernetes.list
sudo apt-get update
sudo apt-get install -y kubelet kubeadm kubectl
sudo apt-mark hold kubelet kubeadm kubectl # evita atualização acidental
sudo systemctl enable --now kubelet # fica reiniciando até o kubeadm init/join: é normal
```

- Os repositórios `pkgs.k8s.io` **têm um endereço por versão menor** (`v1.37`). Para atualizar para a 1.38, é preciso trocar a URL.
- Os antigos `apt.kubernetes.io` e `packages.cloud.google.com` foram **desativados** em 2024, e `apt-key` está descontinuado. Tutoriais com esses comandos não funcionam mais.

7.3 Criar o cluster

7.3.1 kubeadm init e kubeadm join

```
# No primeiro nó de control plane
sudo kubeadm init \
  --pod-network-cidr=10.244.0.0/16 \
  --apiserver-advertise-address=10.0.0.10
# Para alta disponibilidade, acrescente: --control-plane-endpoint=k8s-api.exemplo.local:6443 --upload-certs

mkdir -p $HOME/.kube
sudo cp -i /etc/kubernetes/admin.conf $HOME/.kube/config
sudo chown $(id -u):$(id -g) $HOME/.kube/config

# Instalar o CNI (exemplos: Calico, Cilium, Flannel), seguindo a documentação dele
kubectl get nodes          # NotReady até o CNI estar rodando

# Nos workers, com o comando impresso pelo init
sudo kubeadm join 10.0.0.10:6443 --token <token> \
  --discovery-token-ca-cert-hash sha256:<hash>

# Token expirado (validade padrão: 24 h)? Gere outro comando no control plane:
kubeadm token create --print-join-command
```

Fase do kubeadm init	O que faz
preflight	Verifica requisitos (swap, portas, runtime, módulos) e baixa imagens
certs	Cria a CA do cluster e os certificados em <code>/etc/kubernetes/pki</code>
kubeconfig	Gera <code>admin.conf</code> , <code>kubelet.conf</code> , <code>controller-manager.conf</code> , <code>scheduler.conf</code> e <code>super-admin.conf</code>
control-plane / etcd	Escreve os manifestos de Pods estáticos em <code>/etc/kubernetes/manifests</code>
mark-control-plane	Adiciona a label <code>node-role.kubernetes.io/control-plane</code> e o taint <code>NoSchedule</code>
bootstrap-token	Cria o token e as permissões para os nós entrarem
addons	Instala CoreDNS e kube-proxy

- **Pods estáticos:** o kubelet lê os arquivos de `/etc/kubernetes/manifests` e roda o API server, o scheduler, o controller-manager e o etcd como Pods, sem depender do API server para isso. Editar um desses arquivos recria o componente.
- `--pod-network-cidr` precisa combinar com a configuração do CNI e **não pode se sobrepor** à rede dos nós nem à faixa de Services (padrão `10.96.0.0/12`).
- `--discovery-token-ca-cert-hash` garante que o nó está entrando no cluster certo (evita um API server falso). O token autentica o nó; o hash autentica o cluster.
- **Alta disponibilidade:** use `--control-plane-endpoint` apontando para um **load balancer** (ou DNS) na frente dos API servers, desde o primeiro nó, e entre com os demais control planes usando `kubeadm join ... --control-plane --certificate-key <chave>`.

7.3.2 Kubeconfig do administrador

- O `admin.conf` tem três partes: `clusters` (endereço do API server e **CA** do cluster), `users` (o **certificado de cliente** e a **chave privada**, em base64) e `contexts`. O certificado identifica o usuário no grupo `kubeadm:cluster-admins`, com poder total.
- Quem tem esse arquivo **administra o cluster**. Distribua acessos individuais com RBAC (capítulo 17), não cópias do `admin.conf`.
- `kubectl config view` mostra o arquivo com os dados sensíveis omitidos (`--raw` mostra tudo).

7.3.3 Escolher o CNI

Plugin	Destaques
Calico	Muito usado; roteamento BGP ou overlay (VXLAN/IP-in-IP); NetworkPolicy completa e políticas próprias
Cilium	Baseado em eBPF ; NetworkPolicy em L3–L7, pode substituir o kube-proxy, observabilidade com Hubble; projeto graduado da CNCF
Flannel	Simples, overlay VXLAN; não aplica NetworkPolicy sozinho
Plugins das nuvens (AWS VPC CNI, Azure CNI, GKE Dataplane V2)	Pods com IPs da própria VPC; integração com a rede do provedor
Weave Net	Popular em tutoriais antigos; a Weaveworks encerrou as atividades em 2024 e o projeto deixou de ser mantido . Não use em clusters novos

- CNI** (*Container Network Interface*) é a especificação que o runtime usa para chamar o plugin quando um sandbox de Pod é criado. O Kubernetes **não traz** implementação de rede de Pods: sem um CNI, os nós ficam `NotReady` e o CoreDNS fica `Pending`.

7.4 Operar o cluster

7.4.1 Manutenção do dia a dia

```
kubectl describe node <nó>                # labels, taints, capacidade, alocável, Pods, condições
kubectl get nodes -o wide                  # versões do kubelet, do SO e do runtime
kubectl cordon <nó>                        # não recebe Pods novos
kubectl drain <nó> --ignore-daemonsets --delete-emptydir-data # esvazia para manutenção
kubectl uncordon <nó>                     # volta a receber Pods
sudo kubeadm certs check-expiration        # certificados do control plane valem 1 ano
sudo kubeadm upgrade plan                  # atualização: uma versão menor por vez
sudo kubeadm reset                         # desfaz init/join em um nó
```

- `Capacity` × `Allocatable`: o nó reserva parte dos recursos para o sistema e o kubelet; o scheduler usa o **Allocatable**. O limite padrão é de **110 Pods por nó**.
- Condições do nó**: `Ready`, `MemoryPressure`, `DiskPressure`, `PIDPressure`, `NetworkUnavailable`. Pressão de recursos leva o kubelet a **despejar** Pods (começando pelos `BestEffort`).
- Atualizações**: suba **uma versão menor por vez** (1.36 → 1.37), primeiro o control plane, depois os nós (com `drain`). Os certificados gerados pelo `kubeadm` são renovados automaticamente em cada `kubeadm upgrade`; clusters que não são atualizados por um ano param quando eles expiram.

7.5 Decisão rápida — Instalação

Situação	Abordagem recomendada	Erro comum
Produção em nuvem sem time dedicado à plataforma	Serviço gerenciado (EKS, GKE, AKS)	kubeadm em VMs "para economizar"
Nós <code>NotReady</code> logo após o <code>init</code>	Instalar o CNI com o CIDR usado no <code>--pod-network-cidr</code>	Reiniciar o kubelet
<code>kubeadm init</code> falha no preflight por swap	Desativar a swap (e no <code>/etc/fstab</code>) ou configurar o kubelet para tolerá-la	Usar <code>--ignore-preflight-errors=all</code>
Token do <code>join</code> expirou	<code>kubeadm token create --print-join-command</code>	Refazer o <code>init</code>
Control plane de produção	3 nós atrás de um load balancer (<code>--control-plane-endpoint</code>)	Um nó só, ou adicionar o endpoint depois
Manutenção de um nó	<code>kubectyl drain</code> e depois <code>uncordon</code>	Desligar o nó com Pods rodando
Tutorial usa <code>apt.kubernetes.io</code>	Repositório <code>pkgs.k8s.io</code> por versão menor	Insistir no repositório desativado
Tutorial instala Weave Net	Calico, Cilium ou o CNI da sua nuvem	Instalar um projeto sem manutenção
Cluster parou depois de um ano sem atualização	Renovar certificados (<code>kubeadm certs renew</code>) e passar a atualizar regularmente	Recriar o cluster

Volumes e Armazenamento Persistente

Ideia central: o Pod *pede* armazenamento com um *PersistentVolumeClaim* (PVC); o cluster *entrega* um *PersistentVolume* (PV), criado à mão pelo administrador ou, na prática quase sempre, *dinamicamente* por um driver CSI a partir de uma *StorageClass*. O Pod só conhece o PVC; o tipo de disco por baixo fica transparente.

8.1 Tipos de volume

8.1.1 Efêmeros e persistentes

Volume	Ciclo de vida	Uso
<code>emptyDir</code>	Nasce e morre com o Pod	Compartilhar arquivos entre contêineres, cache, temporários (capítulo 4)
<code>configMap</code> , <code>secret</code> , <code>downwardAPI</code> , <code>projected</code>	Do Pod	Entregar configuração, credenciais e metadados como arquivos (capítulo 11)
Volume efêmero genérico (<code>ephemeral</code>)	Do Pod, mas provisionado por uma <code>StorageClass</code>	Espaço temporário grande com as características de um disco de verdade
<code>hostPath</code>	Do nó	Agentes de nó (logs, métricas, sockets). Evite em aplicações: amarra o Pod ao nó e expõe o sistema de arquivos do host
<code>persistentVolumeClaim</code>	Independente do Pod	Dados que precisam sobreviver ao Pod (bancos, uploads)

8.2 StorageClass

8.2.1 O que define

```
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: rapido
  annotations:
    storageclass.kubernetes.io/is-default-class: "true" # classe padrão
provisioner: ebs.csi.aws.com # driver CSI que cria os volumes
parameters:
  type: gp3 # parâmetros próprios do driver
reclaimPolicy: Delete # o que fazer com o disco quando o PVC for apagado
volumeBindingMode: WaitForFirstConsumer # criar o disco só quando um Pod for agendado
allowVolumeExpansion: true # permitir aumentar PVCs
```

Campo	Opções
<code>reclaimPolicy</code>	<code>Delete</code> (padrão: apaga o PV e o disco) ou <code>Retain</code> (mantém o PV e os dados para recuperação manual). <code>Recycle</code> está obsoleto
<code>volumeBindingMode</code>	<code>Immediate</code> (padrão: cria e vincula na hora) ou <code>WaitForFirstConsumer</code> (espera o Pod ser agendado, para criar o disco na mesma zona do nó)

Campo	Opções
allowVolumeExpansion	Permite aumentar o PVC editando <code>spec.resources.requests.storage</code> . Diminuir não é possível

- **PVC sem** `storageClassName` usa a classe marcada como **padrão**. Mantenha **uma só** classe padrão. `storageClassName: ""` pede explicitamente um PV **sem** classe (vínculo estático).
- **CSI** (*Container Storage Interface*) é o padrão atual de drivers de armazenamento. Os provisionadores antigos embutidos no Kubernetes (`kubernetes.io/aws-ebs`, `kubernetes.io/gce-pd`, `kubernetes.io/azure-disk` e outros) foram **removidos** e substituídos por drivers CSI (`ebs.csi.aws.com`, `pd.csi.storage.gke.io`, `disk.csi.azure.com`). Em clusters antigos, classes com o nome in-tree ainda funcionam porque são redirecionadas ao driver CSI, que **precisa estar instalado** (no EKS, o add-on do EBS CSI driver).
- **Clusters locais**: o kind usa o provisionador `rancher.io/local-path` (classe `standard`), e o Minikube, o `k8s.io/minikube-hostpath`. Os dois gravam em diretórios do nó.
- `kubernetes.io/no-provisioner` indica que não há criação dinâmica: os PVs são criados à mão (é o caso de volumes `local`).
- **NFS**: não existe provisionador NFS embutido. Para criação dinâmica, instale o driver CSI de NFS (`nfs.csi.k8s.io`) ou um provisionador externo; sem isso, os PVs NFS são criados manualmente.

8.3 PersistentVolume e PersistentVolumeClaim

8.3.1 Vínculo estático (PV criado à mão)

```

apiVersion: v1
kind: PersistentVolume
metadata:
  name: pv-nfs-dados
  labels: { storage: nfs }
spec:
  capacity: { storage: 10Gi }
  accessModes: [ReadWriteMany]
  persistentVolumeReclaimPolicy: Retain
  storageClassName: nfs-manual
  mountOptions: [nfsvers=4.1]
  nfs:
    server: 10.0.0.50
    path: /exports/dados
---
apiVersion: v1
kind: PersistentVolumeClaim
metadata:
  name: dados
spec:
  accessModes: [ReadWriteMany]
  storageClassName: nfs-manual
  resources:
    requests: { storage: 10Gi }
  selector:
    matchLabels: { storage: nfs }      # opcional: escolher entre PVs pelas labels

```

8.3.2 Vínculo dinâmico (o caso comum)

```
apiVersion: v1
kind: PersistentVolumeClaim
metadata:
  name: dados-app
spec:
  accessModes: [ReadWriteOnce]
  storageClassName: rapido
  resources:
    requests: { storage: 20Gi }
---
# No Pod (ou no template do Deployment/StatefulSet)
spec:
  containers:
    - name: app
      image: nginx:1.29
      volumeMounts:
        - name: dados
          mountPath: /usr/share/nginx/html
  volumes:
    - name: dados
      persistentVolumeClaim:
        claimName: dados-app
```

8.3.3 Modos de acesso

Modo	Sigla	Significado
ReadWriteOnce	RWO	Leitura e escrita por um nó por vez (vários Pods no mesmo nó podem usar)
ReadOnlyMany	ROX	Somente leitura por vários nós
ReadWriteMany	RWX	Leitura e escrita por vários nós
ReadWriteOncePod	RWOP	Leitura e escrita por um único Pod no cluster inteiro

- O modo precisa ser **suportado pelo tipo de armazenamento**. Discos de bloco (EBS, Persistent Disk, Azure Disk) são **RWO**; RWX exige sistemas de arquivos de rede (NFS, EFS, Azure Files, CephFS).
- Volume local** × **hostPath**: os dois usam disco do nó, mas o **local** declara em qual nó está (**nodeAffinity** obrigatório), e o scheduler leva os Pods para lá. O **hostPath** não tem essa informação e é perigoso em clusters com vários nós.

8.3.4 Estados e ciclo de vida

Objeto	Estados
PV	Available (livre) → Bound (vinculado) → Released (PVC apagado, dados ainda lá) → Failed
PVC	Pending (sem PV compatível ou aguardando o primeiro Pod) → Bound

- PVC em Pending com WaitForFirstConsumer** é normal até um Pod que o use ser agendado (evento **waiting for first consumer to be created before binding**).
- PV Released com Retain** não volta sozinho a **Available**: os dados continuam lá, e o administrador decide o que fazer (recuperar, limpar e liberar removendo o **claimRef**, ou apagar).

- **Proteção:** um PVC em uso por um Pod não é apagado de imediato (finalizar `kubernetes.io/pvc-protection`); fica `Terminating` até o Pod sair.
- **Snapshots** (`VolumeSnapshot`) e **clonagem** de PVCs estão disponíveis quando o driver CSI suporta.

```
kubectl get sc          # classes, provisionador, reclaim policy, binding mode, padrão
kubectl get pv          # CAPACITY, ACCESS MODES, RECLAIM POLICY, STATUS, CLAIM
kubectl get pvc -A      # eventos de provisionamento e vínculo
kubectl describe pvc dados-app
```

8.4 Decisão rápida — Armazenamento

Situação	Abordagem recomendada	Erro comum
Banco de dados em nuvem	PVC com StorageClass de disco em bloco (CSI) e <code>WaitForFirstConsumer</code>	<code>hostPath</code>
Vários Pods em nós diferentes escrevendo nos mesmos arquivos	RWX em NFS/EFS/Azure Files	Disco em bloco RWO
Disco criado em outra zona e o Pod fica <code>Pending</code>	<code>volumeBindingMode: WaitForFirstConsumer</code>	<code>Immediate</code> em clusters multi-zona
Não perder dados se alguém apagar o PVC	<code>reclaimPolicy: Retain</code> (e backups/snapshots)	Confiar no <code>Delete</code> padrão
PVC ficou pequeno	<code>allowVolumeExpansion: true</code> e aumentar o request	Criar outro PVC e copiar à mão
PVC <code>Pending</code> para sempre	<code>describe pvc</code> : classe inexistente, driver CSI ausente, modo de acesso não suportado	Recriar o PVC repetidamente
NFS com criação automática de volumes	Driver CSI de NFS	Esperar que uma StorageClass com <code>no-provisioner</code> crie PVs
Disco local rápido em nós específicos	Volume local com <code>nodeAffinity</code>	<code>hostPath</code> em todos os nós
Classe <code>kubernetes.io/aws-ebs</code> sem funcionar	Instalar o driver EBS CSI (ou migrar para <code>ebs.csi.aws.-com</code>)	Procurar o provisionador in-tree, que foi removido

Services, EndpointSlices e DNS

*Ideia central: Pods mudam de IP o tempo todo. O **Service** dá a um grupo de Pods, escolhidos por **labels**, um **nome DNS** e um **IP virtual estáveis**, e distribui o tráfego entre os que estão **prontos**. O tipo do Service define de onde ele pode ser acessado: de dentro do cluster, das portas dos nós ou de um load balancer externo.*

9.1 Como um Service funciona

9.1.1 Seletor, EndpointSlices e kube-proxy

1. O Service declara um **seletor** (`app: web`).
 2. O controlador de EndpointSlices lista os Pods que casam com o seletor e **estão prontos** (readiness probe) e grava seus IPs e portas em objetos **EndpointSlice**.
 3. O **kube-proxy** de cada nó (ou o CNI com eBPF) programa regras que levam o tráfego do IP virtual do Service para esses endereços.
 4. O **CoreDNS** responde o nome do Service com o IP virtual.
- **EndpointSlices** substituem o antigo objeto **Endpoints**, que ficou **obsoleto** na versão 1.33 (continua existindo, com avisos). Consulte com `kubectl get endpointslices -l kubernetes.io/service-name=web`.
 - **Service sem endpoints** (seletor que não casa com nenhuma label, ou Pods não prontos) aceita a conexão e não tem para onde mandar: é a primeira coisa a conferir quando um Service "não responde".

9.1.2 Portas

```
apiVersion: v1
kind: Service
metadata:
  name: web
spec:
  selector:
    app: web
  ports:
    - name: http
      protocol: TCP
      port: 80           # porta do Service (quem chama usa esta)
      targetPort: 8080   # porta do contêiner (pode ser o nome da porta, ex.: http)
```

- `port` é a porta do Service; `targetPort`, a do contêiner (se omitido, igual a `port`); `nodePort`, a porta aberta em cada nó (só nos tipos NodePort e LoadBalancer).
- Services com **várias portas** exigem `name` em cada uma.

9.2 Tipos de Service

9.2.1 Visão geral

Tipo	Acessível de	Como
ClusterIP (padrão)	Dentro do cluster	IP virtual interno + nome DNS
NodePort	Fora do cluster, por IP-de-qualquer-nó:nodePort	Abre a mesma porta (faixa 30000–32767) em todos os nós; inclui um ClusterIP
LoadBalancer	Internet ou rede corporativa	Pede um balanceador ao provedor (cloud-controller-manager); inclui NodePort e ClusterIP
ExternalName	Dentro do cluster	Responde um CNAME para um nome DNS externo; não tem IP nem proxy
Headless (clusterIP: None)	Dentro do cluster	Sem IP virtual: o DNS devolve os IPs dos Pods diretamente

```
kubectl expose deployment web --port=80 --target-port=8080 # ClusterIP
kubectl expose deployment web --type=NodePort --port=80 --target-port=8080
kubectl expose deployment web --type=LoadBalancer --port=80 --target-port=8080
kubectl create service externalname banco --external-name=db.exemplo.com.br
kubectl get svc -o wide
kubectl describe svc web
```

- **LoadBalancer fora de nuvem:** sem um provedor, o `EXTERNAL-IP` fica `<pending>` para sempre. Em bare metal, use **MetalLB** ou similar; no kind, o **cloud-provider-kind**; no Minikube, `minikube tunnel`.
- **Um LoadBalancer por serviço custa caro** em nuvem. Para vários serviços HTTP, use **um** ponto de entrada (Ingress ou Gateway, capítulo 12).
- **ExternalName** aceita **nomes DNS**, não IPs. Para apontar para um IP fixo fora do cluster, crie um Service **sem seletor** e um EndpointSlice manual.
- `kubectl expose` também funciona com Pods, ReplicaSets, StatefulSets e até outro Service (para expor o mesmo conjunto de Pods com outro tipo), porque ele só copia o seletor.

9.2.2 Opções úteis

Campo	Efeito
<code>sessionAffinity: ClientIP</code>	Mantém um cliente no mesmo Pod (pelo IP de origem), com timeout configurável
<code>externalTrafficPolicy: Local</code>	Em NodePort e LoadBalancer, entrega só a Pods do nó que recebeu o tráfego: preserva o IP do cliente e evita um salto extra, mas pode desbalancear
<code>internalTrafficPolicy: Local</code>	Tráfego interno só para Pods do mesmo nó (útil com DaemonSets)
<code>trafficDistribution: PreferClose</code>	Prefere endpoints topologicamente próximos (mesma zona), reduzindo latência e custo entre zonas
<code>publishNotReadyAddresses: true</code>	Inclui Pods não prontos no DNS (usado por alguns sistemas distribuídos durante a descoberta)

9.3 DNS dentro do cluster

9.3.1 Nomes

Registro	Formato	Exemplo
Service	<code><serviço>.<namespace>.svc.cluster.local</code>	<code>redis.loja.svc.cluster.local</code>
Pod de um StatefulSet (via Service headless)	<code><pod>.<serviço>.<namespace>.svc.cluster.local</code>	<code>db-0.db.loja.svc.cluster.local</code>
Porta nomeada (SRV)	<code>_<code><porta></code>._<protocolo>.<serviço>.<namespace>.svc.cluster.local</code>	<code>_http._tcp.web.loja.svc.cluster.local</code>

- Dentro do **mesmo namespace**, basta o nome curto (`redis`); de outro namespace, `redis.loja`. O `/etc/resolv.conf` dos Pods tem os domínios de busca que completam o nome.
- Teste rápido: `kubectl run -it --rm dns --image=busybox:1.37 --restart=Never -- nslookup web.loja`.
- Variáveis de ambiente `<SERVIÇO>_SERVICE_HOST` também são injetadas nos Pods, mas só para Services que já existiam quando o Pod foi criado. Prefira o DNS.

9.4 Decisão rápida — Services

Situação	Abordagem recomendada	Erro comum
Comunicação entre microserviços	ClusterIP e nome DNS	IP de Pod fixo no código
Service não responde	<code>kubectl get endpointslices -l kubernetes.io/service-name=<svc></code> e conferir labels e readiness	Recriar o Service
Vários sites HTTP expostos	Um Ingress ou Gateway com um único LoadBalancer	Um LoadBalancer por aplicação
Precisar do IP real do cliente	<code>externalTrafficPolicy: Local</code> (ou cabeçalhos do proxy)	Ler o IP do nó como se fosse o cliente
Banco de dados fora do cluster com nome DNS	<code>ExternalName</code>	Endereço fixo em cada aplicação
Serviço externo com IP fixo	Service sem seletor + <code>EndpointSlice</code> manual	<code>ExternalName</code> com IP
LoadBalancer <code><pending></code> no bare metal	MetalLB ou similar	Esperar o provedor que não existe
Acessar um Pod específico de um StatefulSet	Service headless e o nome <code><pod>.<svc></code>	ClusterIP comum
Testar um Service da máquina local	<code>kubectl port-forward svc/<nome></code>	NodePort aberto na internet

StatefulSets

Ideia central: um *StatefulSet* gerencia Pods que **não são intercambiáveis**. Cada réplica tem **nome fixo com índice** (db-0, db-1), **nome DNS estável** (via Service headless) e **o próprio PVC**, que continua sendo dela mesmo quando o Pod é recriado em outro nó. É a base para bancos de dados, filas e sistemas distribuídos com consenso.

10.1 Garantias do StatefulSet

10.1.1 Deployment × StatefulSet

Aspecto	Deployment	StatefulSet
Nomes dos Pods	Aleatórios (web-5d8f7c9b6d-4kq2x)	Fixos e ordenados (db-0, db-1, db-2)
Identidade de rede	Qualquer Pod atende pelo Service	Cada Pod tem DNS próprio: db-0.db.<ns>.svc.cluster.local
Armazenamento	Um PVC compartilhado (ou nenhum)	Um PVC por réplica , criado a partir de volumeClaimTemplates
Criação e remoção	Em paralelo	Em ordem: 0, 1, 2 (cada um espera o anterior ficar pronto); remoção na ordem inversa
Pod recriado	Com outro nome, qualquer volume	Com o mesmo nome e o mesmo PVC

10.2 Criar um StatefulSet

10.2.1 Service headless e StatefulSet

```
apiVersion: v1
kind: Service
metadata:
  name: web
spec:
  clusterIP: None          # headless: o DNS devolve os IPs dos Pods
  selector:
    app: web
  ports:
    - name: http
      port: 80
---
apiVersion: apps/v1
kind: StatefulSet
metadata:
  name: web
spec:
  serviceName: web        # Service headless responsável pelo DNS dos Pods (crie-o antes ou junto)
  replicas: 3
  selector:
    matchLabels:
      app: web
  template:
    metadata:
      labels:
        app: web
    spec:
      containers:
        - name: nginx
          image: nginx:1.29
          ports:
            - name: http
              containerPort: 80
          volumeMounts:
            - name: dados
              mountPath: /usr/share/nginx/html
  volumeClaimTemplates:
    - metadata:
        name: dados
      spec:
        accessModes: [ReadWriteOnce]
        resources:
          requests: { storage: 1Gi }
```

```
kubectl apply -f web-sts.yaml
kubectl get sts web          # READY 3/3
kubectl get pods -l app=web  # web-0, web-1, web-2 (criados em ordem)
kubectl get pvc              # dados-web-0, dados-web-1, dados-web-2
kubectl exec web-0 -- sh -c 'echo "sou o web-0" > /usr/share/nginx/html/index.html'
kubectl run -it --rm t --image=busybox:1.37 --restart=Never -- wget -qO- http://web-0.web
kubectl delete pod web-0     # volta com o mesmo nome e o mesmo conteúdo
```

- **Nome dos PVCs:** <nome do volumeClaimTemplate>-<nome do StatefulSet>-<índice> (no exemplo, dados-web-0).
- Não existe `kubectl create statefulset`: StatefulSets são criados a partir de manifestos.

10.3 Escala, atualização e remoção

10.3.1 Comportamentos

Campo	Opções
<code>podManagementPolicy</code>	<code>OrderedReady</code> (padrão: um de cada vez, em ordem) ou <code>Parallel</code> (todos juntos; a ordem deixa de valer para criação e remoção)
<code>updateStrategy</code>	<code>RollingUpdate</code> (padrão: do maior índice para o menor, um por vez) ou <code>OnDelete</code> (só atualiza Pods que você apagar)
<code>rollingUpdate.partition</code>	Só atualiza Pods com índice maior ou igual ao valor: permite testar a versão nova em parte das réplicas (canário)
<code>persistentVolumeClaimRetentionPolicy</code>	<code>whenDeleted</code> e <code>whenScaled</code> : <code>Retain</code> (padrão) ou <code>Delete</code>
<code>ordinals.start</code>	Índice inicial diferente de 0

- **Os PVCs sobrevivem:** por padrão, nem reduzir réplicas nem apagar o StatefulSet apaga os PVCs. Voltar a escalar reaproveita os dados. Para limpar, apague os PVCs explicitamente (`kubectl delete pvc dados-web-0`) ou configure a política de retenção.
- **Apagar o StatefulSet não garante ordem de encerramento** dos Pods. Para um desligamento ordenado, escale para 0 antes de apagar.
- **StatefulSet não faz replicação de dados:** cada réplica tem o próprio disco, vazio no início. Sincronizar os dados entre elas é trabalho da aplicação (replicação do banco). Para bancos em produção, considere **operadores** (Cloud-NativePG, Percona, Strimzi) ou o serviço gerenciado da nuvem.

10.4 Decisão rápida — StatefulSets

Situação	Abordagem recomendada	Erro comum
Aplicação web sem estado	Deployment	StatefulSet "por garantia"
Cluster de banco, fila ou consenso (etcd, Kafka, Zookeeper)	StatefulSet + Service headless (ou um operador)	Deployment com um PVC compartilhado
Acessar um membro específico	<code><pod>.<serviço-headless></code>	IP do Pod
Testar versão nova em uma réplica	<code>rollingUpdate.partition</code>	Atualizar todas de uma vez
Liberar disco depois de reduzir réplicas	Apagar os PVCs ou usar <code>persistentVolumeClaimRetentionPolicy</code>	Esperar que o Kubernetes apague sozinho
Desligar tudo em ordem	Escalar para 0 e então apagar	<code>kubectl delete sts</code> direto
Banco de produção sem time especializado	Serviço gerenciado ou operador maduro	StatefulSet escrito do zero

ConfigMaps e Secrets

Ideia central: a mesma imagem deve rodar em todos os ambientes; o que muda é a **configuração**, entregue por **ConfigMaps** (dados comuns) e **Secrets** (dados sensíveis), como variáveis de ambiente ou arquivos. Um **Secret**, por padrão, é só **base64** guardado no **etcd**: a proteção real vem de **RBAC**, **criptografia em repouso** e, cada vez mais, de um **cofre externo** sincronizado com o cluster.

11.1 ConfigMaps

11.1.1 Criar

```
kubectl create configmap app-config --from-literal=LOG_LEVEL=info --from-literal=FEATURE_X=true
kubectl create configmap nginx-config --from-file=nginx.conf
kubectl create configmap app-env --from-env-file=app.env
kubectl get configmap nginx-config -o yaml
```

```
apiVersion: v1
kind: ConfigMap
metadata:
  name: app-config
data:
  LOG_LEVEL: info
  app.properties: |
    timeout=30
    retries=3
immutable: true           # campo de primeiro nível (não vai em metadata)
```

- Limite de **1 MiB** por ConfigMap (e por Secret): para arquivos grandes, use volumes.
- `immutable: true` impede alterações (é preciso apagar e recriar) e alivia o API server, que deixa de observar o objeto. O campo fica no **primeiro nível** do objeto, ao lado de `data`, e não dentro de `metadata`.

11.1.2 Consumir no Pod

```
spec:
  containers:
    - name: app
      image: minha-org/app:1.0
      env:
        - name: LOG_LEVEL                      # uma chave específica
          valueFrom:
            configMapKeyRef: { name: app-config, key: LOG_LEVEL }
      envFrom:
        - configMapRef: { name: app-env }      # todas as chaves como variáveis
      volumeMounts:
        - name: config
          mountPath: /etc/app                  # cada chave vira um arquivo
        - name: nginx
          mountPath: /etc/nginx/nginx.conf
          subPath: nginx.conf                 # um arquivo só, sem esconder o diretório
  volumes:
    - name: config
      configMap: { name: app-config }
    - name: nginx
      configMap: { name: nginx-config }
```

- **Atualizações:** arquivos montados de ConfigMap ou Secret **são atualizados** automaticamente no Pod (com atraso de até um minuto, aproximadamente), **exceto** quando montados com `subPath`. **Variáveis de ambiente nunca mudam** depois que o contêiner inicia. A aplicação precisa reler o arquivo, ou o Deployment precisa de um `kubectl rollout restart`.
- `subPath` monta um único arquivo sem esconder o resto do diretório (útil para `nginx.conf`), ao custo de perder as atualizações automáticas.

11.2 Secrets

11.2.1 Base64 não é criptografia

```
echo -n 'giropops' | base64          # Z2lyb3BvcHM= (-n evita codificar a quebra de linha)
echo -n 'Z2lyb3BvcHM=' | base64 -d  # giropops
```

- Base64 só transforma bytes em texto seguro para transporte. **Qualquer pessoa que leia o Secret decodifica o valor.**
- A proteção de um Secret depende de: **RBAC** restrito (quem pode `get / list` Secrets, ou criar Pods que os montem, pode lê-los), **criptografia em repouso no etcd** (`EncryptionConfiguration`, com KMS em clusters gerenciados; nas nuvens, muitas vezes já vem habilitada), e **não versionar** manifestos de Secret em texto no Git.

11.2.2 Tipos

Tipo	Uso	Como criar
Opaque	Dados arbitrários (senhas, tokens)	<code>kubectl create secret generic app --from-literal=senha=...</code>

Tipo	Uso	Como criar
kubernetes.io/docker-configjson	Credenciais de registry privado	<code>kubectl create secret docker-registry regcred --docker-server=... --docker-username=... --docker-password=...</code>
kubernetes.io/tls	Certificado e chave TLS (chaves <code>tls.crt</code> e <code>tls.key</code>)	<code>kubectl create secret tls site-tls --cert=site.crt --key=site.key</code>
kubernetes.io/basic-auth / ssh-auth	Credenciais básicas / chave SSH	Manifesto com os campos do tipo
kubernetes.io/service-account-token	Token de ServiceAccount de longa duração	Legado; hoje os tokens são emitidos sob demanda (capítulo 17)
bootstrap.kubernetes.io/token	Tokens de entrada de nós	Criado pelo <code>kubeadm</code>

```

apiVersion: v1
kind: Secret
metadata:
  name: app-secret
type: Opaque
stringData:      # texto puro: o API server converte para base64 em data
  DB_USER: app
  DB_PASSWORD: troque-me

```

- `data` exige valores em base64; `stringData` aceita texto e é mais prático para escrever (mas continua sendo texto aberto no arquivo).
- Registry privado:** o Secret `dockerconfigjson` é usado em `spec.imagePullSecrets` do Pod, ou associado à **ServiceAccount** para valer em todos os Pods que a usam (`kubectl patch serviceaccount default -p '{"imagePullSecrets":[{"name":"regcred"}]}'`).
- Montar como arquivo é preferível a variável de ambiente:** variáveis aparecem em `/proc`, em dumps de erro e são herdadas por processos filhos. Arquivos de Secret ficam em **tmpfs** no nó.

11.2.3 Exemplo: nginx com HTTPS

```

openssl req -x509 -nodes -days 365 -newkey rsa:2048 \
  -keyout tls.key -out tls.crt -subj "/CN=localhost"      # autoassinado, só para teste
kubectl create secret tls nginx-tls --cert=tls.crt --key=tls.key
kubectl create configmap nginx-config --from-file=nginx.conf

```

```

apiVersion: v1
kind: Pod
metadata:
  name: nginx-https
  labels: { app: nginx-https }
spec:
  containers:
    - name: nginx
      image: nginx:1.29
      ports:
        - containerPort: 443
      volumeMounts:
        - name: config
          mountPath: /etc/nginx/nginx.conf
          subPath: nginx.conf
        - name: tls
          mountPath: /etc/nginx/tls
          readOnly: true
  volumes:
    # no nível do Pod, não dentro do contêiner
    - name: config
      configMap: { name: nginx-config }
    - name: tls
      secret:
        secretName: nginx-tls
        # arquivos /etc/nginx/tls/tls.crt e tls.key

```

- No `nginx.conf`, aponte `ssl_certificate /etc/nginx/tls/tls.crt`; e `ssl_certificate_key /etc/nginx/tls/tls.key`; . Para renomear os arquivos, use `items` com as chaves **reais** do Secret (`key: tls.crt`, `path: certificado.crt`).
- Teste com `kubectl port-forward pod/nginx-https 8443:443` e `curl -k https://localhost:8443`.

11.3 Segredos em cofres externos

11.3.1 External Secrets Operator

O **External Secrets Operator (ESO)** busca segredos em cofres externos (AWS Secrets Manager, HashiCorp Vault/OpenBao, Google Secret Manager, Azure Key Vault e outros) e cria **Secrets do Kubernetes** a partir deles, sincronizando periodicamente.

Recurso	Papel
SecretStore	Como acessar o cofre (endereço e autenticação), válido em um namespace
ClusterSecretStore	O mesmo, válido para todos os namespaces
ExternalSecret	Quais chaves buscar, de qual store, e qual Secret criar (com <code>refreshInterval</code>)

```

helm repo add external-secrets https://charts.external-secrets.io
helm install external-secrets external-secrets/external-secrets -n external-secrets --create-namespace

```

```

apiVersion: external-secrets.io/v1
kind: ClusterSecretStore
metadata:
  name: vault
spec:
  provider:
    vault:
      server: "http://vault.vault.svc:8200"
      path: "secret"
      version: "v2" # engine KV versão 2
      auth:
        kubernetes: # autenticação pela ServiceAccount, sem token fixo
          mountPath: "kubernetes"
          role: "external-secrets"
---
apiVersion: external-secrets.io/v1
kind: ExternalSecret
metadata:
  name: postgres
  namespace: loja
spec:
  refreshInterval: 1h
  secretStoreRef: { name: vault, kind: ClusterSecretStore }
  target:
    name: postgres-secret # Secret criado e mantido pelo ESO
  data:
    - secretKey: POSTGRES_PASSWORD
      remoteRef: { key: postgres, property: password }

```

- A API atual do ESO é `external-secrets.io/v1`. Exemplos com `v1beta1` são de versões anteriores.
- **Autentique pelo mecanismo do provedor** (Kubernetes auth no Vault, IAM Roles/Pod Identity na AWS, Workload Identity no GCP e no Azure) em vez de guardar um token de longa duração em um Secret.
- **Vault em modo `-dev`** guarda tudo em memória, sem selo: só para laboratório. Em produção, o Vault precisa de armazenamento, *unseal* (preferencialmente automático via KMS) e backup. O **OpenBao** é o fork open source mantido pela Linux Foundation.
- **Alternativas ao ESO:** o **Secrets Store CSI Driver** (monta segredos do cofre como arquivos, sem criar Secrets) e o **Sealed Secrets** (criptografa Secrets para poderem ser guardados no Git).

11.4 Decisão rápida — Configuração e segredos

Situação	Abordagem recomendada	Erro comum
Mesma imagem em dev, homologação e produção	ConfigMaps e Secrets por ambiente	Uma imagem por ambiente
Arquivo de configuração completo (nginx.conf)	ConfigMap montado como volume (<code>subPath</code> para um arquivo)	Copiar o arquivo na imagem
Configuração deve mudar sem recriar o Pod	Volume sem <code>subPath</code> + aplicação que relê o arquivo	Variável de ambiente
Configuração lida só na inicialização	<code>kubectl rollout restart</code> depois de alterar	Esperar que o Pod perceba sozinho
Senha de banco	Secret montado como arquivo, com RBAC restrito	ConfigMap ou variável no manifesto versionado

Situação	Abordagem recomendada	Erro comum
Imagem de registry privado	Secret <code>docker-registry</code> + <code>imagePullSecrets</code> (ou na <code>ServiceAccount</code>)	Imagem pública com credencial embutida
Certificado TLS	Secret <code>kubernetes.io/tls</code> (ou <code>cert-manager</code> , capítulo 12)	Certificado dentro da imagem
Segredos centralizados, com rotação e auditoria	Cofre externo + External Secrets Operator	Secrets copiados à mão entre clusters
Manifestos de Secret no Git	Sealed Secrets, SOPS ou cofre externo	Base64 no repositório

Ingress, Gateway API e Certificados

Ideia central: o **Ingress** descreve regras de entrada HTTP/HTTPS (por host e caminho) para Services; quem as executa é um **Ingress Controller**, que não vem no Kubernetes. A API Ingress está **congelada**, e o controlador mais usado, o **ingress-nginx**, foi **aposentado em março de 2026**. Para clusters novos, o caminho é a **Gateway API**. O **cert-manager** emite e renova os certificados TLS nos dois modelos.

12.1 Ingress

12.1.1 Componentes

Peça	Papel
Ingress Controller	Proxy reverso que roda no cluster (NGINX, Traefik, HAProxy, Contour, Kong, controladores das nuvens) e lê os objetos Ingress. Normalmente exposto por um Service LoadBalancer
IngressClass	Diz qual controlador atende qual Ingress (spec.ingressClassName). Uma classe pode ser marcada como padrão
Ingress	Regras: host, caminho, Service de destino, TLS
Annotations	Configurações específicas do controlador (reescrita, autenticação, limites). Não são portáteis entre controladores

```
apiVersion: networking.k8s.io/v1
kind: Ingress
metadata:
  name: loja
  namespace: loja
spec:
  ingressClassName: nginx
  tls:
    - hosts: [loja.exemplo.com.br]
      secretName: loja-tls # Secret TLS no MESMO namespace do Ingress
  rules:
    - host: loja.exemplo.com.br
      http:
        paths:
          - path: /
            pathType: Prefix
            backend:
              service:
                name: loja-web # Service no MESMO namespace
                port: { number: 5000 }
          - path: /api
            pathType: Prefix
            backend:
              service: { name: loja-api, port: { number: 8080 } }
```

pathType	Casa quando
----------	-------------

pathType	Casa quando
Exact	O caminho é exatamente igual
Prefix	O caminho começa com o prefixo, por segmentos (/api casa /api e /api/v1, mas não /apiv1)
ImplementationSpecific	Depende do controlador

- **Cuidado com a estrutura das regras:** `host` e `http` pertencem ao **mesmo item** da lista `rules`. Escrever `- host: x` e `- http: ...` como dois itens cria uma regra sem caminhos e outra **sem host**, que passa a responder para **qualquer** nome.
- **Reescrita de caminho** (`nginx.ingress.kubernetes.io/rewrite-target`) serve para publicar a aplicação em um subcaminho (/app) quando ela espera / . Aplicações que geram links absolutos (CSS, JS) costumam quebrar com isso; a solução definitiva é a aplicação aceitar um prefixo configurável, ou publicar em um host próprio.
- **Testar sem DNS:** `curl -H "Host: loja.exemplo.com.br" http://<IP-do-controlador>/` ou uma entrada no `/etc/hosts`.
- **No kind**, o controlador precisa receber as portas 80 e 443 do host: crie o cluster com `extraPortMappings` e a label `ingress-ready=true` no nó e instale a variante "kind" do manifesto do controlador.

12.1.2 ingress-nginx aposentado

- O projeto **kubernetes/ingress-nginx** (o "NGINX Ingress" da comunidade Kubernetes) **encerrou a manutenção em março de 2026**: não há mais versões, correções nem **patches de segurança**. Instalações existentes continuam funcionando, e as imagens e charts seguem disponíveis, mas o risco cresce com o tempo.
- **Não confunda** com o **NGINX Ingress Controller da F5/NGINX** (`nginx/kubernetes-ingress`), outro projeto, ainda mantido, com annotations diferentes (`nginx.org/...`).
- **Caminhos de migração:** Gateway API com uma implementação mantida (Envoy Gateway, NGINX Gateway Fabric, Istio, Cilium, Traefik, Kong, controladores das nuvens) ou outro controlador de Ingress mantido. A ferramenta **ingress2gateway** converte Ingress em recursos da Gateway API.
- As annotations `nginx.ingress.kubernetes.io/*` usadas em tutoriais (autenticação básica, afinidade por cookie, *upstream hash*, canário por peso, limite de requisições) só existem nesse controlador. Na Gateway API, várias dessas funções viraram campos padronizados.

Recurso no ingress-nginx (annotation)	Efeito
<code>auth-type: basic + auth-secret</code>	Pede usuário e senha (arquivo <code>htpasswd</code> em um Secret com a chave <code>auth</code>)
<code>affinity: cookie</code>	Mantém o usuário no mesmo Pod por meio de um cookie
<code>upstream-hash-by: "\$request_uri"</code>	Escolhe o Pod por hash de um valor da requisição
<code>canary: "true" + canary-weight: "10"</code>	Envia 10% do tráfego para outro Service (um segundo Ingress com o mesmo host)
<code>limit-rps: "10"</code>	Limita requisições por segundo por IP de cliente; excedentes recebem erro (503 por padrão)

12.2 Gateway API

12.2.1 Modelo

Recurso	Quem mantém	Papel
GatewayClass	Provedor da implementação	"Qual controlador" (como a IngressClass)

Recurso	Quem mantém	Papel
Gateway	Time de plataforma	Pontos de entrada: portas, protocolos, certificados, quais namespaces podem se conectar
HTTPRoute, GRPCRoute (e TLSRoute, TCPRoute, UDPRoute)	Times das aplicações	Regras de roteamento para os Services
ReferenceGrant	Dono do recurso referenciado	Autoriza referências entre namespaces

```

apiVersion: gateway.networking.k8s.io/v1
kind: Gateway
metadata:
  name: publico
  namespace: infra
spec:
  gatewayClassName: envoy-gateway          # depende da implementação instalada
  listeners:
    - name: https
      protocol: HTTPS
      port: 443
      hostname: "*.exemplo.com.br"
      tls:
        certificateRefs: [{ name: wildcard-tls }]
      allowedRoutes:
        namespaces: { from: All }
  ---
apiVersion: gateway.networking.k8s.io/v1
kind: HTTPRoute
metadata:
  name: loja
  namespace: loja
spec:
  parentRefs: [{ name: publico, namespace: infra }]
  hostnames: [loja.exemplo.com.br]
  rules:
    - matches: [{ path: { type: PathPrefix, value: / } }]
      backendRefs:
        - { name: loja-web-v1, port: 5000, weight: 90 }    # canário por peso, sem annotations
        - { name: loja-web-v2, port: 5000, weight: 10 }

```

- **Vantagens sobre o Ingress:** papéis separados (plataforma × aplicação), recursos padronizados (pesos, cabeçalhos, redirecionamentos, reescrita, espelhamento de tráfego) em vez de annotations proprietárias, suporte a gRPC, TCP e UDP.
- A Gateway API é instalada como **CRDs** (não vem por padrão em todo cluster) e precisa de uma **implementação** instalada.

12.3 Certificados com cert-manager

12.3.1 Como funciona

O **cert-manager** (projeto CNCF, versão 1.21 em set/2026) pede, instala e **renova** certificados automaticamente, a partir de autoridades como **Let's Encrypt** (protocolo **ACME**), Vault, Venafi ou uma CA própria.

Recurso	Papel
Issuer / ClusterIssuer	Autoridade e forma de validação (um namespace / o cluster todo)
Certificate	Certificado desejado; resulta em um Secret TLS
CertificateRequest, Order, Challenge	Etapas internas da emissão (úteis para depurar)

Desafio ACME	Como prova a posse do domínio	Observações
HTTP-01	Publica um arquivo em <code>http://<domínio>/.well-known/acme-challenge/...</code>	Exige a porta 80 acessível da internet; não emite curingas (<code>*.domínio</code>)
DNS-01	Cria um registro TXT no DNS	Emite curingas; precisa de credenciais do provedor de DNS

```
apiVersion: cert-manager.io/v1
kind: ClusterIssuer
metadata:
  name: letsencrypt-prod
spec:
  acme:
    server: https://acme-v02.api.letsencrypt.org/directory # staging: acme-staging-v02...
    privateKeySecretRef: { name: letsencrypt-prod-conta }
    solvers:
      - http01:
          ingress:
            ingressClassName: nginx
```

- No Ingress, basta a annotation `cert-manager.io/cluster-issuer: letsencrypt-prod` (ou `cert-manager.io/issuer` para um Issuer do namespace) e o bloco `tls` com `secretName`: o cert-manager cria o Certificate e mantém o Secret. Com a Gateway API, o cert-manager também emite certificados a partir dos listeners do Gateway.
- Teste com o ambiente staging** do Let's Encrypt: ele tem limites de emissão bem mais altos. Erros repetidos no ambiente de produção esbarram nos **limites de emissão** e bloqueiam novos certificados por um tempo.
- Depurar:** `kubectl get certificate,certificaterequest,order,challenge -A` e `kubectl describe` do recurso preso.

12.4 Decisão rápida — Entrada de tráfego

Situação	Abordagem recomendada	Erro comum
Cluster novo precisa de entrada HTTP/HTTPS	Gateway API com uma implementação mantida	Instalar o ingress-nginx, já aposentado
Cluster existente com ingress-nginx	Planejar migração (Gateway API ou controlador mantido); ingress2gateway ajuda	Ignorar a ausência de patches de segurança
Vários sites em um único IP	Regras por host (Ingress ou HTTPRoute)	Um LoadBalancer por site
Ingress não pega o tráfego	<code>ingressClassName</code> certo, Service e Secret no mesmo namespace	Criar o Ingress em outro namespace
Regra responde para qualquer host	Conferir se <code>host</code> e <code>http</code> estão no mesmo item de <code>rules</code>	Separar host e caminhos em itens diferentes
HTTPS com renovação automática	cert-manager + ClusterIssuer ACME	Certificado manual que expira
Certificado curinga	DNS-01	HTTP-01

Situação	Abordagem recomendada	Erro comum
Testar emissão de certificados	ACME staging primeiro	Repetir tentativas na produção
Canário por porcentagem	<code>weight</code> em HTTPRoute (ou annotations do controlador em uso)	Duplicar Deployments sem controle de tráfego
Proteger um painel com senha	Autenticação no controlador ou em um proxy de identidade (OAuth2 Proxy)	Deixar o painel público

Metrics Server e Autoescalonamento

Ideia central: o **Metrics Server** coleta CPU e memória de nós e Pods para o `kubectl top` e para o **HorizontalPodAutoscaler (HPA)**, que ajusta o número de réplicas para manter uma métrica perto de um alvo. O HPA calcula a utilização **em relação aos requests**: sem requests, não há o que escalar. Para métricas de negócio e eventos, entram adaptadores de métricas e o **KEDA**; para nós, o **Cluster Autoscaler** ou o **Karpenter**.

13.1 Metrics Server

13.1.1 Instalação e uso

```
kubectl apply -f https://github.com/kubernetes-sigs/metrics-server/releases/latest/download/components.yaml
minikube addons enable metrics-server # no Minikube

# kind e clusters de laboratório com certificados autoassinados no kubelet:
kubectl patch deployment metrics-server -n kube-system --type=json \
  -p '[{"op": "add", "path": "/spec/template/spec/containers/0/args/-", "value": "--kubelet-insecure-tls"}]'

kubectl get apiservice v1beta1.metrics.k8s.io # AVAILABLE deve ser True
kubectl top nodes
kubectl top pods -A --sort-by=memory
kubectl top pod <pod> --containers
```

- O Metrics Server lê os dados do **kubelet** de cada nó (por padrão a cada 15 s) e os expõe pela API agregada `metrics.k8s.io`. Ele guarda só o valor mais recente, em memória.
- **Não é ferramenta de monitoramento:** não tem histórico, gráficos nem alertas. Para isso, use Prometheus (ou o serviço de observabilidade da nuvem).
- Erro `Metrics API not available` ou `x509: cannot validate certificate`: o Metrics Server não consegue falar com os kubelets. Em clusters de estudo, `--kubelet-insecure-tls` resolve; em produção, o certo é o kubelet ter certificados válidos.

13.2 HorizontalPodAutoscaler

13.2.1 Manifesto

```
apiVersion: autoscaling/v2
kind: HorizontalPodAutoscaler
metadata:
  name: web
spec:
  scaleTargetRef:
    apiVersion: apps/v1
    kind: Deployment
    name: web
  minReplicas: 3
  maxReplicas: 10
  metrics:
    - type: Resource
      resource:
        name: cpu
        target:
          type: Utilization
          averageUtilization: 60          # % do REQUEST de CPU, na média dos Pods
    - type: Resource
      resource:
        name: memory
        target:
          type: AverageValue
          averageValue: 400Mi
  behavior:
    scaleUp:
      stabilizationWindowSeconds: 0
      policies:
        - { type: Percent, value: 100, periodSeconds: 15 }    # pode dobrar a cada 15 s
    scaleDown:
      stabilizationWindowSeconds: 300          # olha 5 min antes de reduzir
      policies:
        - { type: Pods, value: 2, periodSeconds: 60 }        # remove no máximo 2 Pods por minuto
```

```
kubectl autoscale deployment web --cpu-percent=60 --min=3 --max=10    # forma imperativa
kubectl get hpa -w              # TARGETS (atual/alvo), MINPODS, MAXPODS, REPLICAS
kubectl describe hpa web        # condições e eventos de cada decisão
```

- A API atual é `autoscaling/v2`. As versões `v2beta1` e `v2beta2` foram **removidas** (1.25 e 1.26); exemplos com elas não são aceitos por clusters atuais.
- Métrica** `ContainerResource` (estável desde a 1.30) usa o consumo de **um contêiner** do Pod, ignorando sidecars: `type: ContainerResource` com `container: <nome>`.

13.2.2 Algoritmo

réplicas desejadas = $\lceil \text{réplicas atuais} \times (\text{valor atual da métrica} \div \text{valor alvo}) \rceil$

Situação	Cálculo	Resultado
----------	---------	-----------

Situação	Cálculo	Resultado
2 réplicas, CPU média em 90%, alvo 60%	$\lceil 2 \times 90/60 \rceil = \lceil 3 \rceil$	3 réplicas
4 réplicas, CPU em 80%, alvo 50%	$\lceil 4 \times 1,6 \rceil = \lceil 6,4 \rceil$	7 réplicas
5 réplicas, CPU em 30%, alvo 50%	$\lceil 5 \times 0,6 \rceil$	3 réplicas (depois da janela de estabilização)

- O controlador roda a cada **15 s** e ignora variações dentro de uma **tolerância de 10%** (sem mudança se a razão estiver entre 0,9 e 1,1).
- **Várias métricas:** calcula o número de réplicas para cada uma e usa o **maior**.
- **Pods que ainda não estão prontos** ou sem métricas são tratados de forma conservadora para não provocar escalonamento errado durante a inicialização. Readiness e startup probes bem configuradas ajudam.
- A redução espera a **janela de estabilização** (padrão **300 s**) para evitar oscilações; o aumento é imediato por padrão.
- **Requests obrigatórios:** `averageUtilization` é uma porcentagem do **request**. Contêiner sem request de CPU → o HPA mostra `<unknown>` e não age.

13.2.3 Teste de carga

```
kubectl create deployment web --image=nginx:1.29
kubectl set resources deployment web --requests=cpu=100m --limits=cpu=200m
kubectl expose deployment web --port=80 # o gerador de carga precisa do Service
kubectl autoscale deployment web --cpu-percent=50 --min=1 --max=10
kubectl run carga -it --rm --image=busybox:1.37 --restart=Never -- \
  sh -c 'while true; do wget -q -O- http://web > /dev/null; done'
kubectl get hpa web -w # em outro terminal
```

13.2.4 Outros escaladores

Ferramenta	O que escala	Quando usar
HPA com métricas personalizadas (Prometheus Adapter)	Réplicas, por métricas da aplicação (requisições por segundo, latência)	CPU e memória não refletem a carga real
KEDA (CNCF)	Réplicas, a partir de eventos (tamanho de fila, Kafka, cron, métricas externas), inclusive para zero	Workers de fila, cargas intermitentes
VerticalPodAutoscaler	Requests e limits dos contêineres	Descobrir o tamanho certo; não combine com HPA na mesma métrica
Cluster Autoscaler / Karpenter	Nós do cluster	Pods Pending por falta de capacidade; nós ociosos

- HPA e o número de nós se complementam: o HPA cria Pods; se não houver espaço, eles ficam `Pending`, e o auto-escalador de nós adiciona máquinas.
- Com HPA, **retire** replicas **do manifesto** do Deployment (ou do `values.yaml` do Helm), senão cada `apply` volta o número ao valor fixo.

13.3 Decisão rápida — Autoescalamento

Situação	Abordagem recomendada	Erro comum
----------	-----------------------	------------

Situação	Abordagem recomendada	Erro comum
<code>kubectl top</code> retorna erro	Instalar o Metrics Server (e <code>--kubelet-insecure-tls</code> em laboratório)	Procurar métricas no Prometheus
HPA com TARGETS <unknown>	Definir requests de CPU/memória e conferir o Metrics Server	Aumentar <code>maxReplicas</code>
Escalar por fila de mensagens	KEDA	HPA por CPU
Réplicas oscilando	<code>behavior.scaleDown.stabilizationWindowSeconds</code> e políticas de ritmo	Diminuir o alvo repetidamente
Pods novos ficam Pending durante picos	Cluster Autoscaler ou Karpenter	Só aumentar o <code>maxReplicas</code>
Não sabe quanto pedir de CPU e memória	VPA em modo recomendação	Chutar valores e nunca revisar
<code>kubectl apply</code> desfaz o escalonamento	Tirar <code>replicas</code> do manifesto	Brigar com o HPA a cada deploy
Monitorar histórico de uso	Prometheus/Grafana	Metrics Server

Agendamento: Taints, Tolerations e Afinidade

Ideia central: o scheduler decide **onde** cada Pod roda. **Labels nos nós + nodeSelector/nodeAffinity** atraem Pods para certos nós. **Taints** repelem Pods de nós, e **tolerations** permitem (mas não obrigam) que um Pod ignore um taint. **podAffinity/podAntiAffinity** e **topologySpreadConstraints** aproximam ou espalham Pods em relação a outros Pods, por nó, zona ou região.

14.1 Labels nos nós

14.1.1 Organizar o cluster

```
kubectl label nodes worker-1 topology.kubernetes.io/region=br-sp topology.kubernetes.io/zone=br-sp-1
kubectl label nodes worker-1 gpu=true
kubectl label nodes worker-1 gpu- # remove a label
kubectl get nodes -L topology.kubernetes.io/zone,gpu
kubectl get nodes --show-labels
```

- **Labels bem conhecidas:** `kubernetes.io/hostname`, `kubernetes.io/os`, `kubernetes.io/arch`, `node.kubernetes.io/instance-type`, `topology.kubernetes.io/region`, `topology.kubernetes.io/zone`. Em nuvem, as de topologia e tipo de instância já vêm preenchidas. Use essas chaves em vez de inventar `region` e `datacenter`: ferramentas do ecossistema as entendem.
- `nodeSelector`, a forma mais simples de escolher nós: `spec.nodeSelector: { gpu: "true" }` (valores são strings: use aspas em `"true"`).

14.2 Taints e tolerations

14.2.1 Efeitos

Efeito	Pods novos sem toleration	Pods que já estão no nó
NoSchedule	Não são agendados	Continuam
PreferNoSchedule	O scheduler evita , mas usa o nó se não houver outro	Continuam
NoExecute	Não são agendados	São despejados (os que toleram podem ficar por <code>tolerationSeconds</code>)

```
kubectl taint nodes worker-1 gpu=true:NoSchedule # aplica
kubectl taint nodes worker-1 gpu=true:NoSchedule- # remove (sufixo -)
kubectl describe node worker-1 | grep Taints
```

```
spec:
  tolerations:
    - key: gpu
      operator: Equal          # ou Exists (qualquer valor da chave)
      value: "true"
      effect: NoSchedule
  nodeSelector:
    gpu: "true"               # toleration + seletor = roda SÓ nos nós com GPU
```

- **Toleration não atrai:** ela só permite que o Pod vá para o nó com taint. Para **garantir** que vá, combine com `nodeSelector` ou `nodeAffinity`. Para **reservar** nós a certos Pods, use os dois: taint (afasta os outros) e afinidade (atrai os escolhidos).
- **Taints automáticos:** o control plane recebe `node-role.kubernetes.io/control-plane:NoSchedule`; nós com problemas recebem `node.kubernetes.io/not-ready` e `node.kubernetes.io/unreachable` (`NoExecute`), e os Pods comuns ganham tolerations automáticas de **300 s** para eles: é por isso que um Pod leva cerca de 5 minutos para ser recriado em outro nó quando o nó dele cai. Há também taints de pressão (`memory-pressure`, `disk-pressure`).
- **Reorganizar Pods:** remover um taint `NoSchedule` não move os Pods que já estão em outros nós. O scheduler só age em Pods **novos**; um `kubectl rollout restart` redistribui. Para rebalanceamento contínuo, existe o **Descheduler**.
- **Manutenção de nó:** prefira `kubectl cordon + kubectl drain`, que respeitam **PodDisruptionBudgets** e encerram os Pods de forma graciosa, a aplicar um taint `NoExecute` à mão.

14.3 Afinidade e antiafinidade

14.3.1 nodeAffinity

```
spec:
  affinity:
    nodeAffinity:
      requiredDuringSchedulingIgnoredDuringExecution:      # obrigatório
        nodeSelectorTerms:
          - matchExpressions:
              - key: gpu
                operator: In
                values: ["true"]
        preferredDuringSchedulingIgnoredDuringExecution:    # preferência (peso 1-100)
          - weight: 80
            preference:
              matchExpressions:
                - key: topology.kubernetes.io/zone
                  operator: In
                  values: [br-sp-1]
```

- `required...`: se nenhum nó atender, o Pod fica `Pending`. `preferred...`: soma pontos para os nós que atendem.
- `IgnoredDuringExecution`: as regras valem **no agendamento**. Se a label do nó mudar depois, o Pod continua lá.
- Operadores: `In`, `NotIn`, `Exists`, `DoesNotExist`, `Gt`, `Lt`. Vários `nodeSelectorTerms` são combinados com **OU**; várias `matchExpressions` do mesmo termo, com **E**.

14.3.2 podAffinity, podAntiAffinity e distribuição

```
spec:
  affinity:
    podAntiAffinity:
      preferredDuringSchedulingIgnoredDuringExecution:
        - weight: 100
          podAffinityTerm:
            labelSelector:
              matchLabels: { app: web }
            topologyKey: topology.kubernetes.io/zone      # evite duas réplicas na mesma zona
      topologySpreadConstraints:
        - maxSkew: 1                                     # diferença máxima entre domínios
          topologyKey: topology.kubernetes.io/zone
          whenUnsatisfiable: ScheduleAnyway               # ou DoNotSchedule
          labelSelector:
            matchLabels: { app: web }
```

- `topologyKey` define o "domínio": `kubernetes.io/hostname` (nó), `topology.kubernetes.io/zone`, `topology.kubernetes.io/region` ou qualquer label dos nós.
- **podAffinity** aproxima (ex.: cache no mesmo nó da aplicação); **podAntiAffinity** afasta (réplicas em nós ou zonas diferentes).
- **Antiafinidade obrigatória limita as réplicas ao número de domínios:** com `required` e 4 zonas, a quinta réplica fica `Pending` para sempre. Para alta disponibilidade, prefira a forma `preferred` ou `topologySpreadConstraints` com `maxSkew`, que espalham sem travar o escalonamento.
- Afinidade entre Pods é cara de calcular em clusters muito grandes; `topologySpreadConstraints` é a forma recomendada de distribuir réplicas.

14.3.3 Prioridade e disrupções

- **PriorityClass** dá prioridade a Pods; quando falta espaço, o scheduler pode **preemptar** (despejar) Pods de menor prioridade para agendar os mais importantes.
- **PodDisruptionBudget** (`minAvailable` ou `maxUnavailable`) limita quantos Pods de uma aplicação podem ser tirados **voluntariamente** ao mesmo tempo (drain, atualizações de nós).

```
apiVersion: policy/v1
kind: PodDisruptionBudget
metadata:
  name: web
spec:
  minAvailable: 2
  selector:
    matchLabels: { app: web }
```

14.4 Decisão rápida — Agendamento

Situação	Abordagem recomendada	Erro comum
Nós com GPU só para cargas de GPU	Taint nos nós de GPU + toleration e nodeAffinity nos Pods de GPU	Só toleration (o Pod pode ir para qualquer nó)

Situação	Abordagem recomendada	Erro comum
Réplicas em zonas diferentes	<code>topologySpreadConstraints</code> por zona (ou antiafinidade <code>preferred</code>)	Antiafinidade <code>required</code> com mais réplicas que zonas
Manutenção de nó	<code>kubectl drain</code> (respeita PDB) e <code>uncordon</code>	Taint <code>NoExecute</code> improvisado
Pod Pending com <code>didn't match Pod's node affinity/selector</code>	Conferir labels dos nós e valores com aspas	Remover a afinidade
Garantir mínimo de réplicas durante manutenções	<code>PodDisruptionBudget</code>	Confiar no número de réplicas
Cargas críticas precisam de espaço em cluster cheio	<code>PriorityClass</code>	Aumentar requests de tudo
Cache perto da aplicação	<code>podAffinity</code> por <code>kubernetes.io/hostname</code>	Fixar os dois no mesmo nó pelo nome
Nós do control plane rodando aplicações	Manter o taint padrão	Remover o taint "para aproveitar o nó"
Pods levam 5 minutos para sair de um nó morto	É a toleration automática de 300 s; ajuste <code>tolerationSeconds</code> se precisar	Achar que o cluster travou

Políticas e Controle de Admissão

Ideia central: depois de autenticar e autorizar um pedido, o API server passa o objeto por **controladores de admissão**, que podem **modificar** (mutating) e **validar** (validating) antes de gravar no etcd. É nesse ponto que se impõem regras como "toda imagem vem do registry da empresa" ou "nenhum contêiner roda como root". As ferramentas são o **Pod Security Admission** (nativo), a **ValidatingAdmissionPolicy** (nativa, em CEL) e motores de políticas como o **Kyverno** e o **OPA Gatekeeper**.

15.1 O caminho de um pedido

15.1.1 Etapas

1. **Autenticação:** quem é você (certificado, token, OIDC).
 2. **Autorização:** você pode fazer isso (RBAC, capítulo 17).
 3. **Admissão com mutação:** webhooks e políticas podem **alterar** o objeto (adicionar labels, valores padrão, sidecars).
 4. **Validação de esquema** do objeto.
 5. **Admissão com validação:** webhooks e políticas **aceitam ou recusam**.
 6. **Gravação** no etcd.
- Admissão age sobre **pedidos** de criação e alteração. Objetos que já existiam antes da política só são afetados quando mudam; relatórios de auditoria mostram quais estão fora da regra.

15.2 Pod Security Admission

15.2.1 Padrões por namespace

O **Pod Security Admission** (estável desde a 1.25) aplica os **Pod Security Standards** por meio de labels no namespace:

Nível	O que exige
privileged	Nada: sem restrições
baseline	Bloqueia escaladas conhecidas: contêineres privilegiados, hostNetwork, hostPID, hostPath, capabilities perigosas
restricted	Além do baseline: runAsNonRoot, sem escalada de privilégio, drop: [ALL] capabilities, perfil seccomp RuntimeDefault

```
kubectl label namespace loja \
  pod-security.kubernetes.io/enforce=restricted \
  pod-security.kubernetes.io/warn=restricted \
  pod-security.kubernetes.io/audit=restricted
```

- Modos: `enforce` (recusa), `warn` (avisa o usuário) e `audit` (registra no log de auditoria). Comece com `warn` e `audit` para ver o impacto antes do `enforce`.
- Substitui a antiga **PodSecurityPolicy**, removida na 1.25.

15.3 ValidatingAdmissionPolicy

15.3.1 Regras em CEL, sem webhook

Estável desde a 1.30, a **ValidatingAdmissionPolicy** escreve regras em **CEL** que o próprio API server executa, sem instalar nada. A **MutatingAdmissionPolicy** segue o mesmo modelo para mutação nas versões recentes.

```
apiVersion: admissionregistration.k8s.io/v1
kind: ValidatingAdmissionPolicy
metadata:
  name: exigir-limits
spec:
  failurePolicy: Fail
  matchConstraints:
    resourceRules:
      - apiGroups: ["apps"]
        apiVersions: ["v1"]
        operations: ["CREATE", "UPDATE"]
        resources: ["deployments"]
  validations:
    - expression: >
        object.spec.template.spec.containers.all(c,
          has(c.resources.limits) && has(c.resources.limits.memory))
      message: "Todo contêiner precisa de limite de memória."
---
apiVersion: admissionregistration.k8s.io/v1
kind: ValidatingAdmissionPolicyBinding
metadata:
  name: exigir-limits
spec:
  policyName: exigir-limits
  validationActions: [Deny]          # ou Warn, Audit
  matchResources:
    namespaceSelector:
      matchLabels: { ambiente: producao }
```

15.4 Kyverno

15.4.1 O que faz

O **Kyverno** (projeto CNCF) é um motor de políticas feito para Kubernetes: **valida, modifica, gera e apaga** recursos e **verifica assinaturas de imagens**, com políticas escritas como objetos do cluster.

```
helm repo add kyverno https://kyverno.github.io/kyverno/
helm install kyverno kyverno/kyverno -n kyverno --create-namespace
kubectl get pods -n kyverno
kubectl get crd | grep kyverno
```

15.4.2 Tipos de política

Tipo (Kyverno 1.19)	Função
ValidatingPolicy	Aceitar ou recusar recursos (CEL)
MutatingPolicy	Alterar recursos na admissão
GeneratingPolicy	Criar recursos a partir de outros (ex.: NetworkPolicy padrão em cada namespace novo)
DeletingPolicy	Apagar recursos periodicamente por critério
ImageValidatingPolicy	Verificar assinaturas e atestados de imagens
ClusterPolicy / Policy (kyverno.io/v1)	Formato antigo, baseado em padrões YAML. Obsoleto a partir do Kyverno 1.19, mas ainda muito presente em tutoriais e clusters existentes

```
apiVersion: policies.kyverno.io/v1
kind: ValidatingPolicy
metadata:
  name: registry-confiavel
spec:
  validationActions: [Deny]                # ou Audit para só relatar
  matchConstraints:
    resourceRules:
      - apiGroups: [""]
        apiVersions: [v1]
        operations: [CREATE, UPDATE]
        resources: [pods]
  validations:
    - message: "Imagens devem vir de registry.empresa.com.br"
      expression: >
        object.spec.containers.all(c, c.image.startsWith('registry.empresa.com.br/')) &&
        object.spec?.initContainers.orValue([]).all(c, c.image.startsWith('registry.empresa.com.br/'))
```

No formato antigo, ainda comum:

```

apiVersion: kyverno.io/v1
kind: ClusterPolicy
metadata:
  name: exigir-limits
spec:
  rules:
    - name: validar-limits
      match:
        any:
          - resources: { kinds: [Pod] }
      exclude:
        any:
          - resources: { namespaces: [kube-system] }
      validate:
        failureAction: Enforce # por regra; o campo spec.validationFailureAction é antigo
        message: "CPU e memória precisam de limits."
        pattern:
          spec:
            containers:
              - resources:
                  limits:
                    memory: "?*"
                    cpu: "?*"

```

- **Enforce x Audit:** `Enforce` (ou `Deny`) recusa; `Audit` deixa passar e registra em **PolicyReports** (`kubectl get policyreport -A`). Comece em `Audit`.
- **Regras de Pod valem para os controladores:** o Kyverno gera automaticamente as regras equivalentes para Deployments, StatefulSets, Jobs e outros, recusando o Deployment na hora, em vez de deixar os Pods falharem depois.
- **Cuidados:** regras que olham só `containers` deixam `initContainers` e `ephemeralContainers` de fora; um padrão que exige um valor exato (por exemplo, `readiness` em `/` na porta 8080) recusa aplicações corretas que usam outro caminho. Exclua namespaces de sistema com cuidado e rode o Kyverno com réplicas: se o webhook cair e a política for `Fail`, o cluster deixa de aceitar alterações.
- **Teste antes de aplicar:** a CLI `kyverno apply` e `kyverno test` avaliam políticas contra manifestos locais, útil no CI.
- **Alternativa:** o **OPA Gatekeeper** usa a linguagem Rego e o modelo de `ConstraintTemplates`.

15.5 Decisão rápida — Políticas

Situação	Abordagem recomendada	Erro comum
Bloquear Pods privilegiados e root por namespace	Pod Security Admission (<code>restricted</code> ou <code>baseline</code>)	Escrever tudo do zero em um motor de políticas
Regra simples de validação, sem instalar nada	ValidatingAdmissionPolicy (CEL)	Webhook próprio
Mutação, geração de recursos, verificação de imagens	Kyverno	Scripts que corrigem recursos depois
Introduzir políticas em cluster em uso	Modo Audit/Warn, analisar relatórios, depois Enforce	Enforce direto e quebrar deploys
Restringir registries de imagens	Política que cobre <code>containers</code> e <code>initContainers</code>	Checar só <code>containers</code>

Situação	Abordagem recomendada	Erro comum
Webhook de política fora do ar travando o cluster	Réplicas e exclusão de namespaces de sistema	Uma réplica com <code>failurePolicy: Fail</code>
Escrever políticas novas no Kyverno	Tipos novos (<code>ValidatingPolicy</code> e similares)	Novos <code>ClusterPolicy</code> sem necessidade

Network Policies

Ideia central: por padrão, **todo Pod fala com todo Pod** do cluster. Uma **NetworkPolicy** seleciona Pods e define quem pode falar com eles (**ingress**) e com quem eles podem falar (**egress**). As políticas são **listas de permissão que se somam**: a partir do momento em que um Pod é selecionado por uma política de uma direção, tudo o que não for permitido naquela direção é bloqueado. E nada disso funciona sem um **CNI que implemente NetworkPolicy**.

16.1 Como funcionam

16.1.1 Regras fundamentais

- **Suporte do CNI:** o API server **aceita** NetworkPolicies em qualquer cluster (a API `networking.k8s.io/v1` sempre existe), mas quem as aplica é o plugin de rede. **Calico** e **Cilium** aplicam; o **Flannel** sozinho, não; na AWS, o **VPC CNI** aplica quando a opção de NetworkPolicy está habilitada no add-on. Verificar se a API existe (`kubectl api-versions`) **não** prova que as políticas são aplicadas: teste o bloqueio de verdade.
- **Pod não selecionado** por nenhuma política: tudo liberado.
- **Pod selecionado** em uma direção: só entra ou sai o que alguma política permitir. Políticas **somam** permissões; não existe regra de "negar" na API padrão.
- `policyTypes`: se omitido, a política vale para `Ingress` e, se tiver seção `egress`, também para `Egress`. Declare explicitamente.
- A **resposta** de uma conexão permitida sempre volta (as regras são *stateful*).

16.1.2 Seletores: E e OU

```
ingress:
- from:
  - namespaceSelector:           # item 1
    matchLabels: { kubernetes.io/metadata.name: ingress-nginx }
  - podSelector:                 # item 2 → item 1 OU item 2
    matchLabels: { app: web }
- from:
  - namespaceSelector:           # MESMO item: namespace E Pod
    matchLabels: { kubernetes.io/metadata.name: monitoring }
    podSelector:
      matchLabels: { app: prometheus }
```

- **Itens separados** na lista `from/ to` (cada um começa com `-`) são alternativas (**OU**).
- `namespaceSelector` e `podSelector` **no mesmo item** significam "**Pods com estas labels, nos namespaces com estas labels**" (**E**).
- Não é possível repetir a mesma chave (`namespaceSelector` duas vezes) no mesmo item: em YAML isso é uma chave duplicada, e só uma das duas vale.
- `podSelector` **sem** `namespaceSelector` se refere a Pods **do mesmo namespace** da política. `podSelector: {}` significa todos os Pods daquele namespace.

- Todo namespace tem automaticamente a label `kubernetes.io/metadata.name: <nome>`, útil para selecionar namespaces pelo nome.
- `ipBlock` (com `except`) serve para endereços **fora do cluster**. IPs de Pods mudam; para Pods, use seletores.

16.2 Receitas

16.2.1 Negar tudo e liberar o necessário

1. Negar tudo (entrada e saída) no namespace:

```
apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata: { name: negar-tudo, namespace: loja }
spec:
  podSelector: {}
  policyTypes: [Ingress, Egress]
```

2. Liberar o DNS para todos os Pods do namespace:

```
apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata: { name: permitir-dns, namespace: loja }
spec:
  podSelector: {}
  policyTypes: [Egress]
  egress:
    - to:
        - namespaceSelector:
            matchLabels: { kubernetes.io/metadata.name: kube-system }
        podSelector:
            matchLabels: { k8s-app: kube-dns }
  ports:
    - { protocol: UDP, port: 53 }
    - { protocol: TCP, port: 53 }
```

3. Entrada na aplicação só a partir do controlador de entrada:

```
apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata: { name: web-do-ingress, namespace: loja }
spec:
  podSelector:
    matchLabels: { app: web }
  policyTypes: [Ingress]
  ingress:
    - from:
        - namespaceSelector:
            matchLabels: { kubernetes.io/metadata.name: ingress-nginx }
  ports:
    - { protocol: TCP, port: 5000 }
```

4. Aplicação → Redis: saída na aplicação e entrada no Redis:

```

apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata: { name: web-para-redis, namespace: loja }
spec:
  podSelector:
    matchLabels: { app: web }
  policyTypes: [Egress]
  egress:
    - to:
        - podSelector: { matchLabels: { app: redis } }
      ports:
        - { protocol: TCP, port: 6379 }
  ---
apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata: { name: redis-da-web, namespace: loja }
spec:
  podSelector:
    matchLabels: { app: redis }
  policyTypes: [Ingress]
  ingress:
    - from:
        - podSelector: { matchLabels: { app: web } }
      ports:
        - { protocol: TCP, port: 6379 }

```

- Com "negar tudo" nas duas direções, uma comunicação só funciona com **duas permissões: egress** na origem e **ingress** no destino.
- **Não esqueça o DNS** (UDP e TCP 53): sem ele, nomes de Services não resolvem, e o sintoma parece "a aplicação não acha o Redis".
- **Portas** em NetworkPolicy são as do **Pod** (a `targetPort`), não a porta do Service.

16.2.2 Testar

```

kubectl get networkpolicy -n loja
kubectl describe networkpolicy web-do-ingress -n loja
# De fora do namespace (deve falhar com timeout)
kubectl run t -it --rm --image=redis:8 --restart=Never -- redis-cli -h redis.loja ping
# De dentro, com a label permitida (deve responder PONG)
kubectl run t -n loja -it --rm --image=redis:8 --restart=Never --labels=app=web -- redis-cli -h redis ping

```

- Bloqueio por NetworkPolicy aparece como **timeout** (pacotes descartados), não como "conexão recusada".
- CNIs como **Cilium** e **Calico** oferecem políticas estendidas: regras por nome DNS (FQDN), por método e caminho HTTP (L7) e políticas de cluster inteiro que o administrador impõe acima dos namespaces.

16.3 Decisão rápida — Network Policies

Situação	Abordagem recomendada	Erro comum
Políticas criadas, mas nada é bloqueado	Conferir se o CNI aplica NetworkPolicy (Calico, Cilium, VPC CNI habilitado)	Confiar em <code>kubectl api-versions</code>

Situação	Abordagem recomendada	Erro comum
Isolar um namespace	Negar tudo + liberações explícitas	Uma política por Pod, sem padrão
Tudo parou depois do "negar tudo"	Liberar DNS (UDP e TCP 53) e as saídas necessárias	Desfazer o isolamento
Pods da origem X em namespaces Y	namespaceSelector e podSelector no mesmo item	Itens separados (vira OU)
Comunicação A → B com egress restrito	Egress em A e ingress em B	Só um dos lados
Liberar um serviço externo	ipBlock (ou política FQDN do CNI)	ipBlock com IPs de Pods
Porta errada na política	Usar a porta do contêiner (targetPort)	Usar a porta do Service

RBAC e Controle de Acesso

Ideia central: o Kubernetes **não tem objeto "usuário"**. Pessoas se autenticam de fora (certificados, OIDC) e **ServiceAccounts** identificam processos dentro do cluster. O **RBAC** define o que cada identidade pode fazer: **Roles/ClusterRoles** listam permissões (verbos sobre recursos) e **RoleBindings/ClusterRoleBindings** as concedem. Tudo é **permissão positiva**: o que não foi concedido, é negado.

17.1 Identidades

17.1.1 Usuários, grupos e ServiceAccounts

Identidade	Como é autenticada	Uso
Usuário (pessoa)	Certificado X.509 (<code>CN</code> = usuário, <code>O</code> = grupos), token OIDC do provedor de identidade, integração da nuvem (IAM no EKS, Entra ID no AKS)	Acesso humano
Grupo	Vem junto da autenticação	Conceder permissões a times
ServiceAccount	Token emitido pelo cluster (JWT), montado nos Pods	Aplicações e ferramentas dentro do cluster (CI, operadores, Prometheus)

- **Em produção, prefira OIDC** (ou a integração da nuvem) para pessoas: certificados de cliente **não podem ser revogados** antes de expirar. Se usar certificados, dê validade curta.
- **Grupo** `system:masters` ignora o RBAC por completo. Por isso o `admin.conf` do kubeadm usa o grupo `kubeadm:cluster-admins`, e o arquivo `super-admin.conf` (com `system:masters`) deve ficar guardado para emergências.

17.1.2 Criar um usuário com certificado

```
openssl genrsa -out dev.key 2048
openssl req -new -key dev.key -out dev.csr -subj "/CN=maria/O=desenvolvimento"

cat <<EOF | kubectl apply -f -
apiVersion: certificates.k8s.io/v1
kind: CertificateSigningRequest
metadata:
  name: maria
spec:
  request: $(base64 < dev.csr | tr -d '\n')
  signerName: kubernetes.io/kube-apiserver-client
  expirationSeconds: 604800          # 7 dias
  usages: [client auth]
EOF

kubectl certificate approve maria
kubectl get csr maria -o jsonpath='{.status.certificate}' | base64 -d > dev.crt

kubectl config set-credentials maria --client-certificate=dev.crt --client-key=dev.key --embed-
certs=true
kubectl config set-context maria --cluster=<nome-do-cluster> --user=maria --namespace=dev
kubectl --context maria get pods      # Forbidden até existir um RoleBinding
```

- O certificado é assinado pela **CA do cluster**; a identidade é o que está no **CN** e no **O** do CSR. O objeto CSR aprova- do expira do cluster depois de algum tempo, mas o certificado continua válido até a data de expiração.

17.1.3 ServiceAccounts e tokens

```
kubectl create serviceaccount ci -n dev
kubectl create token ci -n dev --duration=1h          # token temporário (TokenRequest API)
```

```
spec:
  serviceAccountName: ci          # identidade do Pod
  automountServiceAccountToken: false # desligue quando o Pod não fala com a API
```

- Desde a **1.24**, criar uma ServiceAccount **não gera mais** um Secret com token de longa duração. Os Pods recebem **tokens projetados**, com validade limitada e renovados automaticamente pelo kubelet (em `/var/run/secrets/kubernetes.io/serviceaccount/`). Tokens de longa duração só existem se criados explicitamente (Secret do tipo `service-account-token`), e devem ser evitados.
- Todo namespace tem a ServiceAccount `default`, usada por Pods que não declaram outra. Não conceda permis- sões a ela.

17.2 Roles e bindings

17.2.1 Anatomia de uma regra

Campo	Significado
-------	-------------

Campo	Significado
apiGroups	Grupo da API: "" para o grupo principal (Pods, Services, ConfigMaps, Secrets), apps (Deployments, StatefulSets), batch, networking.k8s.io ... Veja a coluna APIVERSION de kubectl api-resources
resources	Tipos no plural (pods, deployments) e subrecursos (pods/log, pods/exec, deployments/scale)
verbs	get, list, watch, create, update, patch, delete, deletecollection (e especiais: bind, escalate, impersonate)
resource-Names	Opcional: limita a objetos com nomes específicos

```

apiVersion: rbac.authorization.k8s.io/v1
kind: Role
metadata:
  name: desenvolvedor
  namespace: dev
rules:
- apiGroups: [""]
  resources: [pods, pods/log, services, configmaps]
  verbs: [get, list, watch, create, update, patch, delete]
- apiGroups: [apps]
  resources: [deployments]
  verbs: [get, list, watch, create, update, patch, delete]
---
apiVersion: rbac.authorization.k8s.io/v1
kind: RoleBinding
metadata:
  name: desenvolvedores
  namespace: dev
subjects:
- kind: Group # prefira grupos a usuários individuais
  name: desenvolvimento
  apiGroup: rbac.authorization.k8s.io
- kind: ServiceAccount
  name: ci
  namespace: dev
roleRef:
  kind: Role
  name: desenvolvedor
  apiGroup: rbac.authorization.k8s.io

```

Objeto	Escopo
Role	Permissões dentro de um namespace
ClusterRole	Permissões em recursos de cluster (nós, PVs, namespaces), em todos os namespaces, ou um modelo reutilizável
RoleBinding	Concede uma Role ou uma ClusterRole dentro de um namespace
ClusterRoleBinding	Concede uma ClusterRole no cluster inteiro

- **RoleBinding + ClusterRole** é o jeito de reaproveitar um conjunto de permissões em vários namespaces sem copiá-lo.
- **ClusterRoles padrão:** view (leitura, sem Secrets), edit (altera a maioria dos recursos, sem mexer em RBAC), admin (tudo no namespace, inclusive RBAC local) e cluster-admin (tudo). Use-as antes de escrever as suas.
- O roleRef **é imutável:** para trocar a Role de um binding, apague e crie outro.

```
kubectl create role leitor-pods --verb=get,list,watch --resource=pods -n dev
kubectl create rolebinding maria-leitora --role=leitor-pods --user=maria -n dev
kubectl create clusterrolebinding plataforma-edit --clusterrole=edit --group=plataforma
kubectl auth can-i create deployments -n dev --as=maria
kubectl auth can-i --list -n dev --as=system:serviceaccount:dev:ci
kubectl auth whoami # quem sou eu para o cluster
```

17.2.2 Cuidados de segurança

- **Menor privilégio:** comece por `view` e acrescente. Evite `*` em verbos e recursos.
- **Criar Pods é poderoso:** quem pode criar Pods em um namespace pode montar qualquer Secret dele e usar qualquer ServiceAccount dele. `pods/exec` permite entrar em contêineres.
- `list` **em Secrets revela o conteúdo** (não só os nomes).
- **Verbos** `bind`, `escalate` e `impersonate` permitem ganhar mais permissões; reserve-os aos administradores.
- **Revise periodicamente** quem tem `cluster-admin`: `kubectl get clusterrolebindings -o wide | grep cluster-admin`.

17.3 Decisão rápida — RBAC

Situação	Abordagem recomendada	Erro comum
Acesso de pessoas ao cluster	OIDC ou integração IAM da nuvem, por grupos	Cópias do <code>admin.conf</code>
Laboratório com usuário por certificado	CSR com <code>expirationSeconds</code> curto	Certificado de 1 ano sem forma de revogar
Mesmo conjunto de permissões em vários namespaces	Uma ClusterRole + RoleBindings por namespace	Copiar a Role em cada namespace
Pipeline de CI implantando em um namespace	ServiceAccount + RoleBinding com <code>edit</code> no namespace	ClusterRoleBinding <code>cluster-admin</code>
Aplicação que não fala com a API	<code>automountServiceAccountToken: false</code>	Deixar o token montado
Conferir o que alguém pode fazer	<code>kubectl auth can-i --list --as=...</code>	Testar na tentativa e erro
Leitura para um time de suporte	ClusterRole <code>view</code>	Role com <code>*</code>
Token para um sistema externo	<code>kubectl create token</code> com validade curta	Secret de token sem expiração

Helm

Ideia central: o **Helm** é o gerenciador de pacotes do Kubernetes. Um **chart** é um pacote de **templates** de manifestos mais um **values.yaml** com os valores padrão; cada instalação é uma **release** com histórico de **revisões**, que pode ser atualizada e revertida. A versão atual é o **Helm 4** (novembro de 2025); o Helm 3 recebe só correções de segurança até **10 de fevereiro de 2027**.

18.1 Instalar e usar charts

18.1.1 Instalação

```
curl -fsSL https://raw.githubusercontent.com/helm/helm/main/scripts/get-helm-4 | bash
brew install helm # macOS
winget install Helm.Helm # Windows
helm version
```

18.1.2 Comandos do dia a dia

```
helm repo add prometheus-community https://prometheus-community.github.io/helm-charts
helm repo update
helm search repo prometheus # nos repositórios adicionados
helm search hub prometheus # no Artifact Hub
helm show values prometheus-community/kube-prometheus-stack > monitoramento-values.yaml

helm install monitoramento prometheus-community/kube-prometheus-stack \
  -n monitoring --create-namespace -f monitoramento-values.yaml
helm install app oci://ghcr.io/minha-org/charts/app --version 1.4.0 # chart em registry OCI
helm upgrade --install app ./app -n loja -f valores-prod.yaml --set image.tag=1.4.2
helm list -A
helm status app -n loja
helm history app -n loja
helm rollback app 3 -n loja # volta para a revisão 3 (e cria uma nova revisão)
helm get values app -n loja # valores usados
helm get manifest app -n loja # manifestos aplicados
helm uninstall app -n loja
```

Conceito	Significado
Chart	O pacote (templates + valores padrão + metadados)
Release	Uma instalação de um chart, com nome, em um namespace
Revisão	Cada <code>install</code> , <code>upgrade</code> ou <code>rollback</code> cria uma nova, guardada em Secrets do namespace
Repositório	Onde os charts são publicados: HTTP (arquivo <code>index.yaml</code>) ou registry OCI (o mesmo das imagens)

- **Precedência de valores:** `values.yaml` do chart < arquivos `-f` (na ordem) < `--set`. Guarde os valores de cada ambiente em arquivos versionados; `--set` é para pequenos ajustes.
- `helm upgrade --install` instala se não existir e atualiza se existir: é o comando típico de pipelines.
- **Mudanças do Helm 4:** aplica os manifestos com **server-side apply** nas releases novas; `--atomic` virou `--roll-back-on-failure` e `--force` virou `--force-replace`; post-renderers passaram a ser plugins; `helm registry login` recebe só o domínio. Scripts escritos para o Helm 3 podem precisar de ajustes.

18.2 Criar um chart

18.2.1 Estrutura

```
app/
├─ Chart.yaml           # nome, versão do chart, appVersion, dependências
├─ values.yaml          # valores padrão
├─ values.schema.json   # opcional: valida os valores (tipos, obrigatórios)
├─ charts/              # dependências empacotadas
├─ crds/                # CRDs instaladas antes dos templates
├─ templates/
│   ├── _helpers.tpl    # templates nomeados (não gera manifesto)
│   ├── deployment.yaml
│   ├── service.yaml
│   ├── NOTES.txt       # mensagem exibida depois do install
│   └─ tests/
```

```
# Chart.yaml
apiVersion: v2
name: app
description: Aplicação de exemplo
type: application
version: 0.3.0          # versão do CHART (SemVer); mude a cada alteração no chart
appVersion: "1.4.2"     # versão da APLICAÇÃO empacotada (informativa)
dependencies:
- name: redis
  version: "~2.1"
  repository: oci://registry.exemplo.com.br/charts # repositório ilustrativo
  condition: redis.enabled                        # dependência opcional
```

- `helm create app` gera um esqueleto completo (Deployment, Service, Ingress, HPA, ServiceAccount, helpers e testes), bom ponto de partida.
- `version` × `appVersion`: a primeira é a do pacote; a segunda, a do software dentro dele.

18.2.2 Templates

```
# values.yaml
replicaCount: 2
image:
  repository: ghcr.io/minha-org/app
  tag: "" # vazio = usar appVersion
service:
  type: ClusterIP
  port: 5000
resources:
  requests: { cpu: 250m, memory: 128Mi }
  limits: { memory: 256Mi }
env:
  REDIS_HOST: app-redis
```

```
# templates/deployment.yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: {{ include "app.fullname" . }}
  labels:
    {{- include "app.labels" . | nindent 4 }}
spec:
  {{- if not .Values.autoscaling.enabled }}
  replicas: {{ .Values.replicaCount | default 1 }}
  {{- end }}
  selector:
    matchLabels:
      {{- include "app.selectorLabels" . | nindent 6 }}
  template:
    metadata:
      labels:
        {{- include "app.selectorLabels" . | nindent 8 }}
    spec:
      containers:
        - name: app
          image: "{{ .Values.image.repository }}:{{ .Values.image.tag | default .Chart.AppVersion }}"
          ports:
            - containerPort: {{ .Values.service.port }}
          env:
            {{- range $nome, $valor := .Values.env }}
            - name: {{ $nome }}
              value: {{ $valor | quote }}
            {{- end }}
          resources:
            {{- toYaml .Values.resources | nindent 12 }}
```

Recurso de template	Uso
<code>.Values</code> , <code>.Release</code> (<code>Name</code> , <code>Namespace</code> , <code>Revision</code>), <code>.Chart</code> , <code>.Capabilities</code>	Objetos disponíveis nos templates
<code>{{- ... -}}</code>	Remove espaços e quebras de linha antes/depois
<code>if / else / with</code>	Condicionais (e mudança de escopo com <code>with</code>)

Recurso de template	Uso
<code>range</code>	Repetir para cada item de uma lista ou mapa (<code>range \$chave, \$valor := ...</code>)
<code>default</code> , <code>quote</code> , <code>required</code>	Valor padrão, aspas, falha com mensagem se o valor faltar
<code>toYaml</code> / <code>toJson</code> + <code>nindent N</code>	Inserir blocos inteiros (resources, labels) com a indentação certa
<code>include "nome" .</code>	Chamar um template definido em <code>_helpers.tpl</code> (com <code>define</code>)
<code>index .Values "chave-com-hifen"</code>	Acessar chaves que não são identificadores válidos
<code>tpl</code>	Renderizar um valor que contém template

- **Chaves com hífen** (`giropops-senhas`) não funcionam com a notação de ponto (`.Values.giropops-senhas`) e geram `bad character U+002D '-'`. Use **camelCase** nos valores (`giropopsSenhas`) ou `index`.
- **Helpers** (`_helpers.tpl`) centralizam nomes, labels e seletores. Arquivos que começam com `_` não geram manifestos.
- **Várias peças no mesmo arquivo**: separe com `---`. Um `range` que gera vários objetos precisa do `---` dentro do laço.
- **Segredos** não devem ficar em `values.yaml` versionado: use referências a Secrets existentes, External Secrets ou plugins como `helm-secrets`.

18.2.3 Validar e publicar

```
helm lint ./app # erros de estrutura e boas práticas
helm template app ./app -f valores-prod.yaml # renderiza localmente, sem cluster
helm install app ./app --dry-run=server # renderiza e valida no API server
helm dependency update ./app # baixa as dependências para charts/
helm package ./app # gera app-0.3.0.tgz
helm push app-0.3.0.tgz oci://ghcr.io/minha-org/charts
```

- **Confira a origem e a manutenção dos charts de terceiros**: em 2025 a Bitnami reduziu o catálogo gratuito de imagens e charts, e muitos tutoriais que usavam `bitnami/...` deixaram de funcionar como antes. Prefira charts mantidos pelos próprios projetos.
- **Repositórios OCI** (GHCR, ECR, Harbor, Docker Hub) são o modo recomendado de publicar charts. O modelo antigo, com `index.yaml` servido por HTTP (por exemplo, no GitHub Pages com `helm repo index`), continua funcionando.

18.3 Decisão rápida — Helm

Situação	Abordagem recomendada	Erro comum
Instalar software de terceiros (Redis, Prometheus, cert-manager)	Chart oficial ou mantido pelo projeto, com arquivo de valores versionado	Copiar manifestos soltos da internet
Mesma aplicação em vários ambientes	Um chart + um arquivo de valores por ambiente	Um chart por ambiente
Deploy em pipeline	<code>helm upgrade --install ... --rollback-on-failure</code> (Helm 4)	<code>helm install</code> que falha na segunda execução
Upgrade quebrou a aplicação	<code>helm rollback <release> <revisão></code>	Desinstalar e instalar de novo
Conferir o YAML antes de aplicar	<code>helm template</code> ou <code>--dry-run=server</code>	Aplicar direto em produção

Situação	Abordagem recomendada	Erro comum
bad character U+002D '-'	Chaves em camelCase ou index	Tirar o hífen só de alguns lugares
Publicar charts internos	Registry OCI	Enviar .tgz por e-mail
Senhas no values.yaml	Secrets existentes, External Secrets, helm-secrets	Versionar as senhas
Scripts antigos com --atomic	--rollback-on-failure no Helm 4	Ficar no Helm 3 depois do fim do suporte

Pegadinhas e Informações Desatualizadas

Como usar: revise antes de uma prova (CKA, CKAD, KCNA), de uma entrevista ou de uma revisão de arquitetura. As afirmações falsas abaixo aparecem com frequência em tutoriais, cursos e até em manifestos que "funcionam".

19.1 Afirmações falsas clássicas

Afirmação falsa	O que é verdade
"O Kubernetes executa contêineres"	Ele agenda Pods; o kubelet pede a um runtime CRI (containerd, CRI-O) que os execute
"Kubernetes não roda imagens Docker desde a 1.24"	Saiu o dockershim (Docker Engine como runtime); as imagens, que são OCI, continuam rodando
"O scheduler olha o uso real de CPU e memória"	Ele decide pelos requests declarados
"O kube-proxy cria a rede dos Pods"	A rede dos Pods é do CNI ; o kube-proxy implementa os Services
"livenessProbe que falha reinicia o Pod"	Reinicia o contêiner ; o Pod (nome, IP, volumes) continua o mesmo
"A readiness só roda na inicialização"	Roda durante toda a vida do contêiner; falhou, sai dos endpoints do Service
"timeoutSeconds é o intervalo entre tentativas"	É o prazo de cada verificação; o intervalo é <code>periodSeconds</code>
"Passar do limit de CPU mata o contêiner"	CPU é estrangulada (throttling); só a memória acima do limite causa <code>OOMKilled</code>
"128m de memória são 128 megabytes"	São 0,128 byte ; o certo é <code>128Mi</code> ou <code>128M</code>
"Toleration faz o Pod ir para o nó com taint"	Ela só permite ; para atrair, use <code>nodeSelector</code> ou <code>nodeAffinity</code>
"Mudar o template de um ReplicaSet atualiza os Pods"	Só Pods novos usam o template; quem troca versões é o Deployment
"Escalar um Deployment cria uma revisão"	Só mudanças em <code>spec.template</code> criam revisões
"O Deployment faz rollback sozinho se a versão falhar"	Ele marca <code>ProgressDeadlineExceeded</code> ; o rollback é uma decisão sua
" <code>kubectl get all</code> mostra tudo"	Mostra só alguns tipos; ConfigMaps, Secrets, Ingresses e PVCs ficam de fora
"Secret é criptografado"	É base64; a proteção vem de RBAC, criptografia em repouso e cofres externos
"ConfigMap montado nunca é atualizado no Pod"	Arquivos montados são atualizados (exceto com <code>subPath</code>); variáveis de ambiente não
" <code>immutable: true</code> vai em <code>metadata</code> "	É um campo de primeiro nível do ConfigMap/Secret
"Existe <code>kubectl create daemonset</code> "	Não existe; DaemonSets e StatefulSets vêm de manifestos
"Apagar o StatefulSet apaga os dados"	Os PVCs ficam, a menos que a política de retenção diga o contrário
"O volume de um StatefulSet se chama <code><template>-<índice></code> "	Se chama <code><template>-<statefulset>-<índice></code> (ex.: <code>dados-web-0</code>)
"ExternalName aceita IP"	Aceita nome DNS (gera um CNAME); para IP, Service sem seletor + <code>EndpointSlice</code>

Afirmção falsa	O que é verdade
" <code>kubectl api-versions</code> mostra <code>networking.k8s.io/v1</code> , logo as <code>NetworkPolicies</code> funcionam"	A API sempre existe; quem aplica é o CNI
" <code>NetworkPolicy</code> tem regras de negar"	São listas de permissão que se somam; o bloqueio vem de o Pod estar selecionado
"Dois <code>namespaceSelector</code> no mesmo item fazem um E"	É uma chave YAML duplicada; o E é <code>namespaceSelector</code> + <code>podSelector</code> no mesmo item
"Criar uma <code>ServiceAccount</code> gera um <code>Secret</code> com token"	Não desde a 1.24; tokens são temporários e emitidos sob demanda
"O Kubernetes tem objetos de usuário"	Usuários são identidades externas (certificado, OIDC); só <code>ServiceAccounts</code> são objetos
"O Metrics Server serve para monitoramento"	Ele só guarda o valor atual para <code>kubectl top</code> e autoescalamento
"O HPA calcula a utilização sobre o limit"	Sobre o request ; sem request, o HPA não age
"Antiafinidade obrigatória garante alta disponibilidade"	Com mais réplicas que domínios, as sobras ficam <code>Pending</code> ; prefira <code>topologySpreadConstraints</code>
"4 nós de control plane são mais seguros que 3"	O etcd com 4 membros tolera a perda de 1, como com 3; use número ímpar
"Helm acessa <code>.Values.minha-chave</code> "	Chaves com hífen exigem <code>index</code> ou <code>camelCase</code>

19.2 Informações desatualizadas em materiais antigos

Se o material diz...	Hoje (set/2026)
Instalar kubelet/kubeadm por <code>apt.kubernetes.io/packages.-cloud.google.com</code> com <code>apt-key</code>	Repositórios <code>pkgs.k8s.io</code> por versão menor, chave em <code>/etc/apt/key-rings</code>
Docker Engine como runtime do cluster, IDs <code>docker://</code> no <code>describe</code>	<code>containerd</code> ou CRI-O (<code>containerd://</code>); Docker só com <code>cri-dockerd</code>
Clusters 1.23 a 1.29 nos exemplos	Versões com suporte: 1.35, 1.36 e 1.37
<code>kind v0.20</code> e imagens <code>kindest/node:v1.24</code>	<code>kind v0.33</code> com imagens de versões atuais
Weave Net como CNI	Projeto sem manutenção; Calico, Cilium ou o CNI da nuvem
ingress-nginx como controlador padrão	Aposentado em março de 2026 ; Gateway API ou controlador mantido
<code>autoscaling/v2beta2</code> no HPA	<code>autoscaling/v2</code> (as versões beta foram removidas)
Provisionadores <code>kubernetes.io/aws-ebs</code> , <code>gce-pd</code> , <code>azure-disk</code>	Drivers CSI (<code>ebs.csi.aws.com</code> etc.)
Política de retenção <code>Recycle</code>	Obsoleta; <code>Delete</code> ou <code>Retain</code>
Objeto <code>Endpoints</code>	Obsoleto desde a 1.33; EndpointSlices
<code>PodSecurityPolicy</code>	Removida na 1.25; Pod Security Admission
<code>kubectl rollout ... --record</code>	Obsoleto; anotação <code>kubernetes.io/change-cause</code>
Sidecars em <code>containers</code> sem controle de ordem	Sidecars nativos (<code>init container</code> com <code>restartPolicy: Always</code>), estáveis desde a 1.33
Recriar o Pod para mudar CPU e memória	Redimensionamento no lugar, estável desde a 1.35
External Secrets com <code>external-secrets.io/v1beta1</code>	<code>external-secrets.io/v1</code>
Kyverno <code>ClusterPolicy</code> com <code>spec.validationFailureAction</code>	Tipos novos (<code>ValidatingPolicy</code> etc.); no formato antigo, <code>failureAction</code> por regra

Se o material diz...	Hoje (set/2026)
Helm 3 (<code>get-helm-3</code> , <code>--atomic</code> , <code>--force</code>)	Helm 4 (<code>get-helm-4</code> , <code>--rollback-on-failure</code> , <code>--force-replace</code>); Helm 3 com patches só até fev/2027
Charts e imagens <code>bitnami/...</code> gratuitos	Catálogo gratuito reduzido em 2025; confira a disponibilidade
Docker Hub limitado a 100/200 pulls "desde 2022"	Limites mudam; confira a política atual e autentique os pulls

19.3 Pares que mais se confundem

Par	Diferença
Container engine × container runtime	O engine é a ferramenta completa do usuário (Docker, Podman); o runtime executa contêineres (containerd, CRI-O; runc no nível mais baixo)
OCI × CRI	OCI padroniza imagens e execução; CRI é a API entre o kubelet e o runtime
<code>kubectl apply</code> × <code>create</code>	<code>apply</code> cria ou atualiza; <code>create</code> falha se o objeto existir
<code>requests</code> × <code>limits</code>	Requests reservam e orientam o agendamento; limits são o teto de execução
Liveness × readiness × startup	Reinicia contêiner × tira do tráfego × protege a inicialização
Deployment × StatefulSet	Réplicas intercambiáveis × identidade, ordem e PVC por réplica
Deployment × DaemonSet	N réplicas em qualquer nó × uma por nó
RollingUpdate × Recreate	Troca gradual, versões convivem × derruba tudo e sobe de novo
<code>maxSurge</code> × <code>maxUnavailable</code>	Pods a mais × Pods a menos durante o rollout
ClusterIP × NodePort × LoadBalancer	Interno × porta em todos os nós × balanceador externo
Service comum × headless	IP virtual com balanceamento × DNS devolve os IPs dos Pods
PV × PVC × StorageClass	O volume × o pedido de volume × o "tipo" que cria volumes dinamicamente
<code>Immediate</code> × <code>WaitForFirstConsumer</code>	Cria o disco na hora × espera o Pod ser agendado (zona certa)
RWO × RWX × RWOP	Um nó × vários nós × um único Pod
ConfigMap × Secret	Configuração comum × dados sensíveis (tratamento e permissões diferentes)
<code>data</code> × <code>stringData</code> (Secret)	Base64 × texto que o API server converte
Ingress × Gateway API	API congelada com annotations por controlador × API padronizada com papéis separados
Issuer × ClusterIssuer	Um namespace × todo o cluster
HTTP-01 × DNS-01	Arquivo no site × registro TXT (permite curinga)
Taint × toleration	No nó, repele × no Pod, permite
<code>nodeAffinity required</code> × <code>preferred</code>	Obrigatória × pontuação
<code>podAffinity</code> × <code>podAntiAffinity</code>	Aproxima × afasta, por <code>topologyKey</code>
Role × ClusterRole	Um namespace × cluster (ou modelo reutilizável)
RoleBinding × ClusterRoleBinding	Concede em um namespace × concede no cluster todo
HPA × VPA × Cluster Autoscaler	Número de Pods × tamanho dos Pods × número de nós
Chart × release	O pacote × uma instalação dele

Par	Diferença
<code>version</code> × <code>appVersion</code> (Chart.yaml)	Versão do chart × versão da aplicação

Referência Rápida de Comandos

Como usar: consulta de bancada. Com o alias `k=kubectl` e o autocompletar configurados, a maioria cabe em poucas teclas.

20.1 Contexto, descoberta e diagnóstico

Comando	Para que serve
<code>kubectl config get-contexts / use-context / set-context --current --namespace=</code>	Clusters e namespace padrão
<code>kubectl api-resources / kubectl explain <tipo>.<campo></code>	Tipos, abreviações, grupos e documentação de campos
<code>kubectl get <tipo> -A -o wide</code>	Listar em todos os namespaces, com detalhes
<code>kubectl describe <tipo> <nome></code>	Configuração e eventos
<code>kubectl get events -A --sort-by=.lastTimestamp</code>	Linha do tempo de eventos do cluster
<code>kubectl logs <pod> [-c contêiner] [-f] [--previous]</code>	Logs
<code>kubectl exec -it <pod> -- sh</code>	Shell no contêiner
<code>kubectl debug -it <pod> --image=busybox:1.37 --target=<contêiner></code>	Contêiner efêmero de depuração
<code>kubectl port-forward svc/<nome> 8080:80</code>	Acessar um Service ou Pod da máquina local
<code>kubectl top nodes / kubectl top pods -A</code>	Consumo atual (Metrics Server)
<code>kubectl auth can-i --list --as=<usuário></code>	Permissões de uma identidade

20.2 Criar e alterar

Comando	Para que serve
<code>kubectl apply -f <arquivo ou diretório> / kubectl diff -f</code>	Aplicar e comparar manifestos
<code>kubectl create deployment web --image=nginx:1.29 --replicas=3 --dry-run=client -o yaml</code>	Gerar o YAML de um Deployment
<code>kubectl run t -it --rm --image=busybox:1.37 --restart=Never -- sh</code>	Pod temporário para testes
<code>kubectl expose deployment web --port=80 --target-port=8080 [--type=NodePort]</code>	Criar um Service
<code>kubectl create configmap / create secret generic tls docker-registry</code>	Configuração e segredos
<code>kubectl scale deployment web --replicas=5</code>	Escalar
<code>kubectl set image deployment/web nginx=nginx:1.29.1</code>	Trocar a imagem
<code>kubectl label / kubectl annotate (sufixo - remove; --overwrite troca)</code>	Labels e annotations
<code>kubectl taint nodes <nó> chave=valor:NoSchedule[-]</code>	Aplicar/remover taints
<code>kubectl delete -f <arquivo> / kubectl delete <tipo> <nome></code>	Remover

20.3 Rollouts, nós e autoescalonamento

Comando	Para que serve
<code>kubectl rollout status history undo pause resume restart deployment/<nome></code>	Ciclo de atualização (Deployments, DaemonSets, StatefulSets)
<code>kubectl autoscale deployment web --cpu-percent=60 --min=2 --max=10</code>	Criar um HPA
<code>kubectl cordon uncordon <nó> / kubectl drain <nó> --ignore-daemonsets --delete-emptydir-data</code>	Manutenção de nós
<code>kubeadm token create --print-join-command</code>	Novo comando de entrada de nós
<code>kubeadm certs check-expiration / kubeadm upgrade plan</code>	Certificados e atualização do cluster

20.4 Ferramentas do ecossistema

Comando	Para que serve
<code>kind create cluster --name x --config c.yaml / kind delete cluster --name x</code>	Clusters locais com kind
<code>minikube start --nodes 3 -p x / minikube addons enable metrics-server</code>	Clusters locais com Minikube
<code>helm upgrade --install <release> <chart> -n <ns> -f valores.yaml</code>	Instalar ou atualizar um chart
<code>helm list -A / helm history / helm rollback / helm uninstall</code>	Gerenciar releases
<code>helm template / helm lint / helm package / helm push</code>	Desenvolver e publicar charts
<code>kubectl get certificate,order,challenge -A</code>	Depurar certificados do cert-manager
<code>kubectl get policyreport -A</code>	Resultados de políticas do Kyverno em modo auditoria

Autoteste — Flashcards de Revisão

Cada card esconde a resposta: tente responder antes de abrir. Uma rodada de 20 cards por dia cobre o banco em pouco mais de uma semana.

21.1 Runtimes e arquitetura

Qual é a diferença entre container engine e container runtime?

RESPOSTA

O **engine** (Docker, Podman) é a ferramenta completa que o usuário opera: imagens, redes, volumes, CLI. O **runtime** executa contêineres: os de alto nível (containerd, CRI-O) gerenciam imagens e ciclo de vida; os de baixo nível (runc, crun) criam namespaces e cgroups.

O que o dockershim removido na 1.24 mudou para quem usa imagens Docker?

RESPOSTA

Nada nas imagens: elas seguem o padrão OCI e rodam em containerd ou CRI-O. Mudou apenas que o Docker Engine deixou de ser runtime dos nós sem o adaptador cri-dockerd.

O que é a CRI?

RESPOSTA

A **Container Runtime Interface**, API gRPC pela qual o kubelet pede ao runtime (containerd, CRI-O) que crie sandboxes, baixe imagens e inicie contêineres.

Qual componente é o único que fala diretamente com o etcd?

RESPOSTA

O **kube-apiserver**. Todos os outros componentes, e o kubectl, passam por ele.

O que o kube-scheduler faz, e com base em quê?

RESPOSTA

Escolhe o nó de cada Pod sem nó definido: filtra os nós viáveis (requests, taints, afinidade, volumes) e pontua os restantes. Usa os **requests** declarados, não o consumo real.

Qual é o papel do kube-controller-manager?

RESPOSTA

Executar os controladores (Deployment, ReplicaSet, Node, Job, EndpointSlice...), que observam o estado desejado e agem para que o estado real chegue a ele.

Por que um cluster de produção usa 3 nós de control plane?

RESPOSTA

Para o etcd manter quórum com a perda de um membro: N membros toleram $(N - 1) / 2$ falhas. Com 2 ou 4, a tolerância não melhora.

Quais portas o API server, o kubelet e os NodePorts usam por padrão?

RESPOSTA

API server **6443**, kubelet **10250**, NodePort **30000–32767** (TCP e UDP). O etcd usa 2379–2380.

Por que os nós ficam `NotReady` logo depois do `kubeadm init`?

RESPOSTA

Porque ainda não há **plugin CNI** instalado; sem rede de Pods, o kubelet não reporta o nó como pronto.

Qual é a regra de diferença de versão entre `kubectl` e o cluster?

RESPOSTA

No máximo **uma versão menor** acima ou abaixo (um `kubectl` 1.37 fala com 1.36, 1.37 e 1.38).

21.2 kubectl e primeiros passos

Como gerar o YAML de um Deployment sem criá-lo?

RESPOSTA

```
kubectl create deployment web --image=nginx:1.29 --dry-run=client -o yaml > deploy.yaml.
```

Qual é a diferença entre `kubectl apply -f` e `kubectl create -f`?

RESPOSTA

`apply` cria ou atualiza o objeto; `create` só cria e falha com `AlreadyExists` se ele já existir.

Por que `kubectl expose pod web` pode falhar com "couldn't find port"?

RESPOSTA

Porque o Pod não declara `containerPort` e o comando não recebeu `--port`: o Kubernetes não sabe qual porta expor.

Como acessar um Service ClusterIP a partir da sua máquina?

RESPOSTA

Com `kubectl port-forward svc/<nome> <porta-local>:<porta-do-service>`. O ClusterIP só é alcançável de dentro do cluster.

O que `kubectl get all` deixa de fora?

RESPOSTA

Vários tipos, como ConfigMaps, Secrets, Ingresses, PVCs e ServiceAccounts. Ele lista só alguns tipos de workload e Services.

21.3 Pods

O que os contêineres de um mesmo Pod compartilham?

RESPOSTA

O IP e o namespace de rede (falam por `localhost`), os volumes declarados no Pod e o nó onde rodam.

O que acontece com um Pod criado diretamente, sem controlador, se o nó falhar?

RESPOSTA

Nada o recria: ele simplesmente deixa de existir. Por isso aplicações rodam em Deployments, StatefulSets, DaemonSets ou Jobs.

Como declarar um sidecar nativo e o que ele garante?

RESPOSTA

Como init container com `restartPolicy: Always`. Ele inicia antes dos contêineres principais, roda junto com eles e só é encerrado depois deles (estável desde a 1.33).

Qual é a diferença entre `kubectl exec` e `kubectl attach`?

RESPOSTA

`exec` cria um processo novo no contêiner (ex.: um shell); `attach` se conecta ao STDIN/STDOUT do processo principal, sem criar processo.

Como ler os logs de um contêiner que está em CrashLoopBackOff?

RESPOSTA

`kubectl logs <pod> --previous`, que mostra a saída da execução anterior, a que falhou.

O que significa `OOMKilled` com código `137`?

RESPOSTA

O contêiner passou do **limit de memória** e foi morto pelo kernel.

O que acontece quando um contêiner atinge o limit de CPU?

RESPOSTA

Ele é **estrangulado** (throttling): fica mais lento, mas não é morto.

Quanto é `500m` de CPU e qual a diferença entre `128Mi` e `128M`?

RESPOSTA

`500m` é meio núcleo (0,5 CPU). `128Mi` = 128×1024^2 bytes; `128M` = 128×1000^2 bytes.

Quais são as classes de QoS e qual é despejada primeiro?

RESPOSTA

Guaranteed (requests = limits em todos os contêineres), **Burstable** e **BestEffort** (sem requests nem limits). **BestEffort** é despejada primeiro.

Como aumentar a CPU de um Pod em execução sem recriá-lo?

RESPOSTA

Com o subrecurso `resize` (estável desde a 1.35): `kubectl patch pod <pod> --subresource=resize -p '{...}'`.

Quanto tempo vive um `emptyDir` e para que ele serve?

RESPOSTA

O mesmo que o Pod (sobrevive a reinícios de contêiner, não à remoção do Pod). Serve para compartilhar arquivos entre contêineres do Pod, cache e temporários.

Quanto tempo o kubelet espera entre o `SIGTERM` e o `SIGKILL`?

RESPOSTA

`terminationGracePeriodSeconds`, **30 s** por padrão.

21.4 Deployments, ReplicaSets e DaemonSets

Qual é a relação entre Deployment, ReplicaSet e Pod?

RESPOSTA

O Deployment gerencia ReplicaSets (um por versão do template); cada ReplicaSet mantém um número de Pods idênticos.

O que cria uma nova revisão em um Deployment?

RESPOSTA

Mudanças em `spec.template` (imagem, variáveis, recursos). Escalar não cria revisão.

Quais são os padrões de `maxSurge` e `maxUnavailable`?

RESPOSTA

25% cada. `maxSurge` arredonda para cima e `maxUnavailable` para baixo; os dois não podem ser 0.

Com 10 réplicas, `maxSurge: 1` e `maxUnavailable: 2`, quais são os limites durante o rollout?

RESPOSTA

No máximo **11** Pods ao todo e no mínimo **8** disponíveis.

Quando usar a estratégia Recreate?

RESPOSTA

Quando duas versões não podem rodar ao mesmo tempo (esquema incompatível, volume RWO compartilhado), aceitando indisponibilidade.

Como registrar o motivo de uma revisão hoje?

RESPOSTA

Com a anotação `kubernetes.io/change-cause`; a flag `--record` está obsoleta.

O que o `kubectl rollout restart` faz?

RESPOSTA

Altera uma anotação de data no template, disparando um rollout que recria os Pods sem mudar a imagem.

Por que não se deve criar ReplicaSets diretamente?

RESPOSTA

Porque o ReplicaSet não atualiza os Pods existentes quando o template muda; não há rollout nem rollback.

Como fazer um DaemonSet rodar também nos nós de control plane?

RESPOSTA

Adicionando uma toleration para o taint `node-role.kubernetes.io/control-plane:NoSchedule`.

Quais são as estratégias de atualização de um DaemonSet?

RESPOSTA

RollingUpdate (padrão, `maxUnavailable: 1`) e OnDelete (só recria os Pods que você apagar).

21.5

Probes

O que acontece quando cada tipo de probe falha?

RESPOSTA

Liveness: o contêiner é reiniciado. **Readiness:** o Pod sai dos endpoints do Service. **Startup:** após o limite, o contêiner é reiniciado; enquanto ela não passa, as outras não rodam.

Quais são os padrões de `periodSeconds`, `timeoutSeconds` e `failureThreshold`?

RESPOSTA

10 s, 1 s e 3.

Por que a liveness não deve checar o banco de dados?

RESPOSTA

Se o banco cair, todos os contêineres reiniciam em cadeia sem resolver nada. Dependências vão, no máximo, na readiness.

Como proteger uma aplicação que demora 2 minutos para iniciar?

RESPOSTA

Com uma **startupProbe** cujo `failureThreshold × periodSeconds` seja maior que o tempo de inicialização.

O que são os Pods estáticos do kubeadm?

RESPOSTA

Manifestos em `/etc/kubernetes/manifests` que o kubelet executa diretamente: API server, scheduler, controller-manager e etcd.

Como gerar um novo comando de `kubeadm join` depois que o token expirou?

RESPOSTA

`kubeadm token create --print-join-command` no control plane. O token padrão vale 24 h.

O que significa `volumeBindingMode: WaitForFirstConsumer`?

RESPOSTA

O disco só é criado e vinculado quando um Pod que usa o PVC é agendado, garantindo que fique na mesma zona do nó.

Qual é a diferença entre as reclaim policies `Delete` e `Retain`?

RESPOSTA

`Delete` apaga o PV e o disco quando o PVC é removido; `Retain` mantém o PV (`Released`) e os dados para recuperação manual.

Quais são os modos de acesso de um volume?

RESPOSTA

RWO (um nó), ROX (leitura em vários nós), RWX (leitura e escrita em vários nós) e RWOP (um único Pod).

O que substituiu os provisionadores `kubernetes.io/aws-ebs` e similares?

RESPOSTA

Os **drivers CSI** (`ebs.csi.aws.com`, `pd.csi.storage.gke.io`, `disk.csi.azure.com`).

Como o Service descobre para quais Pods mandar tráfego?

RESPOSTA

Pelo seletor de labels; o controlador grava os Pods **prontos** em `EndpointSlices`, e o kube-proxy programa as regras.

Qual é o nome DNS completo do Service `redis` no namespace `loja`?

RESPOSTA

`redis.loja.svc.cluster.local`.

O que é um Service headless?

RESPOSTA

Um Service com `clusterIP: None`: sem IP virtual, o DNS devolve os IPs dos Pods. É usado por StatefulSets para dar nome a cada réplica.

Como o LoadBalancer funciona fora de nuvem?

RESPOSTA

Precisa de uma implementação como MetalLB (bare metal), cloud-provider-kind (kind) ou `minikube tunnel`; sem ela, o IP externo fica `<pending>`.

Quais garantias um StatefulSet dá?

RESPOSTA

Nomes fixos e ordenados, DNS por réplica via Service headless, um PVC por réplica que acompanha o Pod, e criação, remoção e atualização em ordem.

Como testar uma versão nova em só algumas réplicas de um StatefulSet?

RESPOSTA

Com `updateStrategy.rollingUpdate.partition`: só Pods com índice maior ou igual ao valor são atualizados.

21.7 Configuração, entrada de tráfego e certificados

Base64 protege um Secret?

RESPOSTA

Não. É só codificação. A proteção vem de RBAC, criptografia em repouso no etcd e de não versionar os valores.

Quando um ConfigMap alterado chega ao Pod?

RESPOSTA

Arquivos montados como volume são atualizados em até cerca de um minuto (exceto com `subPath`); variáveis de ambiente só mudam com a recriação do Pod.

Como usar uma imagem de registry privado?

RESPOSTA

Criando um Secret `docker-registry` e referenciando-o em `imagePullSecrets` do Pod ou da ServiceAccount.

Quais são as chaves de um Secret do tipo `kubernetes.io/tls` ?

RESPOSTA

`tls.crt` e `tls.key`.

O que o External Secrets Operator faz?

RESPOSTA

Busca segredos em cofres externos (Vault, AWS Secrets Manager, Key Vault...) e cria e atualiza Secrets do Kubernetes a partir deles, por meio de `SecretStore` / `ClusterSecretStore` e `ExternalSecret`.

O que aconteceu com o ingress-nginx?

RESPOSTA

O projeto da comunidade Kubernetes foi aposentado em março de 2026: sem novas versões nem correções de segurança. A recomendação é migrar para a Gateway API ou outro controlador mantido.

Quais são os recursos principais da Gateway API?

RESPOSTA

GatewayClass (implementação), **Gateway** (pontos de entrada, mantidos pela plataforma) e **HTTPRoute/GRPCRoute** (rotas, mantidas pelas aplicações).

Por que uma regra de Ingress com `- host:` e `- http:` em itens separados é um problema?

RESPOSTA

Porque vira uma regra sem caminhos e outra sem host, que responde para qualquer nome.

Qual desafio ACME permite certificados curinga?

RESPOSTA

O **DNS-01**. O HTTP-01 não emite curingas.

Por que testar o cert-manager com o ambiente staging do Let's Encrypt?

RESPOSTA

Porque a produção tem limites de emissão; erros repetidos bloqueiam novos certificados por um tempo.

Qual é a fórmula do HPA?**RESPOSTA**

$\text{réplicas desejadas} = \lceil \text{réplicas atuais} \times (\text{métrica atual} \div \text{alvo}) \rceil$, com tolerância de 10% e janela de estabilização de 300 s para reduzir.

Por que um HPA mostra `<unknown>` em TARGETS?**RESPOSTA**

Falta o Metrics Server ou os contêineres não têm **requests** do recurso usado na métrica.

O que o KEDA faz que o HPA sozinho não faz?**RESPOSTA**

Escala a partir de eventos externos (filas, Kafka, cron) e pode reduzir a zero réplicas.

Quais são os efeitos de um taint?**RESPOSTA**

`NoSchedule` (não agenda novos), `PreferNoSchedule` (evita) e `NoExecute` (não agenda e despeja os que não toleram).

Por que um Pod leva cerca de 5 minutos para ser recriado quando o nó dele morre?**RESPOSTA**

Porque os Pods recebem tolerations automáticas de 300 s para os taints `not-ready` e `unreachable`.

Como reservar nós de GPU só para cargas de GPU?**RESPOSTA**

Taint nos nós de GPU (afasta os outros) + toleration e `nodeAffinity/nodeSelector` nos Pods de GPU (atrai estes).

Por que preferir `topologySpreadConstraints` à antiafinidade obrigatória?**RESPOSTA**

Porque espalha réplicas sem travar o escalonamento: a antiafinidade `required` deixa `Pending` as réplicas que excedem o número de domínios.

Para que serve um PodDisruptionBudget?

RESPOSTA

Limitar quantos Pods de uma aplicação podem ser removidos voluntariamente ao mesmo tempo (drain, atualizações de nós).

Quais são os níveis do Pod Security Admission?

RESPOSTA

privileged, baseline e restricted, aplicados por labels no namespace nos modos enforce, warn e audit.

O que é a ValidatingAdmissionPolicy?

RESPOSTA

Um mecanismo nativo (estável desde a 1.30) de validação na admissão com regras em CEL, sem webhook.

Quais funções o Kyverno oferece?

RESPOSTA

Validar, modificar, gerar e apagar recursos e verificar imagens. Na versão 1.19, os tipos novos (ValidatingPolicy, MutatingPolicy ...) substituem o ClusterPolicy, que ficou obsoleto.

21.9

Network Policies, RBAC e Helm

Qual é o comportamento padrão da rede de Pods sem NetworkPolicies?

RESPOSTA

Todo Pod pode falar com todo Pod. Um Pod passa a ser isolado em uma direção quando alguma política o seleciona nessa direção.

Qual é a diferença entre namespaceSelector e podSelector em itens separados ou no mesmo item?

RESPOSTA

Itens separados são **OU**; no mesmo item, significam "Pods com estas labels **nos** namespaces com estas labels" (**E**).

O que costuma quebrar depois de uma política "negar tudo" com Egress?

RESPOSTA

O **DNS**. É preciso liberar a saída para o CoreDNS em UDP e TCP 53.

Como o Kubernetes identifica um usuário autenticado por certificado?

RESPOSTA

Pelo CN (nome do usuário) e pelos O (grupos) do certificado assinado pela CA do cluster.

Qual é a diferença entre RoleBinding e ClusterRoleBinding?

RESPOSTA

O RoleBinding concede uma Role ou ClusterRole dentro de um namespace; o ClusterRoleBinding concede uma ClusterRole no cluster inteiro.

Como verificar as permissões de uma ServiceAccount?

RESPOSTA

```
kubectl auth can-i --list -n <ns> --as=system:serviceaccount:<ns>:<nome>.
```

Por que dar permissão de criar Pods é sensível?

RESPOSTA

Porque quem cria Pods pode montar qualquer Secret e usar qualquer ServiceAccount do namespace.

Como obter um token para uma ServiceAccount hoje?

RESPOSTA

`kubectl create token <sa> --duration=1h`, que emite um token temporário. Desde a 1.24, não são mais criados Secrets de token automaticamente.

Qual é a diferença entre chart e release no Helm?

RESPOSTA

O chart é o pacote; a release é uma instalação dele, com nome, namespace e histórico de revisões.

Qual é a ordem de precedência dos valores no Helm?

RESPOSTA

values.yaml do chart < arquivos -f (na ordem) < --set .

Como acessar no template um valor cuja chave tem hífen?

RESPOSTA

Com `index .Values "minha-chave"`, ou renomeando a chave para camelCase.

Como conferir o YAML que um chart vai gerar sem instalá-lo?

RESPOSTA

`helm template <release> <chart> -f valores.yaml` (ou `helm install --dry-run=server` para validar no cluster).

Quais flags mudaram de nome no Helm 4?

RESPOSTA

`--atomic` virou `--rollback-on-failure` e `--force` virou `--force-replace`.

Síntese de revisão

Este guia percorre o Kubernetes da arquitetura do cluster à entrega de aplicações com Helm, reunindo formatos de consulta rápida e prática ativa.

- O Kubernetes é declarativo: o API server guarda o estado desejado no etcd, e controladores, scheduler e kubelet trabalham em laços para alcançá-lo. O runtime (containerd ou CRI-O) executa os contêineres pela CRI (capítulos 1 a 3).
- Aplicações rodam em Pods criados por controladores: Deployments para réplicas sem estado, StatefulSets para identidade e dados, DaemonSets para agentes de nó. Requests, limits e probes definem onde e como elas rodam (capítulos 4 a 7 e 10).
- Volumes com CSI e StorageClasses, Services com DNS, ConfigMaps e Secrets e a entrada de tráfego pela Gateway API (ou por um Ingress mantido) com cert-manager completam a aplicação (capítulos 8 a 12).
- HPA, regras de agendamento, políticas de admissão, Network Policies e RBAC sustentam a operação segura; o Helm empacota tudo em charts versionados (capítulos 13 a 18).
- As pegadinhas, a referência de comandos e o autoteste (capítulos 19 a 21) oferecem revisão rápida, com 87 perguntas. Versões e comportamentos foram conferidos em setembro de 2026.